

¿Cuánto depende el mapa de la ciencia del modelo de embeddings?

Alejandro Treny Ortega

Investigador independiente

Versión española para revisión personal • 20 de septiembre de 2026

Resumen

Los mapas de la ciencia describen relaciones entre artículos. Los modelos de embeddings de texto construyen esas relaciones al convertir el texto de un artículo en una lista de números que le da una posición. ¿Otro modelo daría la misma imagen? Comparo diez modelos con los títulos y resúmenes de 500.000 publicaciones de 2000–2024 del catálogo bibliográfico OpenAlex, repartidas en 26 disciplinas, como Medicina o Física. Representar cada disciplina mediante la posición media de sus artículos produce una organización parecida entre modelos, también al elegir otros artículos. Sin embargo, dentro de una disciplina y período, dos modelos comparten, en promedio, solo ocho de los 25 artículos más cercanos a un mismo trabajo. Darles solo los títulos también cambia buena parte de esa lista, con efectos que varían entre modelos. Los modelos también pueden discrepar sobre qué disciplina tiene sus artículos más dispersos. Cuando medimos esa dispersión mediante ángulos desde un punto común, mover ese punto puede cambiar la comparación, incluso cuando elegir otros artículos no la cambia. Estas pruebas distinguen el acuerdo entre modelos de la estabilidad al elegir artículos. La organización general puede mantenerse mientras las respuestas sobre artículos cercanos y diferencias entre disciplinas dependen del modelo, del texto que recibe y de cómo se procesa su salida.

Palabras clave: mapas de la ciencia; embeddings de documentos; robustez; acuerdo de vecindarios; comparaciones geométricas.

1. Introducción

Un mapa de la ciencia puede ayudar a encontrar artículos relacionados o a comparar áreas de investigación. Su utilidad depende de las relaciones que muestra. Cuando un modelo obtiene esas relaciones a partir del texto, elegir el modelo también forma parte de elegir el mapa. Dos modelos pueden llevar al lector a artículos distintos cerca de un mismo trabajo, o discrepar sobre lo dispersos que están los artículos de un área. En este estudio pregunto cuánto cambia la respuesta si mantenemos los artículos y usamos otro modelo para representarlos.

Los modelos de este estudio leen el título y el resumen de un artículo y convierten ese texto en una lista de números, llamada vector o *embedding*. Los números funcionan como coordenadas: juntos dan al artículo una posición desde la que podemos calcular distancias a otros artículos. Los que quedan cerca se consideran relacionados. Este procedimiento se ha usado para cartografiar la literatura biomédica y la estructura de la física (González-Márquez et al., 2024; Constantino et al., 2025). Pero la posición la produce el modelo. No es una relación observada con independencia de él, y el título y el resumen no contienen todo lo que dice el artículo.

Esta preocupación tiene una trayectoria en los estudios de mapas de la ciencia. Gläser et al. (2017) preguntaron cuánto refleja una estructura temática reconstruida el conocimiento científico y cuánto refleja el método utilizado para recuperarla. Boyack and Klavans (2020) encontraron que distintos métodos podían lograr una precisión global parecida y, al mismo tiempo, asignar artículos diferentes a cada grupo. Por tanto, una puntuación general puede dejar sin respuesta una pregunta importante: ¿otro método respaldaría la comparación concreta que quiere hacer el lector?

Utilizo diez modelos y una colección fija de 500.000 publicaciones para examinar tres preguntas. La primera trata sobre las relaciones compartidas: ¿conservan los modelos la organización general de las áreas y encuentran los mismos artículos cercanos? La segunda pregunta cuánto del cambio viene de lo que lee el modelo: ¿importa dar solo el título tanto como cambiar de modelo? La tercera, añadida como una exploración posterior, trata sobre una descripción que podríamos extraer del mapa: ¿coinciden los modelos en que los artículos de un área están más dispersos que los de otra? Repetir cada tipo de comparación con otras selecciones de artículos permite ver también si la respuesta depende de los trabajos concretos elegidos.

La aportación consiste en seguir las comparaciones que un lector podría extraer de un mapa de la ciencia y comprobar qué decisiones resisten. La afirmación de que los artículos de un área están más dispersos que los de otra puede repetirse al elegir otros artículos y, aun así, recibir respuestas contrarias de distintos modelos. Examino esos desacuerdos persistentes junto con el tamaño de las diferencias y su dependencia del procesamiento. Así, la comparación general entre modelos se conecta con la fiabilidad de afirmaciones concretas sobre las áreas de investigación.

2. Antecedentes y preguntas de investigación

2.1. Qué aportan las comparaciones anteriores

Los trabajos previos evalúan los embeddings científicos con varios criterios útiles. Constantino et al. (2025) los comparan con clasificaciones disciplinares de física; González-Márquez et al. (2024) examinan artículos biomédicos relacionados y sus etiquetas. Estas comprobaciones preguntan si una representación coincide con información sobre la literatura. Este estudio plantea una pregunta complementaria: ¿qué relaciones se mantienen cuando cambia la representación?

Elegir el modelo es solo una de las decisiones. El *texto de entrada* es el que le damos para que lo lea: un título solo ofrece menos información que un título seguido de su resumen. Los modelos también admiten textos de distinta longitud y utilizan reglas distintas para producir un único vector. Singh and Singh (2022) muestran que la búsqueda académica puede ser sensible a cómo se redactan las consultas cortas. Por eso, el texto entregado al modelo forma parte de la comparación junto con el propio modelo.

Varias partes de esta comparación tienen antecedentes directos. Caspari et al. (2024) combinan la similitud de estructura con la coincidencia de los documentos recuperados. Imel and Hafen (2025) estudian la geometría local de la literatura científica, y Raju (2026) distingue la similitud entre representaciones de la estabilidad de su geometría. Aquí llevo esas preguntas a comparaciones concretas entre áreas de investigación. Para cada pareja de áreas, compruebo si un modelo conserva el mismo orden al elegir otros artículos, si otro modelo sostiene de forma persistente el orden contrario y si esos mismos modelos mantienen sus respuestas después de cambiar el procesamiento. Las comparaciones emparejadas de texto y búsqueda permiten precisar qué otras decisiones afectan al resultado.

2.2. Qué permite afirmar el acuerdo

Conviene separar dos cambios. Para medir el *acuerdo*, mantengo los artículos y comparo modelos. Para comprobar la *estabilidad ante la selección*, mantengo el modelo y elijo otros artículos con las mismas reglas. Una *selección de artículos* es un conjunto elegido de la colección existente; repetirla no significa descargar trabajos nuevos. Un resultado puede repetirse con otros artículos en cada modelo y, aun así, los modelos pueden dar siempre respuestas opuestas.

Ninguna de estas dos propiedades demuestra que la respuesta sea correcta sobre la investigación. Los modelos pueden compartir un error, y un patrón que se repite puede ser difícil de interpretar. En un estudio de biología de invasiones, Held and Velden (2022) muestran por qué las agrupaciones temáticas necesitan una interpretación que vaya más allá de las

comprobaciones numéricas. Aquí, el acuerdo indica que un resultado se mantiene al cambiar de modelo; no demuestra que describa correctamente los temas.

La palabra mapa necesita otra precisión. Comparo las posiciones numéricas, cada una con cientos de coordenadas, antes de reducirlas a un dibujo. Un gráfico de dos dimensiones añadiría una transformación que podría cambiar las distancias aparentes. Llamo *estructura* al patrón de relaciones entre los objetos que comparamos, sean artículos o resúmenes de áreas. La *dispersión* describe cuánto se separan las representaciones dentro de un área. Dos modelos pueden compartir buena parte de la estructura general sin coincidir sobre la dispersión de cada área.

2.3. Preguntas de investigación

PI1. Al cambiar de modelo, ¿qué se mantiene de la organización de las áreas y de los artículos que quedan cerca unos de otros?

PI2. ¿Cuánto importa cambiar el texto de entrada, o la regla para obtener un único vector por artículo, en comparación con cambiar de modelo?

PI3. ¿Coinciden los modelos sobre qué área tiene sus representaciones más dispersas, o sobre si esa dispersión se concentra en pocas direcciones o se reparte entre muchas? ¿Se repiten estas comparaciones con otros artículos?

La tercera pregunta se añadió después de las comparaciones iniciales y es exploratoria. Las tres se refieren a una colección y un conjunto de modelos concretos. No buscan elegir un modelo ganador ni estimar la estructura de toda la literatura científica.

3. Datos y métodos

3.1. Una colección, varias preguntas

OpenAlex es un catálogo bibliográfico que proporciona títulos, resúmenes y otros datos de publicaciones (Priem et al., 2022). La colección de partida, o corpus, contiene 500.000 identificadores distintos de trabajos descargados y limpiados hasta el 15 de septiembre de 2026. Los registros estaban etiquetados como artículos, revisiones o trabajos de congreso en inglés, publicados entre 2000 y 2024. Cada uno debía tener título, un resumen de al menos 50 palabras reconstruido a partir del formato que guarda OpenAlex y un área principal. Se excluyeron retractaciones, material accesorio y fallos claros de contenido. Los casos menos seguros y las posibles versiones duplicadas se conservaron con marcas de revisión. Esas marcas registran una duda para las comprobaciones posteriores; no certifican que todos los registros conservados sean correctos. El Suplemento S1 recoge las reglas y los recuentos.

OpenAlex asigna los artículos a áreas amplias, llamadas *Fields*, y a categorías más estrechas, llamadas *Subfields*, a partir de información del texto, las citas y las revistas (OpenAlex, 2026). Aquí las denomino áreas y especialidades. Por ejemplo, Medicina es un área; Cardiología y Medicina Cardiovascular es una de sus especialidades. Las 26 áreas son las unidades principales de comparación. Estas etiquetas de la base de datos permiten organizar el análisis; no son descripciones de cada artículo verificadas de forma independiente.

La colección tiene dos partes. Las peticiones aleatorias a OpenAlex, con las elecciones registradas para poder repetirlas, proporcionaron 400.000 registros que cumplían los requisitos. Otros 100.000 reforzaron los grupos que inicialmente tenían pocos artículos de una misma área y período de cinco años. Por ejemplo, Medicina en 2000–04 es uno de esos grupos. Los cinco períodos son 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Al combinarlos con las 26 áreas obtenemos 130 grupos de área y período, cada uno con al menos 2.165 artículos. Las búsquedas en toda la colección general utilizan los 400.000 registros iniciales; las comparaciones dentro de áreas pueden usar ambas partes. El refuerzo facilita comparar los grupos pequeños, pero cambia su peso en la colección. Ni ese peso ni una media que da la misma importancia a cada área estiman las proporciones de la producción científica mundial.

Los diez modelos representan los 500.000 artículos mediante sus títulos y resúmenes, pero cada pregunta posterior utiliza los artículos que necesita. El *experimento de texto* compara títulos, resúmenes y ambos juntos en los mismos 52.000 artículos: 2.000 por área, con 400 de cada período. Incluyen los 26.000 de la primera prueba más pequeña. El estudio posterior de la dispersión dentro de las áreas reutiliza este conjunto y sus vectores de título más resumen. La *comprobación de fragmento común* utiliza otro conjunto distinto de 52.000 artículos para que todos los modelos lean exactamente el mismo fragmento, suficientemente corto para caber en todos. Así se distingue una elección sobre el contenido de otra sobre su longitud. La Tabla 1 sirve de guía para estas comparaciones; sus filas se solapan y no deben sumarse. Dentro de cada comparación, los modelos siempre representan los mismos identificadores de artículos.

3.2. Cómo representa cada modelo un artículo

Los diez modelos de la Tabla 2 ya estaban entrenados antes de este estudio. Utilizo sus versiones publicadas para convertir texto en vectores, sin volver a entrenarlos con esta colección. Abarcan documentos científicos, semejanza entre frases de uso general y lenguaje científico o biomédico. Se eligieron por su uso para representar literatura académica y por sus distintas formas de entrenamiento. Son un conjunto fijo de comparación, no una muestra aleatoria de modelos ni una clasificación de los sistemas más recientes. Las versiones, los formatos de entrada y la configuración de los programas se fijaron antes de calcular los vectores.

La entrada principal es el título seguido del resumen, con el formato habitual de cada modelo. Los modelos dividen el texto en piezas pequeñas llamadas *tokens*, que pueden ser palabras

Tabla 1: Preguntas, comparaciones y conjuntos de artículos.

Pregunta	Qué se compara	Artículos utilizados
¿Se conserva la organización general?	Diez modelos: relaciones entre grupos, resumidos por sus posiciones medias, y entre artículos dentro de los grupos.	256 artículos por grupo para calcular su centro; elecciones repetidas y controles con 128 y 512.
¿Encuentran los modelos los mismos artículos cercanos?	Cuántos de los 25 artículos más cercanos aparecen en las listas de ambos modelos.	Todos los artículos de cada área y período; otro control fija 2.048 candidatos por grupo. Búsqueda global: 13.000 artículos de partida entre 400.000 candidatos.
¿Importa cambiar el texto de entrada?	El mismo modelo lee solo el título, solo el resumen o ambos.	52.000: 2.000 por área, 400 por período. Incluye la primera prueba de 26.000.
¿Importa que todos lean el mismo fragmento?	La entrada habitual de cada modelo frente a un fragmento común que cabe en todos.	Otro conjunto de 52.000, con 400 por área y período.
¿Coinciden los modelos sobre la dispersión dentro de áreas?	Ángulos entre vectores de artículos y reparto de su variación entre direcciones; las 325 parejas de áreas, con diez modelos.	Los mismos 52.000 del experimento de texto; otras elecciones de artículos comprueban si las comparaciones se repiten.
¿Importa limitar la búsqueda a una especialidad?	Por ejemplo, Cardiología y Medicina Cardiovascular frente a Medicina, con 256 candidatos en cada búsqueda.	50 artículos de partida fijos por especialidad; diez elecciones de los otros 206 candidatos. En total, 10.850 artículos de partida en 217 especialidades.

Todos los conjuntos proceden de la misma colección de 500.000 artículos: 400.000 registros generales y 100.000 para reforzar grupos pequeños de área y período. Las filas no se suman. Los modelos usan los mismos identificadores en cada comparación. Los candidatos son los artículos disponibles para buscar vecinos. En la comparación de alcance, ambos conjuntos incluyen los mismos 50 artículos de partida. Los métodos y los Suplementos S1–S4 y S9 detallan los controles. Los 1.300 artículos de prueba del programa no son otra muestra científica.

enteras o partes de palabras. Un límite de tokens no equivale, por tanto, a un límite de palabras. Con su configuración habitual, MiniLM lee como máximo 256 tokens y MPNet 384; el texto que sobrepasa ese límite se recorta. Esto afecta al 49,58 % y al 20,16 % de los artículos, respectivamente. Mantengo esas configuraciones y pruebo MiniLM con 512 tokens por separado. La comprobación de fragmento común aborda la diferencia en lo que pueden leer: todos reciben el mismo contenido, aunque cada modelo lo divida en tokens a su manera.

Otra decisión es cómo obtiene el modelo un único vector para todo el artículo. BERT, SciBERT, BioBERT y PubMedBERT producen un vector de salida en cada posición de token, pero no se entrenaron específicamente para comparar documentos completos. La regla principal calcula la media de esas salidas una vez que el modelo ha terminado de procesar el texto. Este paso se llama *pooling por media*. El promedio incluye los símbolos especiales que delimitan el texto y excluye las posiciones vacías añadidas como relleno. Dos alternativas toman solo la salida de la primera posición de símbolo especial (CLS) o la de la última posición sin relleno (SEP). Estas salidas han procesado el texto que las rodea; no representan solo la primera o la última palabra. La regla de la media se fijó antes de las comparaciones principales y se mantuvo tras las primeras comprobaciones, sin elegirla para maximizar el acuerdo. Los otros seis modelos utilizan sus reglas documentadas. La Tabla 2 y el Suplemento S1 precisan la configuración exacta.

Tabla 2: Modelos de embeddings y reglas principales de representación.

Modelo	Tamaño	Límite de tokens	Vector del artículo	Referencia
SPECTER	768	512	CLS	(Cohan et al., 2020)
SPECTER2	768	512	CLS + adaptador	(Singh et al., 2023)
SciNCL	768	512	CLS	(Ostendorff et al., 2022)
SciBERT	768	512	Media	(Beltagy et al., 2019)
BERT	768	512	Media	(Devlin et al., 2019)
MPNet	768	384	Media	(Reimers and Gurevych, 2019)
MiniLM	384	256	Media	(Reimers and Gurevych, 2019)
PubMedBERT / BiomedBERT	768	512	Media	(Gu et al., 2022)
BioBERT	768	512	Media	(Lee et al., 2020)
SimCSE	768	512	CLS	(Gao et al., 2021)

Tamaño indica cuántas coordenadas contiene el vector, no cuántas palabras lee el modelo. MPNet y MiniLM utilizan all-mpnet-base-v2 y all-MiniLM-L6-v2, respectivamente. Los límites cuentan tokens, las piezas en que el modelo divide el texto, incluidos sus símbolos especiales. Media promedia las salidas finales de tokens (la última capa), con símbolos especiales y sin posiciones vacías de relleno. CLS usa la salida de la primera posición antes de la transformación adicional llamada pooler. SPECTER2 utiliza también su adaptador de proximidad, un componente adicional entrenado. En MPNet/MiniLM, la referencia describe el marco Sentence-BERT, no el entrenamiento exacto de esas versiones. Las reglas alternativas no son modelos adicionales. Versiones, formatos y recorte: Tabla S2.

3.3. Del conjunto de áreas a los artículos individuales

Podemos imaginar un vector como una flecha que va desde un punto común hasta la posición del artículo. Antes de comparar, ajusto todas las flechas a longitud uno, conservando hacia dónde apuntan. Esta operación se llama *normalización*; evita que las diferencias de longitud de los vectores determinen la cercanía. Para resumir un área, calculo la media de los vectores de sus artículos y ajusto también el resultado a longitud uno. Llamo *centro* a ese resumen. Comparar los centros pregunta si los modelos sitúan las áreas en relaciones parecidas entre sí. Comparar los artículos individuales de un área pregunta cuánto comparten de su organización interna.

La primera comparación de centros fija 256 artículos por grupo, para que las diferencias de tamaño entre grupos no determinen la comparación. Considera las 26 áreas, las 217 especialidades y un conjunto reducido con una especialidad de cada área. Para comprobar cuánto importa qué artículos elegimos, repito la selección cincuenta veces, conservando los recuentos de los cinco períodos de publicación dentro de cada grupo. Para comprobar cuánto importa el tamaño, utilizo 128, 256 y 512 artículos en las mismas 26 áreas y las 183 especialidades que tienen suficientes trabajos en los tres tamaños. Son condiciones de comparación, no una afirmación de que un tamaño sea suficiente en cualquier estudio.

Cada selección aporta también una referencia: redistribuyo al azar los mismos artículos entre grupos, conservando el tamaño y los recuentos por período de cada grupo. Así podemos ver cuánto acuerdo queda entre modelos cuando los grupos dejan de seguir las etiquetas de área o especialidad. Otras pruebas retiran un área cada vez y, en el conjunto reducido de especialidades, separan la elección de una especialidad de la elección de sus artículos. El Suplemento S9 detalla estas comprobaciones de centros.

3.4. Cómo se buscan y comparan los artículos cercanos

Los *vecinos* de un artículo son los artículos que quedan más cerca de él. El *artículo de partida* es aquel para el que buscamos vecinos; los *candidatos* son todos los artículos entre los que podemos buscarlos. Cada modelo devuelve los 25 más cercanos, y el acuerdo es la fracción que aparece en las listas de ambos modelos. Las listas de 10 y 50 sirven de comprobación. La cercanía se mide con la similitud coseno: las flechas que apuntan en direcciones más parecidas cuentan como más cercanas. El artículo de partida no puede ser su propio vecino. Las listas se calculan de forma exacta y se comprueban mediante una ordenación independiente.

Una búsqueda depende de los artículos que tiene disponibles. Buscar entre todos los de una misma área y período ofrece cantidades distintas de candidatos según el grupo. Otra comprobación fija 2.048 candidatos por grupo para eliminar esa diferencia de cantidad. Dentro de un grupo, todos los modelos buscan entre los mismos artículos. Una búsqueda adicional utiliza

los 400.000 registros generales, sin limitar área ni período. Estas comparaciones responden a preguntas distintas; por eso, cada resultado indica su conjunto de candidatos.

La comprobación de calidad pregunta si los registros marcados y los duplicados explican el desacuerdo entre modelos. Aplicar las marcas de revisión y la regla de duplicados existentes deja 448.886 registros. Comparo las listas de vecinos de los mismos artículos de partida conservados antes y después de filtrar los candidatos. Quitar registros también reduce el tamaño de búsqueda; por eso, otras pruebas lo mantienen fijo: 1.024 candidatos en los 130 grupos y 2.048 en los 63 que siguen teniendo suficientes artículos tras el filtro. Los conjuntos de antes y después incluyen los mismos 100 artículos de partida limpios por grupo. Aquí, limpios significa que pasan el filtro registrado; no significa que se haya descartado todo posible error de origen.

Para separar el alcance de la búsqueda de su tamaño, comparo una especialidad con su área usando la misma cantidad de candidatos y fechas emparejadas. Pensemos en 50 artículos de partida fijos de Cardiología y Medicina Cardiovascular. Para cada uno, buscamos entre 256 artículos de esa especialidad y entre 256 de Medicina. Ambos conjuntos incluyen los mismos 50 artículos de partida; quedan 206 plazas para otros trabajos. Al ordenar los vecinos, se excluye el artículo para el que estamos buscando. Elijo los otros 206 diez veces, manteniendo fijos los 50 y el mismo reparto de períodos entre ambas búsquedas. El procedimiento abarca 217 especialidades: 10.850 artículos de partida en total. También incluye deliberadamente los 50 artículos de la especialidad en el conjunto amplio. Por tanto, el resultado corresponde a esta comparación emparejada, no a una selección aleatoria sin restricciones dentro de Medicina.

3.5. Cómo se mide la estructura compartida

Para medir la estructura compartida, comparo el patrón de relaciones entre los mismos objetos según dos modelos. Los objetos pueden ser artículos individuales o los centros que resumen áreas. La medida principal es la alineación lineal de núcleos centrados con corrección, abreviada CKA (Kornblith et al., 2019; Murphy et al., 2024). Compara esos patrones sin exigir que una coordenada de un modelo signifique lo mismo que una coordenada de otro. Un valor cercano a uno, como 0,9, indica que los patrones se parecen mucho según esta medida. No significa que ese porcentaje de la ciencia esté representado correctamente. La corrección reduce una elevación artificial conocida de la puntuación cuando se usan muestras finitas; no elimina todo el sesgo estadístico.

Otras dos medidas comprueban aspectos distintos de la estructura compartida. La alineación de Procrustes permite girar y cambiar de escala las representaciones antes de compararlas. La comprobación del orden de distancias pregunta si las parejas de artículos siguen un orden parecido, desde las más cercanas hasta las más alejadas. Estas medidas no tienen por qué

dar respuestas idénticas (Williams et al., 2021; Williams, 2024). Sus fórmulas aparecen en el Suplemento S2.

3.6. Cómo se describe la dispersión dentro de un área

Otra pregunta distinta trata sobre la forma que dibujan los artículos dentro de cada área. Describo dos propiedades. La *apertura angular* resume los ángulos entre sus vectores, con la regla de distancia mediana del Suplemento S6. Podemos imaginar flechas trazadas desde un punto común hasta los artículos: ángulos mayores indican que las flechas apuntan en direcciones más separadas.

La *dimensión lineal efectiva* describe cómo se extiende esa nube de posiciones de artículos entre distintas direcciones. Aquí, variación significa diferencias entre las coordenadas de los artículos. Una nube concentrada a lo largo de una línea varía sobre todo en una dirección; otra extendida sobre un plano varía en más. La razón de participación, o PR, lleva esta idea al espacio completo de los vectores y admite valores entre números enteros. Un PR mayor indica que la variación está menos concentrada en unas pocas direcciones. Ni PR ni la apertura angular cuentan temas de investigación o establecen diversidad temática.

Otras formas de resumir los ángulos y medir la dimensión comprueban cuánto depende la respuesta de la fórmula. Para dimensión, la alternativa basada en entropía mide cómo se reparte la variación. D80 cuenta el menor número de direcciones necesarias para explicar el 80 % de esa variación. Como estas alternativas describen la misma variación de partida, que coincidan no validaría de forma independiente una interpretación temática. Probé también otra idea: si los enlaces débiles entre artículos cercanos podían revelar un área dividida en grupos separados. Los ejemplos artificiales mostraron problemas para leer esa señal como fragmentación temática. El Suplemento S6 recoge las definiciones y los controles.

3.7. Cómo se comprueba si una comparación se repite

Con 26 áreas hay 325 formas de elegir dos áreas distintas, contando cada pareja una sola vez. Para cada propiedad, cada modelo da un valor al área A y otro al área B. Pregunto si la misma área conserva el valor mayor cuando elegimos otros artículos. El cálculo principal utiliza 2.000 artículos por área. Lo repito con veinte medias muestras de 1.000 y cinco selecciones adicionales de 2.000. Un orden es *persistente* solo si se mantiene en las 26 condiciones. Esto se refiere al orden de los dos valores medidos, no a la dirección en la que apunta un vector. Las alternativas de dimensión usan las mismas condiciones.

Otra comprobación cambia el punto común desde el que trazamos las flechas. Para cada modelo, calculo la media de los 52.000 vectores de longitud uno del experimento de texto, equilibrados por área y período, la resto a cada vector y vuelvo a ajustar su longitud a uno. Esta operación se llama *centrado global seguido de normalización*. El nuevo origen es la

posición media de este conjunto. Después vuelvo a calcular apertura y dimensión para ver si las comparaciones entre áreas dependen de esa elección. El Suplemento S6 distingue este cambio de los vectores del centrado interno que ya utiliza la fórmula de PR.

Los resultados se agrupan en tres clases. Hay *acuerdo unánime* si los diez modelos dan de forma persistente el valor mayor a la misma área. Hay *oposición* si al menos dos modelos concretos mantienen órdenes opuestos. En los demás casos, la comparación queda *sin resolver*. Por ejemplo, algunos modelos pueden cambiar de orden con otros artículos y ninguna pareja fija mantener respuestas contrarias. Sin resolver no significa iguales. Tampoco un empate en un modelo deja necesariamente toda la comparación sin resolver: otros dos modelos pueden mantener órdenes opuestos.

También pregunto si las diferencias tienen suficiente tamaño numérico. Además de cualquier diferencia distinta de cero, exijo diferencias mínimas del 1, 5 y 10 % del valor medio de las dos áreas. El orden de un modelo solo cuenta con un corte determinado si su diferencia supera ese corte en todas las selecciones. Después se vuelven a aplicar las tres reglas de clasificación. Estos porcentajes describen el tamaño de una diferencia medida; son distintos del porcentaje de las 325 parejas que acaba en una clase. Son comprobaciones de sensibilidad, no umbrales universales de importancia científica.

Otro diagnóstico distinto, la *alerta de selección*, señala un resultado que cambia más de lo permitido por una tolerancia registrada al elegir otros artículos o usar otro tamaño de los probados. Identifica un resultado cuya sensibilidad a la elección de artículos conviene examinar; no es un error en un registro ni una de las tres clases de parejas de áreas anteriores. Cada comprobación tiene su propia regla y recuento, conservados en el suplemento.

Las selecciones se solapan porque proceden de la misma colección fija. Sus rangos describen cambios entre los artículos disponibles, no intervalos de confianza para toda la literatura científica. Un rango central del 95 % de las selecciones deja fuera el 2,5 % inferior y el 2,5 % superior de los resultados registrados. Las comparaciones también reutilizan modelos y áreas; por eso describo sus patrones sin tratarlas como observaciones independientes en pruebas de significación.

El trabajo se desarrolló por etapas. Las primeras comparaciones de estructura y vecinos precedieron a la ampliación del experimento de texto y a las búsquedas por especialidad. El análisis geométrico fue una exploración posterior, y el resumen de las 325 parejas de áreas se hizo después de conocer sus primeros ejemplos. Las reglas se registraron antes de los nuevos cálculos correspondientes, con resultados anteriores ya conocidos; algunos controles se añadieron durante el proceso. El Suplemento S2 documenta esta secuencia. El estudio completo no se registró previamente en un servicio externo, por lo que estas comprobaciones posteriores no deben leerse como predicciones formuladas antes de ver ningún resultado.

4. Resultados

4.1. La organización general se comparte más que el detalle

Los modelos comparten una organización parecida de los centros de áreas, y elegir otros artículos cambia poco esa conclusión. Cada media reúne las 45 formas de emparejar los diez modelos. En la selección original, la CKA corregida media es 0,939 para centros de áreas y 0,911 para centros de especialidades. Con cincuenta selecciones, las medias son 0,940 y 0,911, con rangos centrales del 95 % de 0,937–0,943 y 0,910–0,912 (Figura 1A). Los grupos redistribuidos al azar dan medias de 0,627 y 0,636. Ninguna media de sus selecciones alcanza la menor media de las selecciones observadas. Por tanto, los grupos definidos por las etiquetas producen más estructura compartida que estas referencias aleatorias.

La organización también cambia poco cuando los centros utilizan más artículos. Con 128, 256 y 512 artículos, las medias de los centros de áreas son 0,938, 0,940 y 0,941; las mismas 183 especialidades con suficientes trabajos dan 0,913, 0,914 y 0,915. Retirar un área cada vez da valores entre 0,933 y 0,946 en la comparación original, por lo que ninguna explica por sí sola el alto acuerdo. Cuando una sola especialidad representa cada área, la media es 0,904. En esta comparación reducida, cambiar qué especialidad representa un área importa más que cambiar los artículos elegidos dentro de ella (Tabla S18).

El acuerdo es menor cuando comparamos los artículos individuales dentro de un grupo. La CKA media se mantiene alrededor de 0,63 dentro de áreas y 0,64 dentro de las mismas 183 especialidades al pasar de 128 a 512 artículos (Figura 1B). Esa media estable oculta comparaciones concretas que cambian más. De las 8.235 combinaciones de una especialidad y una pareja de modelos, 2.628 activan la alerta de selección (31,9 %): su acuerdo cambia más de lo permitido por la tolerancia registrada al elegir artículos o variar el tamaño entre los probados. Por tanto, una media estable no vuelve estable cada resultado de especialidad. La comparación con centros también utiliza objetos distintos: resúmenes de grupos frente a artículos individuales. No permite aislar el efecto de la escala por sí solo.

Las medidas alternativas de estructura coinciden en buena parte sobre qué parejas de modelos se parecen más. Dentro de cada uno de los 130 grupos originales de área y período, ordeno las parejas de modelos de menor a mayor acuerdo y comparo esos órdenes. Sus correlaciones medias de rangos con la CKA corregida son 0,891 para Procrustes y 0,881 para el orden de distancias; los valores más cercanos a uno indican órdenes más parecidos. La coincidencia no es completa. La comprobación original de selección de artículos conserva además 50 alertas entre 5.850 comparaciones, correspondientes a 45 parejas de modelos en cada uno de los 130 grupos (Tabla S4). Es una comprobación distinta de las alertas de especialidades anteriores, con sus propios tamaños y tolerancias.




Figura 1: Acuerdo sobre centros de grupos y artículos individuales. Una CKA corregida mayor indica más acuerdo entre modelos. (A) Cada centro resume 256 artículos. Los resultados de áreas y especialidades promedian cincuenta selecciones de artículos. La condición de 26 especialidades elige una de cada una de las 26 áreas, repite esa elección cincuenta veces y elige diez conjuntos de artículos dentro de cada elección. Los grupos aleatorios redistribuyen los mismos artículos, conservando tamaños y fechas. Las líneas abarcan el 95 % central de las medias entre selecciones. (B) Acuerdo entre artículos individuales dentro de 26 áreas y las mismas 183 especialidades, con tres cantidades de artículos. Los puntos muestran medias; las líneas abarcan el 95 % central de los resultados de grupo y pareja de modelos: 1.170 para áreas y 8.235 para especialidades. El panel A compara relaciones entre resúmenes de grupos; el B, relaciones entre artículos dentro de grupos. Sus rangos describen fuentes distintas de variación y no son intervalos de confianza.

4.2. Cambiar el modelo cambia qué artículos aparecen cerca

Cuando todos los artículos de una misma área y período están disponibles como candidatos, dos modelos comparten en promedio el 30,3 % de los 25 vecinos más próximos: unos ocho artículos de 25. La media da el mismo peso a cada grupo de área y período y a cada pareja de modelos. Fijar la cantidad de candidatos en 2.048 por grupo da un acuerdo del 31,9 %. La cantidad es común entre grupos; los artículos concretos son comunes entre modelos dentro de cada grupo, no entre disciplinas.

La búsqueda en la colección general plantea una pregunta más amplia. Toma 100 artículos de partida de cada uno de los 130 grupos, 13.000 en total, y busca entre los 400.000 registros generales. El acuerdo es del 17,5 %. Esta búsqueda admite otras disciplinas y períodos y, a la vez, ofrece muchos más candidatos. Como ambas cosas cambian juntas, la comparación no permite saber cuánto del menor acuerdo procede de cada cambio.

Filtrar las marcas de origen y los duplicados cambia poco este panorama. Para que la comparación de antes y después sea justa, ambas medias utilizan solo los artículos de partida que sobreviven al filtro. Su acuerdo inicial es del 30,58 %, algo distinto del 30,3 % anterior para todos los artículos de partida, y sube al 31,43 % tras filtrar los candidatos. La ganancia es de 0,85 puntos porcentuales. Ambas medias siguen equivaliendo a unos ocho artículos compartidos de 25. Mantener fija la cantidad de candidatos reduce la ganancia a 0,28 puntos con 1.024 candidatos y 0,19 con 2.048. Los problemas eliminados por este filtro explican poco del desacuerdo general, aunque algunas áreas cambian más que otras (Tabla S19).

Las búsquedas emparejadas de especialidades permiten acotar mejor el cambio de alcance disciplinar: ambas tienen 256 candidatos, los mismos artículos de partida y fechas emparejadas (Figura 2). Buscar dentro de la especialidad hace que los modelos compartan menos de sus 25 vecinos en 127 de 217 especialidades (58,5 %), pero más en las otras 90 (41,5 %). El cambio medio respecto a buscar en el área amplia es de $-1,35$ puntos porcentuales. Con listas de 50 vecinos, el reparto es casi igual: 109 especialidades bajan y 108 suben. Por tanto, estrechar la búsqueda no tiene el mismo efecto en todas partes. Estos resultados describen cuánto coinciden las listas de los modelos; no evalúan lo útiles que son los artículos encontrados.

Las parejas de modelos que coinciden más en la estructura general también tienden a compartir más vecinos. Ordenar las 45 parejas de modelos según cada tipo de acuerdo da una correlación de rangos de 0,920. Esta asociación no vuelve intercambiables las dos comprobaciones: una pareja puede conservar las relaciones generales y sustituir muchos vecinos individuales. Además, las parejas reutilizan modelos, por lo que la asociación es descriptiva y no evidencia procedente de 45 observaciones independientes.

El Suplemento S4 pasa de las medias a artículos concretos: comprueba si un artículo conserva sus vecinos al cambiar el tamaño de muestra, la regla que forma su vector o la longitud de la lista de vecinos. Leer esos ejemplos también permitió detectar problemas de origen. Un libro de historia aparece en Física, un texto sobre infección bacteriana en Política y otro registro es un anuncio. Los contrasté con los registros descargados de OpenAlex: esas etiquetas y contenidos ya estaban allí; no surgieron al confundir artículos entre las salidas de los modelos. Los ejemplos permanecen en el análisis. Como se eligieron casos concretos para examinarlos, su número no estima la frecuencia de esos problemas en la colección.




Figura 2: ¿Cambia el acuerdo al buscar dentro de una especialidad? Cada punto representa una de 217 especialidades. El eje horizontal muestra la fracción de vecinos compartidos por los modelos al buscar en el área amplia, como Medicina. El vertical muestra esa fracción dentro de su especialidad, como Cardiología y Medicina Cardiovascular. Por encima de la diagonal, los modelos comparten más vecinos en la búsqueda estrecha; por debajo, menos. Ambos conjuntos tienen 256 candidatos, incluidos los mismos 50 artículos de partida, con fechas emparejadas. Los valores promedian parejas de modelos y diez elecciones de los otros 206 candidatos. El conjunto del área amplia siempre incluye esos 50 artículos de la especialidad. Las diferencias entre puntos describen especialidades, no intervalos de confianza.

4.3. Medias parecidas ocultan comportamientos distintos entre modelos

El experimento de texto cambia ahora lo que lee el modelo. Utiliza los mismos 52.000 artículos para tres entradas: solo título, solo resumen y título más resumen. Aquí, cada área aporta 2.000 candidatos que reúnen sus cinco períodos. Es una búsqueda distinta de las anteriores dentro de una sola área y período.

Partiendo de título más resumen, comparo mantener el texto y cambiar de modelo con mantener el modelo y darle solo el título. El primer cambio sustituye, en promedio, el 68,8 % de los 25 vecinos; el segundo, el 70,7 % (Figura 3). Son fracciones sustituidas, por lo que un

valor mayor significa menos acuerdo. Los cambios de estructura correspondientes son 0,370 y 0,366, medidos como uno menos CKA: restar el acuerdo de uno hace que aquí también los valores mayores signifiquen más cambio. Los dos cambios medios se parecen, pero no tienen por qué parecerse en cada modelo.




Figura 3: Cambiar de modelo o cambiar su entrada. Todas las comparaciones utilizan los mismos 52.000 artículos, con 2.000 por área repartidos entre cinco períodos. La entrada inicial es título más resumen. El cambio de modelo compara modelos con esa entrada; el cambio de texto mantiene el modelo y utiliza solo el título o solo el resumen. Los valores mayores indican más cambio: (A) uno menos CKA corregida; (B) fracción de 25 vecinos sustituidos entre los 2.000 candidatos del área. Cada punto es una media de área. La línea de cada caja es la mediana; la caja abarca la mitad central de los valores de áreas. Las líneas exteriores llegan hasta los valores situados a menos de 1,5 alturas de caja de sus bordes. Estas distribuciones describen diferencias entre áreas, no intervalos de confianza. Los modelos conservan sus límites habituales de texto.

Conservar el resumen y retirar solo el título cambia menos: 0,027 para estructura y el 22,1 % de los vecinos. Los títulos solos también afectan de forma distinta a cada modelo: sustituyen el 51,7 % de los vecinos de MPNet y el 84,2 % de los de SciBERT (Tabla S5). Por tanto, el parecido entre las medias generales no debe leerse como una equivalencia general entre cambiar el texto y cambiar de modelo.

Para ver si esa comparación media se repite, elijo cincuenta conjuntos equilibrados de 1.000 candidatos por área, la mitad de la cantidad del experimento completo. En estas búsquedas más pequeñas, cambiar de modelo sustituye el 64,93 % de los 25 vecinos y usar solo títulos, el 66,49 %. Los títulos solos sustituyen, por tanto, 1,56 puntos porcentuales más, con un rango

central del 95 % entre selecciones de 1,44–1,69. La diferencia general se mantiene positiva en todas las repeticiones. Su media es de 1,97 puntos con 10 vecinos y 1,04 con 50.

Los resultados de cada modelo son menos uniformes. Las diferencias van de $-14,04$ puntos para MPNet a $+16,59$ para SciBERT. Un valor negativo significa que los títulos solos cambian menos vecinos que cambiar de modelo; uno positivo significa que cambian más. Así, una media general positiva que se repite reúne modelos en los que ambos cambios tienen efectos relativos opuestos (Suplemento S9).

Cambiar la regla que forma el vector del artículo también puede invertir el resultado general. Para los cuatro modelos de palabras —BERT, SciBERT, BioBERT y PubMedBERT— sustituyo la media de las salidas de tokens por la salida CLS o SEP definida antes. Los otros seis mantienen sus reglas habituales. Se vuelven a calcular los dos lados de la comparación: el efecto de cambiar de modelo y el de dar solo títulos. Con 25 vecinos, los títulos solos sustituyen ahora 3,13 puntos porcentuales menos con CLS y 2,00 menos con SEP, en todas las repeticiones. El orden depende, por tanto, de esta decisión de procesamiento. Son comparaciones de formas prácticas de usar los modelos; no aíslan la contribución causal del texto, del diseño del modelo o de un único paso de procesamiento.

La ampliación de los primeros 26.000 artículos a 52.000 también redujo la sensibilidad a la selección en la comparación de estructura. Aplicar la misma comprobación con 100 selecciones repetidas en cada tamaño reduce las alertas de 72 entre 520 contrastes de modelo, área y entrada (13,8 %) a cinco entre 520 (1,0 %). Menos contrastes superan, por tanto, la tolerancia registrada. Esto no demuestra estabilidad para cada comparación de vecinos. El Suplemento S3 conserva por separado la comprobación anterior de veinte selecciones. Las pruebas de fragmento común y de MiniLM con 512 tokens tratan, en cambio, sobre la longitud de entrada; no revelan un error de programación en el límite original de MiniLM.

4.4. Comparar dos áreas puede dar la respuesta contraria con otro modelo

El último análisis pregunta si los modelos respaldan la misma descripción de un área. Reutiliza los 52.000 artículos del experimento de texto y sus vectores de título más resumen. Por ejemplo, ¿apuntan más separadas las flechas que representan los artículos de un área que las de otra? Antes de comparar áreas, compruebo si el valor medido en cada una cambia mucho al elegir otros artículos.

Diez modelos y 26 áreas dan 260 casos que comprobar. La apertura angular no tiene alertas de selección ni en la prueba de medias muestras ni en la de igual tamaño. PR tiene cuatro alertas (1,5 %) con veinte medias muestras de 1.000 artículos por área y ninguna con cinco selecciones adicionales de 2.000. Estas pruebas utilizan tamaños y cantidades de repeticiones distintos. Pasar la segunda no elimina la sensibilidad detectada por la primera.

Que los valores se repitan dentro de un modelo no garantiza el acuerdo entre modelos. Entre las 325 parejas de áreas, el 80,6 % tiene respuestas opuestas persistentes de al menos dos modelos para apertura angular, y el 68,0 % para PR (Figura 4). Por ejemplo, un modelo concreto da al área A mayor apertura angular que a B en todas las selecciones de artículos, mientras otro da mayor apertura a B en todas ellas. No hace falta que los demás modelos discrepen todos entre sí. Mayor se refiere a la propiedad medida, no a una posición más alta en un dibujo ni a mejor investigación.

El acuerdo unánime es menos frecuente: los diez modelos dan de forma persistente el valor mayor a la misma área en el 12,9 % de las parejas para apertura angular y el 16,6 % para PR. El 6,5 % y el 15,4 % restantes no cumplen ni la regla de acuerdo unánime ni la de oposición. Quedan sin resolver con esas reglas.

Muchas inversiones corresponden a diferencias pequeñas entre áreas. Exigir que cada orden persistente supere una diferencia del 5 %, respecto al promedio de los dos valores medidos, reduce la oposición al 29,5 % de las 325 parejas para apertura angular y al 54,5 % para PR. Con una diferencia mínima del 10 %, las proporciones bajan al 5,8 % y al 38,8 %. El primer porcentaje de cada comparación es una exigencia sobre el tamaño de la diferencia; el porcentaje resultante indica cuántas parejas siguen cumpliéndola. Una inversión con una diferencia mínima y otra con una diferencia mayor no deberían interpretarse igual.

Las fórmulas alternativas suelen conservar el desacuerdo, aunque no en todos los casos. Solo cuento una oposición como conservada si al menos una de las parejas de modelos originalmente opuestos mantiene los mismos órdenes entre áreas. Las medidas angulares alternativas conservan con esta regla el 85,9 % de las oposiciones angulares originales (225/262). En las mismas 26 condiciones de artículos, la dimensión por entropía conserva el 94,6 % de las oposiciones originales de PR y D80, el 86,0 %; el 86,0 % se mantiene con ambas alternativas (190/221). Estos denominadores son las parejas originalmente opuestas, no todas las parejas de áreas. Como D80 devuelve números enteros, puede dar empates que no aportan un orden persistente.

Los cuatro modelos de palabras tampoco explican toda la oposición. Conservar solo los seis modelos entrenados para similitud sigue dejando respuestas contrarias en el 71,1 % de las 325 parejas para apertura angular y el 49,2 % para PR (Tablas S14–S15).

Las comparaciones angulares cambian mucho más al mover el punto común de referencia a la posición media de los 52.000 artículos equilibrados (Figura 4). Después de restar esa media y reajustar la longitud de los vectores a uno, la oposición baja del 80,6 % al 46,5 % de las 325 parejas: de 262 a 151. Pero el nuevo total no dice qué desacuerdos originales permanecen. Solo el 48,9 % de las oposiciones originales conserva al menos una de las mismas parejas de modelos opuestos con los mismos órdenes entre áreas (128/262). La Tabla S20 separa estas de las oposiciones nuevas o respaldadas por otras parejas de modelos. Con la regla de diferencia mínima del 5 %, quedan solo 11 parejas opuestas en vez de 96.




Figura 4: Cómo cambia el acuerdo entre modelos al cambiar la representación. Cada barra abarca las 325 parejas de áreas. Azul: los diez modelos dan de forma persistente el valor mayor a la misma área. Naranja: al menos dos modelos concretos mantienen órdenes opuestos. Gris: no se cumple ninguna de las dos reglas. Cada orden debe mantenerse en 26 condiciones: los 2.000 artículos principales por área, veinte medias muestras de 1.000 y cinco selecciones adicionales de 2.000. Las representaciones original y centrada usan los mismos artículos. El centrado lleva el origen a la media de los 52.000 vectores de longitud uno, equilibrados por área y período, de cada modelo; después reajusta los vectores resultantes a longitud uno. El corte del 5 % exige una diferencia mayor que el 5 % del promedio de los dos valores de áreas en todas las condiciones; el corte 0 exige una diferencia distinta de cero. La Tabla S20 recoge los cuatro cortes y si los mismos modelos conservan los mismos órdenes opuestos entre áreas.

PR es menos sensible a esta transformación. Las parejas opuestas bajan de 221 a 211, y el 92,3 % de las oposiciones originales conserva al menos una de las mismas parejas de modelos opuestos y los mismos órdenes entre áreas (204/221). Por tanto, una comparación angular que se repite con otros artículos puede seguir dependiendo mucho del origen desde el que medimos los ángulos.

El intento de identificar grupos separados mediante enlaces entre artículos cercanos llegó a otro límite. Unas conexiones débiles podrían parecer señal de un área dividida en temas de investigación. Sin embargo, las nubes artificiales alargadas y los puntos extremos aislados

producen esa señal sin que haya grupos temáticos. Además, cambia con el tamaño de muestra y con la regla que enlaza vecinos, con alertas de selección en 51 de 260 casos. El Suplemento S6 conserva esta comprobación fallida porque muestra un problema que la repetición, por sí sola, no resuelve: una señal geométrica puede no describir la característica de la investigación que queremos estudiar.

5. Discusión

5.1. Qué conviene comprobar antes de utilizar un mapa

Una puntuación general de acuerdo alta deja abiertas algunas preguntas prácticas. Los modelos pueden compartir la organización amplia de las áreas y, a la vez, llevar al lector hacia artículos distintos o dar comparaciones opuestas entre áreas. Supongamos que un modelo da al área A mayor apertura angular que a B y el resultado se repite con otros artículos. Eso muestra estabilidad ante la selección dentro de ese modelo. Si otro modelo invierte el orden de forma persistente, hacer más selecciones con el primero no resuelve el desacuerdo. La afirmación necesita comprobarse cambiando también de modelo, además de artículos.

Esta preocupación continúa trabajos anteriores sobre la dependencia de los mapas respecto al método (Gläser et al., 2017; Boyack and Klavans, 2020) y complementa las evaluaciones con clasificaciones y relaciones externas (González-Márquez et al., 2024; Constantino et al., 2025). Combinar estructura y vecinos también tiene antecedentes (Caspari et al., 2024).

La interpretación también depende de lo que describe la medida. Unos ángulos mayores indican que los vectores apuntan más separados; una dimensión lineal efectiva mayor indica que su variación está menos concentrada en unas pocas direcciones. Son descripciones de la representación. Llamar a un área más diversa en temas o más interdisciplinar exigiría establecer otra relación entre esas propiedades numéricas y la investigación. Otros trabajos sobre geometría de embeddings advierten del riesgo de atribuir un significado amplio a una medida cómoda (Rudman et al., 2022). La comprobación fallida de fragmentación muestra por qué: incluso una diferencia geométrica que se repite puede sostener una explicación equivocada.

Para quien usa estos mapas para comparar áreas de investigación, la consecuencia práctica es comprobar la comparación que quiere sostener. Una puntuación media de acuerdo describe lo que comparten las representaciones en conjunto. Repetir la selección de artículos permite ver si la respuesta depende de los artículos elegidos. Seguir a los mismos modelos que dan respuestas opuestas añade otra comprobación: si una respuesta estable dentro de cada modelo se conserva al cambiar de representación. Mostrar el tamaño de la diferencia y las decisiones de procesamiento permite precisar qué afirmación respalda la evidencia. Para interpretar una diferencia geométrica como una propiedad de la investigación sigue haciendo falta evidencia externa.

5.2. Qué cambian las comprobaciones adicionales

Las comprobaciones adicionales acotan las explicaciones de los resultados principales. La organización compartida de los centros de áreas no depende de un único conjunto de artículos, de elegir 128 en vez de 256 o 512, ni de incluir un área concreta. El filtro de calidad registrado tampoco elimina la mayor parte del bajo acuerdo entre vecinos: tras excluir registros marcados y duplicados, dos modelos siguen compartiendo unos ocho artículos en una lista de 25. Estas pruebas refuerzan esas observaciones dentro de la colección estudiada, sin establecer que las relaciones compartidas sean correctas.

En el experimento de texto, las selecciones repetidas conservan un resultado medio que oculta comportamientos distintos. Dar solo títulos cambia menos vecinos que cambiar de modelo en unos modelos, y más en otros. Sustituir la media por la primera o la última salida que ha procesado el contexto, en los cuatro modelos de palabras, también invierte el orden general. La consecuencia práctica es indicar tanto qué texto lee el modelo como la regla que convierte sus salidas en un vector por artículo. Afirmar que el texto y el modelo importan por igual iría más allá de estos resultados.

Para la apertura angular, el punto común de referencia es otra decisión relevante. Moverlo a la media del conjunto equilibrado de artículos y reajustar los vectores cambia muchas respuestas sobre qué área tiene mayor dispersión. Repetir la selección de artículos no elimina esa dependencia ni establece que una representación sea la correcta. PR cambia menos, aunque las fórmulas alternativas de dimensión tampoco conservan todas las comparaciones. Por eso, una afirmación sobre dispersión debe identificar la representación, la medida y el tamaño de la diferencia.

Las comprobaciones por disciplina examinan una diferencia concreta: con la regla principal, los modelos coinciden menos sobre las relaciones entre artículos de Medicina que entre artículos de Energía (Suplemento S5). Esto no significa que Medicina sea menos coherente, y tampoco tiene siempre el menor acuerdo de vecinos. La diferencia de estructura persiste al equilibrar la contribución de las especialidades dentro de cada área y al excluir los dos modelos biomédicos, BioBERT y PubMedBERT. Ninguna de las dos explicaciones probadas da cuenta de toda la diferencia. Los modelos con entrenamientos relacionados también producen a veces resultados parecidos, pero esas aparentes familias cambian con la regla que forma los vectores. Con diez modelos que difieren a la vez en los textos de entrenamiento, el diseño interno y la tarea para la que se entrenaron, estas asociaciones no permiten identificar una de esas características como la causa.

La comparación temporal aplica los mismos modelos actuales a artículos de períodos de publicación antiguos y recientes. El acuerdo de estructura aumenta ligeramente en promedio. El acuerdo de vecinos baja 0,87 puntos porcentuales cuando cada grupo ofrece todos sus artículos disponibles, pero sube 0,91 puntos cuando todos ofrecen 2.048 candidatos. Por tanto, la tendencia aparente depende de si permitimos tamaños de búsqueda distintos entre

los grupos antiguos y recientes. Describe el acuerdo entre representaciones actuales de esos artículos; por sí sola, no muestra que la ciencia haya convergido históricamente.

5.3. Qué queda abierto

La colección exige registros etiquetados como ingleses y con resúmenes utilizables. Reforzar los grupos pequeños de área y período ayuda a compararlos, pero cambia las proporciones. Persisten errores de origen, y la limpieza no certifica cada registro. Repetir las selecciones no puede reparar la falta de cobertura ni hacer que estos resultados representen todo el trabajo científico.

Los diez modelos también fijan un límite. Cuatro no se entrenaron específicamente para comparar documentos. La prueba con seis muestra que el desacuerdo no se limita a esos cuatro, pero no hace que este conjunto represente todos los modelos de embeddings. Para decidir qué orden entre áreas o qué relación entre artículos tiene mejor respaldo, necesitamos evidencia externa a estos vectores, como evaluaciones independientes de los trabajos.

Varias ampliaciones y controles también se hicieron después de conocer resultados anteriores. Registrar sus reglas antes de los nuevos cálculos permite seguir las decisiones, pero no las convierte en predicciones formuladas antes de empezar el estudio. Un siguiente paso útil sería contrastar una afirmación concreta extraída del mapa con juicios independientes en un área de investigación. Añadir modelos, por sí solo, no resolvería qué significa su geometría compartida o contradictoria.

6. Conclusión

Cambiar el modelo de embeddings puede conservar la organización general de la ciencia y cambiar qué artículos aparecen cerca y qué área tiene representaciones más dispersas. Dar al modelo solo títulos también puede producir cambios grandes, con efectos que dependen del modelo y de la regla que forma el vector del artículo. Elegir otros artículos comprueba una fuente de dependencia; cambiar de modelo o de punto de referencia comprueba otras. Antes de usar un mapa para sostener una relación concreta, conviene comprobar esa relación con las decisiones que pueden afectarla y mostrar cuánto cambia. El acuerdo entre los modelos probados indica qué comparten sus representaciones. Decidir si esa relación describe bien la investigación sigue necesitando evidencia independiente.

Declaraciones

Contribuciones del autor. Alejandro Treny Ortega concibió el proyecto y dirigió la investigación y la preparación del manuscrito como investigador independiente.

Conflictos de interés. El autor declara que no tiene conflictos de interés.

Financiación. Esta investigación no recibió financiación externa.

Disponibilidad de datos y código. El repositorio del proyecto es <https://github.com/aleetreny/Shape-of-Science-Robustness>. Este borrador se acompaña de las tablas utilizadas en las figuras y de las fuentes editables del manuscrito. El corpus fijo, los vectores y los registros locales completos de ejecución no se han depositado en un archivo público persistente. Publicar el código por sí solo no permite reproducir por completo este análisis. El Suplemento S8 detalla el inventario de acceso y los requisitos pendientes; aquí no se afirma que exista un depósito de datos ni un identificador persistente.

Referencias

- Iz Beltagy, Kyle Lo, and Arman Cohan. SciBERT: A pretrained language model for scientific text. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3615–3620, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1371. URL <https://aclanthology.org/D19-1371/>.
- Kevin W. Boyack and Richard Klavans. A comparison of large-scale science models based on textual, direct citation and hybrid relatedness. *Quantitative Science Studies*, 1(4):1570–1585, 2020. ISSN 2641-3337. doi: 10.1162/qss_a_00085.
- Laura Caspari, Kanishka Ghosh Dastidar, Saber Zerhouni, Jelena Mitrovic, and Michael Granitzer. Beyond benchmarks: Evaluating embedding model similarity for retrieval augmented generation systems. arXiv:2407.08275, 2024. URL <https://arxiv.org/abs/2407.08275>. Preprint.
- Arman Cohan, Sergey Feldman, Iz Beltagy, Doug Downey, and Daniel Weld. SPECTER: Document-level representation learning using citation-informed transformers. In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2270–2282, Online, jul 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.207. URL <https://aclanthology.org/2020.acl-main.207/>.
- Isabel Constantino, Sadamori Kojaku, Santo Fortunato, and Yong-Yeol Ahn. Representing the disciplinary structure of physics: A comparative evaluation of graph and text embedding methods. *Quantitative Science Studies*, 6:263–280, 2025. ISSN 2641-3337. doi: 10.1162/qss_a_00349.

- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Jill Burstein, Christy Doran, and Thamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, jun 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423/>.
- Tianyu Gao, Xingcheng Yao, and Danqi Chen. SimCSE: Simple contrastive learning of sentence embeddings. In Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih, editors, *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6894–6910, Online and Punta Cana, Dominican Republic, nov 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.emnlp-main.552. URL <https://aclanthology.org/2021.emnlp-main.552/>.
- Jochen Gläser, Wolfgang Glänzel, and Andrea Scharnhorst. Same data—different results? towards a comparative approach to the identification of thematic structures in science. *Scientometrics*, 111(2):981–998, 2017. ISSN 0138-9130. doi: 10.1007/s11192-017-2296-z.
- Rita González-Márquez, Luca Schmidt, Benjamin M. Schmidt, Philipp Berens, and Dmitry Kobak. The landscape of biomedical research. *Patterns*, 5(6):100968, 2024. ISSN 2666-3899. doi: 10.1016/j.patter.2024.100968.
- Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23, 2022. ISSN 2691-1957. doi: 10.1145/3458754.
- Matthias Held and Theresa Velden. How to interpret algorithmically constructed topical structures of scientific fields? a case study of citation-based mappings of the research specialty of invasion biology. *Quantitative Science Studies*, 3(3):651–671, 2022. ISSN 2641-3337. doi: 10.1162/qss_a_00194.
- Nathaniel Imel and Zachary Hafén. Density, asymmetry and citation dynamics in scientific literature. arXiv:2506.23366, 2025. URL <https://arxiv.org/abs/2506.23366>. Preprint.
- Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529. PMLR, 09–15 Jun 2019. URL <https://proceedings.mlr.press/v97/kornblith19a.html>.
- Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240, 2020. ISSN 1367-4803. doi: 10.1093/bioinformatics/btz682.
- Alex Murphy, Joel Zylberberg, and Alona Fyshe. Correcting biased centered kernel alignment measures in biological and artificial neural networks. arXiv:2405.01012, 2024. URL <https://arxiv.org/abs/2405.01012>. Preprint.
- OpenAlex. Topics. OpenAlex Help Center, 2026. URL <https://help.openalex.org/data/topics/>. Accessed 18 September 2026.

- Malte Ostendorff, Nils Rethmeier, Isabelle Augenstein, Bela Gipp, and Georg Rehm. Neighborhood contrastive learning for scientific document representations with citation embeddings. In Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11670–11688, Abu Dhabi, United Arab Emirates, dec 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.802. URL <https://aclanthology.org/2022.emnlp-main.802/>.
- Jason Priem, Heather Piwowar, and Richard Orr. OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts, 2022. URL <https://arxiv.org/abs/2205.01833v2>. Preprint, version 2.
- Prashant C. Raju. Geometric stability: The missing axis of representations. arXiv:2601.09173, 2026. URL <https://arxiv.org/abs/2601.09173>. Preprint.
- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL <https://aclanthology.org/D19-1410/>.
- William Rudman, Nate Gillman, Taylor Rayne, and Carsten Eickhoff. IsoScore: Measuring the uniformity of embedding space utilization. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3325–3339, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.262. URL <https://aclanthology.org/2022.findings-acl.262/>.
- Amanpreet Singh, Mike D’Arcy, Arman Cohan, Doug Downey, and Sergey Feldman. SciRe-pEval: A multi-format benchmark for scientific document representations. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5548–5566, Singapore, dec 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.338. URL <https://aclanthology.org/2023.emnlp-main.338/>.
- Shruti Singh and Mayank Singh. The inefficiency of language models in scholarly retrieval: An experimental walk-through. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3153–3173, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.249. URL <https://aclanthology.org/2022.findings-acl.249/>.
- Alex H Williams. Equivalence between representational similarity analysis, centered kernel alignment, and canonical correlations analysis. In Marco Fumero, Clementine Domine, Zorah Löhner, Donato Crisostomi, Luca Moschella, and Kimberly Stachenfeld, editors, *Proceedings of UniReps: the Second Edition of the Workshop on Unifying Representations in Neural Models*, volume 285 of *Proceedings of Machine Learning Research*, pages 10–23. PMLR, 14 Dec 2024. URL <https://proceedings.mlr.press/v285/williams24a.html>.
- Alex H Williams, Erin Kunz, Simon Kornblith, and Scott Linderman. Generalized shape metrics on neural representations. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, volume 34, pages 4738–4750. Curran Associates, Inc., 2021. URL https://proceedings.neurips.cc/paper_files/paper/2021/file/252a3dbaeb32e7690242ad3b556e626b-Paper.pdf.