

¿Cuánto depende el mapa de la ciencia del modelo de embeddings?

Alejandro Treny Ortega

Investigador independiente

Opción 1: Directa y sobria • 19 de septiembre de 2026

Resumen

Un mapa de la ciencia resulta útil si podemos interpretar sus conclusiones con cierta confianza en cómo se ha construido. Aquí, diez modelos de embeddings representan el mismo corpus fijo de 500.000 registros de OpenAlex, de 26 áreas y del período 2000–2024. Las muestras emparejadas comparan centros de áreas, estructura interna y vecinos próximos; después varían el texto de entrada y las reglas de representación. Los modelos comparten una estructura general, pero conservan de media solo el 30,3 % de los 25 vecinos más próximos dentro de los grupos de área y período. Quitar el resumen cambia los vecinos casi tanto como cambiar de modelo; quitar el título cambia menos. Una comparación exploratoria de las 325 parejas de áreas encuentra órdenes opuestos persistentes entre modelos en 262 parejas para la apertura angular y 221 para la dimensión lineal efectiva. Al exigir diferencias relativas superiores al 5 %, quedan 96 y 177. Las medidas alternativas conservan muchas oposiciones, mientras que el centrado y la combinación de las salidas afectan a su persistencia. Son resultados geométricos, sin una prueba externa de corrección temática. Una comparación puede resistir la selección repetida de artículos e invertirse al cambiar de modelo. La evaluación de robustez debería seguir la conclusión concreta que se extrae del mapa, junto con su acuerdo general con otros mapas.

Palabras clave: mapas de la ciencia; embeddings de documentos; robustez; acuerdo entre vecinos; comparaciones geométricas.

1. Introducción

Un mapa de la ciencia ayuda a decidir qué artículos agrupar y cómo comparar áreas de investigación. Con embeddings de texto, esa organización empieza cuando un modelo transforma cada artículo en un vector. Las distancias entre vectores proporcionan después las relaciones sobre las que se construye el mapa. Este enfoque se ha utilizado para representar literatura biomédica e investigar la estructura disciplinar de la física (González-Márquez et al., 2024; Constantino et al., 2025). Su utilidad deja una pregunta práctica: si otro modelo representase los mismos artículos, ¿qué conclusiones seguirían en pie?

La cartografía de la ciencia ya se ha enfrentado a este problema. Gläser et al. (2017) preguntaron hasta qué punto una estructura temática reconstruida refleja el conocimiento científico o el método utilizado para recuperarla. Boyack and Klavans (2020) compararon relaciones de texto, citas y una combinación de ambas, y encontraron cambios sustanciales en los artículos que integraban cada grupo pese a obtener medidas globales de precisión parecidas. Una puntuación general cercana puede, por tanto, ocultar una diferencia relevante para el lector: los métodos pueden estar agrupando artículos distintos.

Esta comparación mantiene fijos los artículos y sigue las consecuencias de cambiar su representación. El corpus contiene 500.000 publicaciones etiquetadas como inglesas en OpenAlex, publicadas entre 2000 y 2024 y asignadas a 26 áreas amplias, los Fields. Diez modelos de embeddings representan esos artículos. El análisis pasa de las relaciones entre los centros de las áreas a la estructura de cada área y los vecinos de cada artículo. Las muestras emparejadas varían el texto de entrada y la regla que reduce la salida del modelo a un vector por artículo. Una ampliación geométrica posterior comprueba si la comparación entre dos áreas mantiene su dirección al cambiar el modelo y la selección de artículos.

Los modelos comparten relaciones generales, pero difieren en los vecinos y en las comparaciones entre áreas. Un orden geométrico puede repetirse al seleccionar otros artículos dentro de un modelo y repetirse al revés en otro. Su magnitud y su sensibilidad al procesamiento determinan cómo interpretar ese desacuerdo. Esto limita lo que puede demostrar la selección repetida por sí sola. El acuerdo entre representaciones identifica estructura compartida; para valorar si esa estructura recoge el contenido de la investigación hace falta más evidencia.

2. Antecedentes y preguntas de investigación

2.1. Decisiones de representación en los mapas de la ciencia

Varios estudios ya muestran por qué una representación de documentos necesita un propósito explícito. Constantino et al. (2025) evaluaron representaciones de texto y de grafos frente a una clasificación jerárquica de artículos de física, incluidas representaciones de títulos y resúmenes. En biomedicina, González-Márquez et al. (2024) compararon modelos y reglas de reducción de sus salidas antes de elegir una representación para un mapa amplio de literatura. Su criterio era la frecuencia con la que los artículos próximos compartían etiquetas de área. En ambos casos, interpretar el rendimiento exige atender al criterio con el que se evalúa.

Nombrar el modelo deja varias decisiones sin especificar. Un título y un resumen aportan información distinta; los modelos también admiten cantidades diferentes de texto. Algunos exigen decidir cómo combinar las representaciones de los tokens en un vector por documento. Esta operación, llamada pooling, puede promediar las salidas o tomar una posición concreta. Singh and Singh (2022) mostraron que el comportamiento de búsqueda de los modelos de lenguaje científico puede cambiar con consultas cortas y modificaciones de la redacción. Una

comparación de mapas de la ciencia debería hacer visibles esas decisiones sobre la entrada y la representación.

La geometría y los vecinos recuperados también se han comparado de forma conjunta. Caspari et al. (2024) utilizaron ambas en conjuntos de datos de búsqueda, mientras que Imel and Hafen (2025) examinaron la densidad y la asimetría locales de varios embeddings y disciplinas en relación con las tasas de citación. Aquí se pregunta hasta qué punto las conclusiones generales, locales y geométricas se mantienen en un conjunto fijo de modelos. Emparejar artículos, condiciones de texto, reglas de representación y candidatos permite precisar qué cambio aborda cada comparación.

2.2. Acuerdo, estabilidad e interpretación

El acuerdo describe lo que comparten dos modelos al representar los mismos artículos. La estabilidad pregunta si un resultado concreto resiste un cambio concreto, como seleccionar otros artículos del corpus. Ambas cosas pueden separarse: un orden de áreas puede ser estable dentro de cada modelo y distinto entre modelos. La validez temática añade la pregunta de si las relaciones representadas describen adecuadamente la investigación. En biología de las invasiones, Held and Velden (2022) mostraron por qué interpretar grupos obtenidos por algoritmos exige atender a las distintas relaciones que combina el método. La repetición y el consenso no resuelven por sí solos esa interpretación.

Aquí, *forma* se refiere a las relaciones en los espacios originales de embeddings, antes de proyectarlos en dos dimensiones. Los centros de las áreas describen la organización general. Las comparaciones dentro de cada área mantienen la estructura entre artículos, y el acuerdo de vecinos identifica si los mismos artículos siguen siendo los más próximos a uno dado. La apertura angular y la dimensión lineal efectiva describen otras propiedades geométricas: cuánto se abren los vectores y cómo se reparte su variación entre direcciones. Sus nombres deben mantenerse cerca de esas operaciones. Una mayor apertura no demuestra una mayor diversidad temática, y la dimensión lineal efectiva no cuenta temas. Un cambio en una propiedad tampoco implica necesariamente que cambien todas las demás partes del mapa.

2.3. Preguntas de investigación y alcance

Tres preguntas organizan el análisis:

- PI1.** ¿Qué relaciones estructurales comparten los modelos de embeddings y cómo varía el acuerdo entre los centros de las áreas, los artículos dentro de cada área y los vecinos locales?
- PI2.** ¿Cuánto cambian la geometría y los vecinos al modificar el texto de entrada o la regla de combinación de las salidas, en comparación con cambiar el modelo?

PI3. ¿Qué comparaciones geométricas entre áreas se mantienen, se invierten o quedan sin resolver al cambiar de modelo y de selección de artículos, y qué tamaño tienen las diferencias?

Las preguntas describen el corpus y el conjunto de modelos seleccionados. La tercera surgió después de las comparaciones iniciales, en una ampliación exploratoria cuya secuencia queda registrada en los métodos y el suplemento. Las etiquetas de OpenAlex organizan los análisis y conservan sus errores conocidos. No proporcionan una prueba independiente de corrección temática. El objetivo es establecer qué conclusiones se mantienen dentro de este diseño; recuperar un único mapa correcto o clasificar los modelos frente a él exigiría otro tipo de evidencia.

3. Datos y diseño de la comparación

3.1. Corpus y muestras de análisis

El corpus contiene 500.000 identificadores distintos de trabajos de OpenAlex, recogidos y limpiados hasta el 15 de septiembre de 2026. OpenAlex proporciona los metadatos y los textos (Priem et al., 2022). La consulta a su catálogo principal se limitó a artículos, revisiones y trabajos de congresos publicados entre 2000 y 2024, etiquetados como ingleses, con título no vacío, un resumen reconstruible de al menos 50 palabras y un área principal conocida. Se excluyeron las marcas de retractación y paratexto. Se eliminaron los fallos claros de idioma y contenido; los casos inciertos y las posibles versiones duplicadas se conservaron con marcas. La clasificación por tema principal de cada registro quedó fijada al extraerlo. Estas etiquetas automáticas utilizan texto, citas e información de la revista (OpenAlex, 2026); sirven para organizar el análisis, no como criterio independiente de corrección.

La muestra general de 400.000 registros válidos se obtuvo mediante consultas aleatorias a la API con semillas registradas. Otros 100.000 registros reforzaron los grupos más pequeños de área y período, asignando repetidamente nuevas plazas al grupo menos poblado. Los grupos grandes no se redujeron al tamaño del menor. Los 130 grupos resultantes cubren 26 áreas y cinco períodos: 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Todos contienen al menos 2.165 registros. Las comparaciones globales utilizan la muestra general; las comparaciones entre grupos pueden usar ambas partes. Las medias que dan el mismo peso a cada grupo describen una comparación equilibrada, no las proporciones de la investigación mundial.

Las muestras de la Tabla 1 separan comparaciones distintas. Para las tres entradas de texto, 52.000 artículos se reparten por igual entre grupos de área y período e incluyen el piloto anterior de 26.000. Otra muestra de 52.000 artículos compara la entrada habitual de cada modelo con un mismo fragmento literal, elegido para caber en todos los tokenizadores. Las comparaciones de grupos del mismo tamaño y las búsquedas de vecinos emparejadas abordan

otras fuentes de variación. Todas las comparaciones mantienen la identidad de los artículos entre modelos. El Suplemento S1 recoge las reglas de extracción, los pasos de limpieza, los recuentos y las marcas conservadas.

Tabla 1: Corpus y muestras de análisis.

Muestra	Artículos y representación	Comparación y alcance
Corpus original	500.000 identificadores: 400.000 base + 100.000 de refuerzo. Diez modelos; título y resumen.	26 áreas, cinco períodos. Los resúmenes globales usan la base; el corpus completo no es proporcional a la población.
Tres entradas de texto	52.000 identificadores; 400 por área y período, 2.000 por área. Título, resumen y ambos.	Mismos artículos y candidatos entre modelos. Incluye el piloto de 26.000 artículos.
Fragmento común	Otra muestra distinta de 52.000 identificadores; 400 por área y período.	Contenido habitual y común emparejado; tokenización propia de cada modelo. Distinta de la muestra de tres entradas.
Grupos de igual tamaño	256 artículos por centro; 26 áreas, 217 especialidades o 26 centros de especialidades.	Dentro de grupos: 26 áreas y las mismas 183 especialidades con 128, 256 y 512 artículos. Objetos distintos de los centros.
Búsquedas emparejadas	217 especialidades; 50 consultas fijas por cada una (10.850 en total). Diez selecciones de candidatos.	256 candidatos en cada ámbito, incluidas las 50 consultas. El conjunto del área está condicionado por esas consultas.
Geometría / parejas de áreas	2.000 por área; veinte mitades de 1.000 y cinco selecciones de 2.000.	325 parejas y dos propiedades; 26 condiciones guardadas. Las medidas alternativas tienen distinta cobertura.

Las filas se solapan y no deben sumarse. Períodos: 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Cada comparación usa los mismos identificadores entre modelos. En la búsqueda, cada artículo de consulta se excluye a sí mismo. Los 1.300 artículos de prueba técnica no forman otra muestra científica. Filtros y cuotas completos: Tabla S1.

3.2. Modelos y representaciones del texto

Los diez modelos cubren representaciones de documentos científicos, de frases generales y de palabras en textos biomédicos o científicos (Tabla 2). Es un conjunto fijo elegido por su relevancia para representar publicaciones y por sus distintos enfoques de entrenamiento; no es una muestra aleatoria de modelos ni una clasificación de los sistemas más recientes. Las versiones de los modelos, de los tokenizadores y de los formatos de texto se fijaron antes del cálculo. Cada modelo representó el mismo título y resumen con su formato habitual y su límite propio de entrada. Se conservó como principal el límite de 256 tokens de MiniLM y se preparó una variante separada de 512 para comprobar su efecto. El recorte habitual afectó al 49,58 % de las entradas de MiniLM y al 20,16 % de las de MPNet.

En BERT, SciBERT, BioBERT y PubMedBERT, el vector principal del documento es la media de los estados de los tokens de la última capa que no son relleno, incluidos los símbolos especiales. Estos modelos no se entrenaron específicamente para medir similitud entre documentos. Como alternativas se usaron el estado de la primera posición (CLS, antes del *pooler*) y el de la última posición sin relleno (SEP). La media se fijó antes de las comparaciones principales y se mantuvo tras los primeros controles; no se eligió para maximizar el acuerdo. Los otros seis modelos usan sus reglas documentadas de representación. Las entradas de solo título y solo resumen utilizan los mismos 52.000 identificadores que la comparación con ambos textos. Al mantener los límites propios de cada modelo, se comparan formas prácticas de utilizarlos, sin aislar la arquitectura de la longitud del texto.

Tabla 2: Modelos de embeddings y reglas principales de representación.

Modelo	Dim.	Tokens	Representación	Referencia
SPECTER	768	512	CLS	(Cohan et al., 2020)
SPECTER2	768	512	CLS + adaptador	(Singh et al., 2023)
SciNCL	768	512	CLS	(Ostendorff et al., 2022)
SciBERT	768	512	Media	(Beltagy et al., 2019)
BERT	768	512	Media	(Devlin et al., 2019)
MPNet	768	384	Media	(Reimers and Gurevych, 2019)
MiniLM	384	256	Media	(Reimers and Gurevych, 2019)
PubMedBERT / BiomedBERT	768	512	Media	(Gu et al., 2022)
BioBERT	768	512	Media	(Lee et al., 2020)
SimCSE	768	512	CLS, antes del pooler	(Gao et al., 2021)

MPNet y MiniLM utilizan all-mpnet-base-v2 y all-MiniLM-L6-v2, respectivamente. Los límites cuentan tokens, incluidos los símbolos especiales. Media: promedio de posiciones sin relleno de la

última capa, con símbolos especiales. CLS: primera posición antes del pooler; SPECTER2 añade su adaptador de proximidad. En MPNet/MiniLM, la referencia describe el marco Sentence-BERT, no el entrenamiento exacto de esas versiones. Las reglas alternativas no son modelos adicionales. Versiones, formatos y recorte: Tabla S2.

3.3. Objetos y medidas

Todas las medidas utilizan las dimensiones originales de los embeddings, sin proyectarlos en dos dimensiones. Primero se ajusta cada vector de artículo para que tenga longitud uno. El acuerdo de forma se mide principalmente mediante la alineación lineal centrada de kernels corregida, o CKA, que compara las relaciones entre los mismos artículos (Kornblith et al., 2019; Murphy et al., 2024). Un valor mayor indica más acuerdo. La corrección por tamaño de muestra reduce una fuente conocida de aumento artificial del acuerdo; no convierte el cociente completo en un estimador exactamente insesgado. La alineación de Procrustes y las correlaciones entre los rangos de las distancias aportan comprobaciones con sensibilidades distintas. Sus definiciones y la fórmula de corrección aparecen en el Suplemento S2. Son medidas relacionadas, no votos independientes sobre la validez (Williams et al., 2021; Williams, 2024).

El centro de un grupo promedia sus vectores de artículos de longitud uno. Comparar centros describe así la organización de los grupos, mientras que comparar los artículos que los componen mantiene la variación interna. El control de grupos aleatorios pregunta cuánto acuerdo entre centros puede surgir del promedio sin utilizar las etiquetas observadas. Mantiene el tamaño de los grupos y los períodos de publicación, y usa la misma asignación aleatoria en todos los modelos.

El acuerdo de vecinos es la fracción de los k artículos más próximos que comparten dos modelos. La elección principal es $k = 25$, con 10 y 50 como controles. Las búsquedas usan similitud del coseno y excluyen el propio artículo consultado. En cada resultado se indica qué candidatos pueden aparecer: todos los artículos de un grupo de área y período, una selección de tamaño igualado, un conjunto emparejado de área y especialidad (*Subfield*) o el corpus general. El cálculo exacto por bloques evita almacenar todas las distancias por parejas. Comprobaciones independientes mediante ordenación completa verifican las listas de vecinos guardadas. Ni la coincidencia ni su ajuste simple por azar eliminan todos los efectos de la composición o el tamaño del conjunto de candidatos.

Otras dos propiedades describen geométricamente cada área. La *apertura angular* es la mediana del ángulo entre vectores de artículos distintos. La *dimensión lineal efectiva* es el cociente de participación de la matriz de covarianza centrada C , $PR = (\text{tr } C)^2 / \text{tr}(C^2)$. Es mayor cuando la variación se reparte entre más direcciones. Como alternativas se utilizan cuantiles angulares, ángulos respecto al centro, el rango efectivo basado en entropía y el número de direcciones que contienen el 80 % de la varianza. Las dos últimas proceden del

mismo espectro de covarianza que PR; no aportan una validación temática independiente. También se probaron medidas de conexión de grafos, pero sus contraejemplos con nubes sintéticas impidieron interpretarlas como fragmentación general (Suplemento S6).

3.4. Comparaciones emparejadas y estabilidad

La comparación estricta de vecinos entre área y especialidad fija 50 artículos de consulta en cada una de 217 especialidades. Ambas búsquedas contienen 256 candidatos, incluidas esas mismas 50 consultas, y las mismas cantidades por período. Diez selecciones cambian los 206 candidatos restantes dentro de la especialidad o de su área principal. Por tanto, la búsqueda más amplia está condicionada por las consultas; no es una selección libre de 256 artículos del área. El diseño cubre 10.850 consultas y mantiene constantes las oportunidades de búsqueda mientras cambia su ámbito.

Para las comparaciones geométricas se evalúan todas las parejas no ordenadas de las 26 áreas: 325 por propiedad. Un modelo tiene una dirección persistente solo si esta se mantiene en los 2.000 artículos por área de la selección principal, en veinte medias muestras de 1.000 y en cinco selecciones adicionales de 2.000 del mismo corpus. El acuerdo de los diez requiere la misma dirección persistente en todos los modelos. La oposición exige al menos dos modelos concretos con direcciones opuestas persistentes. Las demás parejas quedan sin resolver, lo que no significa igualdad. La magnitud relativa es $2(B - A)/(A + B)$, donde A y B son los valores de las dos áreas; los mínimos de 0, 1, 5 y 10 % comprueban la sensibilidad a diferencias pequeñas.

Las selecciones repetidas comprueban la sensibilidad dentro del corpus fijo. Como los subconjuntos se solapan, sus rangos no pueden leerse como intervalos de confianza de muestras poblacionales independientes. Los controles operativos señalan desplazamientos excesivos de la mediana o rangos de selección demasiado amplios; el suplemento conserva por separado cada regla y denominador. Las parejas de modelos comparten modelos y las parejas de áreas comparten áreas. Sus recuentos son, por tanto, descriptivos, y ninguna prueba de significación los trata como observaciones independientes.

3.5. Secuencia de las comprobaciones

El trabajo avanzó mediante comparaciones sucesivas. Primero se estudiaron forma y vecinos; después se ampliaron las entradas, las búsquedas emparejadas de especialidades y el atlas de casos. La ampliación morfológica fue exploratoria; su resumen de todas las parejas se hizo tras inspeccionar los primeros ejemplos. Las reglas se registraron localmente antes de cada nuevo cálculo correspondiente, sin realizar un prerregistro externo de todo el estudio. Los centros de grupos aleatorios y la comprobación con una fracción fija de vecinos fueron controles añadidos después de resultados anteriores. El Suplemento S2 recoge esta secuencia. Los Suplementos

S3–S7 conservan las comprobaciones de tiempo, composición disciplinar, características de los modelos, errores de la fuente y procesamiento, incluidas las que restringen la interpretación.

4. Resultados

4.1. Estructura general compartida y variación dentro de las áreas

Los modelos coinciden mucho en la disposición de los centros de los grupos. Con 256 artículos por centro, la CKA corregida media es de 0,939 para las 26 áreas y de 0,911 para 217 especialidades (Figura 1A). Al restringir la segunda comparación a 26 centros de especialidades, el valor es 0,902. Los grupos aleatorios con tamaños y fechas iguales también presentan acuerdo positivo, alrededor de 0,63–0,64, pero no alcanzan el nivel observado. El promedio contribuye, por tanto, al acuerdo, aunque no basta para explicar el asociado a los grupos definidos por estas etiquetas.

Dentro de los grupos, el acuerdo se sitúa en otro nivel. La CKA media ronda 0,63 en las áreas y 0,64 en las mismas 183 especialidades disponibles en cada tamaño (Figura 1B). Aumentar el número de artículos de 128 a 512 cambia poco esas medias. Por tanto, unas etiquetas más detalladas no implican menor acuerdo en esta comparación. Los paneles de centros y de estructura interna describen objetos distintos, de modo que su diferencia no permite aislar un efecto causal de la escala.

Las medidas alternativas respaldan en términos generales el orden del acuerdo entre parejas de modelos. En los 130 grupos originales de área y período, la correlación media de rangos con la CKA corregida es 0,891 para Procrustes y 0,881 para los rangos de distancias. El acuerdo no es completo, y el control original de selección conserva 50 alertas entre 5.850 comparaciones de pareja de modelos y grupo (Tabla S4). Estas limitaciones afectan a comparaciones concretas; una media global no las elimina.

4.2. Acuerdo de vecinos en comparaciones emparejadas

En las búsquedas completas dentro de los grupos de área y período, dos modelos conservan de media el 30,3 % de los 25 vecinos más próximos: unos 7,6 artículos de 25. Esta media da el mismo peso a cada grupo y pareja de modelos. Restringir cada grupo a 2.048 candidatos comunes aumenta la coincidencia al 31,9 %. En la búsqueda separada sobre el corpus general de 400.000 artículos, 13.000 consultas equilibradas conservan el 17,5 %. Este último resultado cambia tanto el ámbito como el número de candidatos, por lo que no demuestra por sí solo que haya menos acuerdo al cruzar fronteras disciplinares.

El experimento emparejado de área y especialidad aborda directamente esa ambigüedad (Figura 2). Con las mismas consultas, fechas y 256 candidatos, el acuerdo es menor en la




Figura 1: Acuerdo entre los centros de los grupos y dentro de los grupos. (A) CKA corregida media de las parejas fijas de modelos y las comparaciones de centros guardadas; cada centro contiene 256 artículos. Los grupos aleatorios conservan tamaños y fechas. La condición de 26 especialidades controla el número de centros. (B) Acuerdo interno con tres cantidades de artículos, para 26 áreas y las mismas 183 especialidades válidas. Los puntos y las etiquetas muestran medias; las líneas abarcan los percentiles 2,5–97,5 entre comparaciones de grupo y pareja de modelos (1.170 para áreas; 8.235 para especialidades). Son rangos descriptivos, no intervalos de confianza; las parejas de modelos no son independientes. Todos los ejes de CKA van de 0 a 1. Los paneles comparan objetos distintos, por lo que su diferencia no es un efecto causal estimado.

especialidad en 127 de 217 casos y mayor en 90. La diferencia media es pequeña: $-1,35$ puntos porcentuales. Con 50 vecinos, el reparto pasa a 109 casos con menos acuerdo y 108 con más. Una búsqueda más estrecha puede conservar más vecinos o menos, según el grupo y el número de vecinos elegido. No hay una pérdida universal de acuerdo al pasar de área a especialidad.

El acuerdo de forma y el de vecinos describen cambios relacionados. Su correlación descriptiva de rangos entre las 45 medias por pareja de modelos originales es 0,920. Aun así, hay una razón práctica para informar de ambos: la CKA resume relaciones distribuidas, mientras que una lista de vecinos identifica los artículos que encontraría el lector. Las dos medidas muestran consecuencias distintas de la elección de representación, sin ser dimensiones independientes de fiabilidad.

El atlas permite examinar esas diferencias locales. Sus ejemplos de especialidades se seleccionan mediante una regla registrada de persistencia en 27 combinaciones de tamaño, regla de representación y número de vecinos. Los ejemplos de artículos muestran después relacio-

nes que se mantienen entre modelos y otras cuya inclusión cambia mucho (Suplemento S4). Algunos casos extremos revelan problemas de la fuente: un libro de historia aparece en Física, un registro sobre infección aparece en Ciencia Política y un anuncio sigue en el corpus. La comparación con los registros originales confirma que son problemas de la fuente o de clasificación, no filas de embeddings mal alineadas. Los ejemplos son exploratorios y se han seleccionado deliberadamente; no estiman la frecuencia de esos errores ni la precisión de las relaciones.




Figura 2: Acuerdo de vecinos en búsquedas emparejadas de área y especialidad. Cada punto es una de las 217 especialidades, con el promedio de las parejas de modelos y diez selecciones de candidatos. Ambos ámbitos contienen las mismas 50 consultas fijas entre 256 candidatos y fechas igualadas; se excluye el propio artículo. El conjunto del área está condicionado por estas consultas. Los puntos por encima de la diagonal tienen más coincidencia en la búsqueda estrecha; los situados por debajo tienen menos. La dispersión describe diferencias entre grupos, no intervalos de confianza.

4.3. Texto de entrada y decisiones de representación

Quitar el resumen puede cambiar la representación casi tanto como cambiar el modelo. En los mismos 52.000 artículos, el cambio medio de forma, medido como uno menos la CKA corregida, es 0,370 al cambiar de modelo y 0,366 al mantenerlo pero usar solo el título. Las fracciones de vecinos sustituidos son, respectivamente, 68,8 % y 70,7 % (Figura 3). Que estas medias estén próximas no demuestra equivalencia. Muestra que, dentro de este diseño, una decisión aparentemente simple sobre el texto puede tener una magnitud comparable a la elección del modelo.




Figura 3: Cambios asociados al modelo y al texto de entrada. Los mismos 52.000 identificadores aportan 2.000 candidatos por área. La entrada de referencia es título y resumen: quitar el resumen deja el título, y quitar el título deja el resumen. (A) Uno menos la CKA corregida. (B) Fracción de los 25 vecinos sustituidos. Cada punto es la media de un área sobre el conjunto fijo de modelos. Las cajas muestran la mediana y el rango intercuartílico, con bigotes de 1,5 veces ese rango; se muestran todas las áreas. No son intervalos de confianza. Se mantienen los límites propios de texto.

Quitar solo el título cambia menos. Las entradas de solo resumen tienen un cambio medio de forma de 0,027, pero sustituyen el 22,1 % de los 25 vecinos. Por tanto, un cambio pequeño en la geometría general puede alterar los artículos recuperados localmente. También hay diferencias importantes entre modelos: al usar solo el título, la sustitución de vecinos va del 51,7 % en MPNet al 84,2 % en SciBERT (Tabla S5). Una única media conjunta ocultaría esas diferencias.

La regla de combinación de las salidas puede alterar la comparación con la que se evalúan los cambios de entrada. Con la media como representación principal, quitar el título tiene un efecto relativamente pequeño, y quitar el resumen supera ligeramente al cambio de modelo en la sustitución media de vecinos. Usar CLS o SEP en los cuatro BERT de palabras invierte ese último orden. Cambian cuatro representaciones a la vez, incluida la referencia para la comparación entre modelos. Esto impide una lectura causal aislada de la combinación de las salidas y no justifica elegir la regla que produzca más acuerdo.

La muestra ampliada reduce la sensibilidad a la selección de artículos. Con 100 selecciones comparables en cada tamaño, el control del contraste de forma pasa de 72 alertas entre 520 contrastes de modelo, área y entrada con 26.000 artículos a cinco con 52.000. La comprobación anterior de 20 selecciones da 31 y cuatro, respectivamente (Figura S1). Se conservan ambos registros. Superar este control no significa que el contraste sea distinto de cero ni certifica todos los resultados de vecinos o variantes de representación. Los controles de fragmento común y longitud de MiniLM también distinguen la exposición desigual al texto de un error de programación: el límite original de MiniLM era su ajuste documentado, no un fallo de implementación.

4.4. Persistencia e inversión de las comparaciones geométricas entre áreas

La ampliación geométrica sigue una afirmación concreta sobre el mapa: si un área tiene una propiedad medida mayor que otra. La primera comprobación cambia los artículos y conserva el modelo. La apertura angular no presenta alertas entre los 260 casos de modelo y área, ni en el control de medias muestras ni en el de igual tamaño. La dimensión lineal efectiva tiene cuatro alertas en medias muestras y ninguna en las cinco selecciones de igual tamaño (Tabla S12). Este último resultado no elimina las cuatro alertas conservadas.

La estabilidad dentro de un modelo no asegura acuerdo entre modelos. Entre las 325 parejas de áreas, la apertura angular presenta una dirección común persistente en los diez modelos para 42 parejas, oposición persistente para 262 y un resultado sin resolver para 21. En la dimensión lineal efectiva, los recuentos son 54, 221 y 50 (Figura 4). La oposición significa que al menos dos modelos concretos mantienen direcciones contrarias en las 26 condiciones de selección guardadas. No exige que discrepen todos los modelos, y las parejas sin resolver pueden contener acuerdo parcial.

Muchas diferencias angulares son pequeñas. Exigir que cada dirección opuesta supere una diferencia relativa simétrica del 5 % reduce la oposición angular a 96 parejas; al 10 % quedan 19. La dimensión lineal efectiva conserva 177 y 126 oposiciones en esos umbrales. Por tanto, los totales basados solo en la dirección no deben leerse como desacuerdos del mismo tamaño. El mínimo es una elección explícita para comprobar sensibilidad, no una definición universal

de diferencia científicamente relevante. La Figura 4 conserva las 325 parejas en cada fila para que siga visible el aumento de la categoría sin resolver.




Figura 4: Persistencia, oposición y magnitud de las comparaciones entre áreas. Cada fila contiene las 325 parejas para una propiedad y diez modelos. La dirección de un modelo debe mantenerse en la selección principal, veinte medias muestras y cinco selecciones adicionales de igual tamaño del mismo corpus. El acuerdo de los diez requiere una dirección común persistente; la oposición exige al menos dos modelos fijos con direcciones contrarias persistentes. Las demás parejas quedan sin resolver. La magnitud utiliza $2(B - A)/(A + B)$. Los cuatro mínimos son cortes operativos, no umbrales de significación o precisión. Las 26 condiciones se solapan; los controles puntuales se presentan por separado.

Las medidas alternativas conservan buena parte del patrón. Al exigir que los mismos modelos opuestos mantengan sus direcciones en las alternativas angulares, permanecen 225 de las 262 oposiciones originales. Las alternativas espectrales conservan 196 de 221. Su cobertura es distinta: las alternativas angulares tienen las 26 condiciones de selección, mientras que el rango basado en entropía y el recuento del 80 % de varianza están disponibles para tres. Estas alternativas también comparten buena parte de su construcción matemática. Su acuerdo respalda una descripción geométrica, sin convertirla en una medida de diversidad temática.

El resultado no se limita a los cuatro BERT de palabras. Al restringir el conjunto a SPECTER, SPECTER2, SciNCL, MPNet, MiniLM y SimCSE, siguen apareciendo 231 oposiciones

angulares y 160 de dimensión efectiva con mínimo cero. Un conjunto menor tiene menos oportunidades de contener modelos opuestos, por lo que el cambio en los recuentos no aísla un efecto del objetivo de entrenamiento. Las Tablas S14–S15 incluyen las omisiones de cada modelo y todas las clasificaciones de parejas.

Las decisiones de procesamiento añaden otro límite. Después de restar el centro global y volver a normalizar, la misma pareja original de modelos opuestos y sus direcciones se conservan en 145 de 262 oposiciones angulares y en 218 de 221 oposiciones de dimensión efectiva, dentro del control puntual emparejado. La ordenación angular depende, por tanto, más de esa elección. Cambiar la regla de combinación también puede invertir comparaciones (Tabla S16). Son controles puntuales con referencias emparejadas, no otra serie de confirmaciones con 26 repeticiones. Las conclusiones se refieren a representaciones definidas explícitamente, no a propiedades que deban sobrevivir a cualquier transformación.

Las medidas de conexión no sostuvieron la interpretación propuesta como fragmentación. Bajo algunas reglas, las nubes alargadas y los puntos extremos aislados producían una señal similar, y cambiar el tamaño de muestra o el número de vecinos alteraba sustancialmente el resultado. El control de selecciones de igual tamaño conservó 51 alertas de conexión entre 260 casos. El Suplemento S6 presenta estas medidas junto con las comprobaciones fallidas de su significado. No permiten afirmar que un área contenga más grupos temáticos separados.

5. Discusión

5.1. Del acuerdo entre mapas a la persistencia de una afirmación

La estructura general que comparten los modelos ofrece un punto de partida útil para interpretar el mapa. El acuerdo entre centros supera la referencia de grupos aleatorios, por lo que esa organización común no se reduce a lo que explica dicha referencia. Los resultados por parejas de áreas muestran dónde hay que avanzar en la interpretación. Un modelo puede ordenar repetidamente dos áreas en una dirección y otro ordenarlas al revés, aunque cambien los artículos. La prueba de robustez pertinente se refiere, por tanto, a la relación, el conjunto de vecinos o la comparación de áreas que el análisis pretende interpretar.

Esta pregunta continúa el problema comparativo descrito por Gläser et al. (2017); Boyack and Klavans (2020). Una clasificación externa, como la utilizada por Constantino et al. (2025), comprueba cómo responde una representación a un criterio concreto. Las comparaciones conjuntas de alineación y búsqueda, como en Caspari et al. (2024), establecen qué relaciones comparten los modelos. La aportación aquí conecta esos niveles con la persistencia y la magnitud de comparaciones concretas entre áreas sobre artículos emparejados. Los trabajos anteriores ya examinaron la elección de representación y aportaron las medidas de acuerdo sobre las que se apoya esta comparación.

La apertura angular y la dimensión lineal efectiva siguen siendo útiles cuando se interpretan como las operaciones geométricas que miden. Los ángulos describen separación; PR describe el reparto de la varianza entre direcciones lineales. Leer cualquiera de ellas como interdisciplinariedad o diversidad semántica requiere evidencia sobre el contenido de los artículos. Hace falta el mismo cuidado al interpretar la isotropía de los embeddings (Rudman et al., 2022). Las comprobaciones fallidas de fragmentación concretan el problema: una medida puede distinguir nubes de vectores de forma fiable sin identificar la propiedad sustantiva que su nombre sugiere.

5.2. Implicaciones para comparar mapas de la ciencia

Una forma útil de evaluar la robustez es empezar por la afirmación que se quiere apoyar con el mapa. En búsqueda, eso exige indicar el conjunto de candidatos y el número de vecinos. En una comparación geométrica de áreas, exige indicar la regla de representación, el equilibrio de artículos y la diferencia mínima. El experimento de entrada añade una obligación sencilla de documentación. El nombre del modelo no permite al lector reconstruir qué se representó; a su lado deben aparecer la elección de título o resumen, el límite de tokens y la regla de combinación de las salidas.

Las comparaciones adicionales también limitan las explicaciones del desacuerdo. Medicina tiene menos acuerdo de forma que Energía, pero no es siempre el área con menos acuerdo de vecinos. La diferencia entre Medicina y Energía persiste al equilibrar la composición por especialidades y al excluir BioBERT y PubMedBERT (Suplemento S5). Ninguna comprobación aporta una causa única. Las familias de modelos también se ven distintas según la forma de obtener el vector. En este conjunto, arquitectura, material de entrenamiento y objetivos varían de manera ligada, lo que impide atribuirles por separado una causa.

La comparación temporal muestra por qué importa la oportunidad de encontrar un vecino. El acuerdo medio de forma aumenta ligeramente del primer período al último. El acuerdo medio de vecinos baja 0,87 puntos porcentuales con todos los candidatos, pero sube 0,91 puntos cuando cada grupo dispone de 2.048 candidatos. La dirección cambia con el diseño de búsqueda. Los parámetros actuales de los modelos representan publicaciones de fechas distintas; no reconstruyen el conocimiento disponible en esas fechas. Estas comparaciones no permiten establecer una convergencia histórica de la propia ciencia.

5.3. Límites y siguiente validación

El corpus delimita la interpretación. Contiene registros seleccionados de OpenAlex con resúmenes utilizables y texto predominantemente inglés. La muestra de refuerzo, las muestras equilibradas y las medias con el mismo peso por grupo permiten comparar áreas, sin estimar la distribución mundial de la investigación. El atlas muestra que quedan errores de clasificación y contenido. La limpieza elimina fallos especificados; no puede certificar todas las etiquetas. Las selecciones registradas y las versiones fijas permiten inspeccionar la comparación, mientras que repetir selecciones dentro del corpus mantiene su sesgo de cobertura.

El conjunto de modelos impone un límite parecido. Sus miembros comparten arquitecturas, fuentes de entrenamiento y objetivos, y varios no fueron entrenados para comparar documentos por similitud. Las comprobaciones con seis modelos orientados a similitud y otras reglas de representación abordan problemas concretos, sin hacer que el conjunto represente a todos los modelos. La oposición persistente identifica dependencia de los modelos probados. Sigue abierto qué orden, si alguno, describe mejor el contenido de la investigación.

La ampliación geométrica y el resumen de todas las parejas también se hicieron después de resultados anteriores. Registrar su secuencia y conservar las tablas completas permite inspeccionar las decisiones y mantiene visible su carácter exploratorio. Un siguiente estudio útil seleccionaría una comparación relevante y la contrastaría con relaciones entre artículos evaluadas de forma independiente o con una pregunta propia de una disciplina. Eso aportaría evidencia sobre la interpretación temática, que más cálculos de acuerdo por sí solos no pueden proporcionar.

6. Conclusión

Los modelos comparten una organización general de la literatura y difieren en los vecinos de los artículos y en el orden geométrico de las áreas. La elección del texto puede importar tanto como la del modelo. Una comparación también puede resistir la selección repetida de artículos e invertirse entre modelos. Estos resultados favorecen comprobar la afirmación concreta que se quiere apoyar con un mapa, junto con la similitud general. La apertura angular y la dimensión lineal efectiva permiten hacerlo si se mantienen explícitas sus definiciones, magnitudes y sensibilidades al procesamiento. Describen las representaciones producidas aquí. Hace falta más validación para interpretar esas diferencias geométricas como propiedades del conocimiento científico.

Declaraciones

Contribuciones del autor. Alejandro Treny Ortega concibió el proyecto y dirigió la investigación y la preparación del manuscrito como investigador independiente. La ayuda computacional y editorial se declara a continuación.

Conflictos de interés. El autor declara que no tiene conflictos de interés.

Financiación. Esta investigación no recibió financiación externa.

Disponibilidad de datos y código. El repositorio del proyecto es <https://github.com/aleetreny/Shape-of-Science-Robustness>. Este borrador se acompaña de las tablas utilizadas en las figuras y de las fuentes editables del manuscrito. El corpus fijo, los vectores y los registros locales completos de ejecución no se han depositado en un archivo público persistente. Publicar el código por sí solo no permite reproducir por completo este análisis. El Suplemento S8 detalla el inventario de acceso y los requisitos pendientes; aquí no se afirma que exista un depósito de datos ni un identificador persistente.

Uso de herramientas de inteligencia artificial. OpenAI Codex ayudó con las búsquedas bibliográficas, el desarrollo de software y los análisis, la visualización y la redacción y edición del manuscrito. El autor es responsable del contenido.

Referencias

- Iz Beltagy, Kyle Lo, and Arman Cohan. SciBERT: A pretrained language model for scientific text. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3615–3620, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1371. URL <https://aclanthology.org/D19-1371/>.
- Kevin W. Boyack and Richard Klavans. A comparison of large-scale science models based on textual, direct citation and hybrid relatedness. *Quantitative Science Studies*, 1(4):1570–1585, 2020. ISSN 2641-3337. doi: 10.1162/qss_a_00085.
- Laura Caspari, Kanishka Ghosh Dastidar, Saber Zerhoubi, Jelena Mitrovic, and Michael Granitzer. Beyond benchmarks: Evaluating embedding model similarity for retrieval augmented generation systems. arXiv:2407.08275, 2024. URL <https://arxiv.org/abs/2407.08275>. Preprint.
- Arman Cohan, Sergey Feldman, Iz Beltagy, Doug Downey, and Daniel Weld. SPECTER: Document-level representation learning using citation-informed transformers. In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2270–2282, Online, jul 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.207. URL <https://aclanthology.org/2020.acl-main.207/>.

- Isabel Constantino, Sadamori Kojaku, Santo Fortunato, and Yong-Yeol Ahn. Representing the disciplinary structure of physics: A comparative evaluation of graph and text embedding methods. *Quantitative Science Studies*, 6:263–280, 2025. ISSN 2641-3337. doi: 10.1162/qss_a_00349.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Jill Burstein, Christy Doran, and Thamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, jun 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423/>.
- Tianyu Gao, Xingcheng Yao, and Danqi Chen. SimCSE: Simple contrastive learning of sentence embeddings. In Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih, editors, *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6894–6910, Online and Punta Cana, Dominican Republic, nov 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.emnlp-main.552. URL <https://aclanthology.org/2021.emnlp-main.552/>.
- Jochen Gläser, Wolfgang Glänzel, and Andrea Scharnhorst. Same data—different results? towards a comparative approach to the identification of thematic structures in science. *Scientometrics*, 111(2):981–998, 2017. ISSN 0138-9130. doi: 10.1007/s11192-017-2296-z.
- Rita González-Márquez, Luca Schmidt, Benjamin M. Schmidt, Philipp Berens, and Dmitry Kobak. The landscape of biomedical research. *Patterns*, 5(6):100968, 2024. ISSN 2666-3899. doi: 10.1016/j.patter.2024.100968.
- Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23, 2022. ISSN 2691-1957. doi: 10.1145/3458754.
- Matthias Held and Theresa Velden. How to interpret algorithmically constructed topical structures of scientific fields? a case study of citation-based mappings of the research specialty of invasion biology. *Quantitative Science Studies*, 3(3):651–671, 2022. ISSN 2641-3337. doi: 10.1162/qss_a_00194.
- Nathaniel Imel and Zachary Hafen. Density, asymmetry and citation dynamics in scientific literature. arXiv:2506.23366, 2025. URL <https://arxiv.org/abs/2506.23366>. Preprint.
- Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529. PMLR, 09–15 Jun 2019. URL <https://proceedings.mlr.press/v97/kornblith19a.html>.
- Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240, 2020. ISSN 1367-4803. doi: 10.1093/bioinformatics/btz682.

- Alex Murphy, Joel Zylberberg, and Alona Fyshe. Correcting biased centered kernel alignment measures in biological and artificial neural networks. arXiv:2405.01012, 2024. URL <https://arxiv.org/abs/2405.01012>. Preprint.
- OpenAlex. Topics. OpenAlex Help Center, 2026. URL <https://help.openalex.org/data/topics/>. Accessed 18 September 2026.
- Malte Ostendorff, Nils Rethmeier, Isabelle Augenstein, Bela Gipp, and Georg Rehm. Neighborhood contrastive learning for scientific document representations with citation embeddings. In Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11670–11688, Abu Dhabi, United Arab Emirates, dec 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.802. URL <https://aclanthology.org/2022.emnlp-main.802/>.
- Jason Priem, Heather Piwowar, and Richard Orr. OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts, 2022. URL <https://arxiv.org/abs/2205.01833v2>. Preprint, version 2.
- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL <https://aclanthology.org/D19-1410/>.
- William Rudman, Nate Gillman, Taylor Rayne, and Carsten Eickhoff. IsoScore: Measuring the uniformity of embedding space utilization. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3325–3339, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.262. URL <https://aclanthology.org/2022.findings-acl.262/>.
- Amanpreet Singh, Mike D’Arcy, Arman Cohan, Doug Downey, and Sergey Feldman. SciRepEval: A multi-format benchmark for scientific document representations. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5548–5566, Singapore, dec 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.338. URL <https://aclanthology.org/2023.emnlp-main.338/>.
- Shruti Singh and Mayank Singh. The inefficiency of language models in scholarly retrieval: An experimental walk-through. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3153–3173, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.249. URL <https://aclanthology.org/2022.findings-acl.249/>.
- Alex H Williams. Equivalence between representational similarity analysis, centered kernel alignment, and canonical correlations analysis. In Marco Fumero, Clementine Domine, Zorah Lähner, Donato Crisostomi, Luca Moschella, and Kimberly Stachenfeld, editors, *Proceedings of UniReps: the Second Edition of the Workshop on Unifying Representations in Neural Models*, volume

285 of *Proceedings of Machine Learning Research*, pages 10–23. PMLR, 14 Dec 2024. URL <https://proceedings.mlr.press/v285/williams24a.html>.

Alex H Williams, Erin Kunz, Simon Kornblith, and Scott Linderman. Generalized shape metrics on neural representations. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, volume 34, pages 4738–4750. Curran Associates, Inc., 2021. URL https://proceedings.neurips.cc/paper_files/paper/2021/file/252a3dbaeb32e7690242ad3b556e626b-Paper.pdf.