

¿Cuánto depende el mapa de la ciencia del modelo de embeddings?

Alejandro Treny Ortega

Investigador independiente

Opción 2: Razonamiento propio • 19 de septiembre de 2026

Resumen

Cambiar de modelo de embeddings cambia la representación de los artículos científicos. La pregunta es qué conclusiones cambian con ella. Comparo diez modelos sobre un corpus fijo de 500.000 registros de OpenAlex, de 26 áreas y del período 2000–2024, mediante muestras emparejadas que examinan centros de áreas, estructura interna y vecinos próximos, junto con las decisiones de entrada y representación. Los modelos comparten una estructura general, pero conservan de media solo el 30,3 % de los 25 vecinos más próximos dentro de los grupos de área y período. Quitar el resumen cambia los vecinos casi tanto como cambiar de modelo; quitar el título cambia menos. Un análisis exploratorio posterior de las 325 parejas de áreas encuentra órdenes opuestos persistentes entre modelos en 262 parejas para la apertura angular y 221 para la dimensión lineal efectiva. Al exigir diferencias relativas superiores al 5 %, quedan 96 y 177. Las medidas alternativas conservan muchas oposiciones, con una dependencia adicional del centrado y la combinación de las salidas. Una comparación entre áreas puede, por tanto, resistir la selección repetida de artículos e invertirse entre modelos. Estos resultados describen geometría, sin establecer corrección temática. Defiendo que la robustez debe evaluarse sobre la afirmación que se extrae del mapa: el acuerdo general puede coexistir con desacuerdo en la comparación que interesa.

Palabras clave: mapas de la ciencia; embeddings de documentos; robustez; acuerdo entre vecinos; comparaciones geométricas.

1. Introducción

Una misma colección de artículos puede sostener descripciones distintas de cómo se organiza un área de investigación. Con embeddings de texto, una parte de esa descripción procede del modelo: transforma cada artículo en un vector, y las relaciones entre vectores determinan qué artículos aparecen próximos. Esto permite encontrar trabajos relacionados y comparar áreas, como muestran las aplicaciones a la literatura biomédica y a la física (González-Márquez et al., 2024; Constantino et al., 2025). Examino qué ocurre cuando los artículos siguen siendo

los mismos y cambia ese modelo. La pregunta se refiere a las conclusiones que extraemos de la representación, más allá de que los mapas resultantes se parezcan en términos generales.

La preocupación está bien establecida. Gläser et al. (2017) preguntaron cuánto de una estructura temática inferida pertenece al conocimiento científico y cuánto al método que la reconstruye. En Boyack and Klavans (2020), las relaciones de texto, citas y su combinación produjeron agrupaciones de artículos sustancialmente distintas, incluso con una precisión global parecida. Esa distinción motiva la comparación actual. Dos mapas pueden coincidir en una medida de resumen y aun así orientar al lector hacia artículos distintos o comparaciones distintas entre áreas.

Mantengo fijo un corpus de 500.000 publicaciones: registros etiquetados como ingleses en OpenAlex, publicados entre 2000 y 2024 y asignados a 26 áreas amplias, los Fields. Diez modelos de embeddings representan los mismos artículos. Las comparaciones siguen el mapa desde los centros de las áreas hasta sus relaciones internas y los vecinos de cada artículo. Otras muestras emparejadas varían el texto de entrada y la manera de convertir la salida de un modelo en un vector por documento. Una ampliación geométrica posterior pregunta si cambiar de modelo invierte una comparación entre dos áreas, incluso cuando su dirección persiste al seleccionar otros artículos.

Los resultados muestran por qué importa esa última distinción. Las relaciones generales se comparten, pero los vecinos concretos y los órdenes geométricos entre áreas pueden cambiar. En algunas comparaciones, repetir la selección de artículos sostiene una dirección con un modelo y la contraria con otro. Conservo tanto la magnitud de las diferencias como su dependencia del procesamiento, porque una dirección persistente dice poco, por sí sola, sobre el tamaño del desacuerdo. El análisis identifica qué relaciones resisten los cambios probados. Su validez temática queda para una evaluación distinta.

2. Antecedentes y preguntas de investigación

2.1. Decisiones de representación en los mapas de la ciencia

Las comparaciones anteriores ayudan a precisar qué requeriría esa evaluación. Constantino et al. (2025) evaluaron representaciones de texto y grafos frente a una clasificación jerárquica de artículos de física, incluidas representaciones del título y el resumen. González-Márquez et al. (2024) compararon modelos y formas de reducir sus salidas para un mapa amplio de literatura biomédica, utilizando como criterio las etiquetas de área compartidas por artículos próximos. En cada caso se juzga la representación a través de un uso y una referencia concretos. Aquí pregunto si una conclusión resiste un cambio de representación. Esas evaluaciones externas aclaran qué evidencia adicional haría falta para juzgar su corrección temática.

El nombre de un modelo es solo el principio de su receta de representación. El título y el resumen aportan información distinta, los límites de entrada determinan cuánto texto llega al modelo y puede ser necesario combinar las salidas de los tokens en un vector por documento. Pooling es el nombre de esa última operación: promediar las salidas y seleccionar una posición concreta son decisiones diferentes. Singh and Singh (2022) demostraron sensibilidad a consultas cortas y cambios de redacción en modelos de lenguaje científico. Para el propósito de este trabajo, dejar esas decisiones sin especificar dejaría fuera de la comparación una parte del procedimiento que construye el mapa.

La comparación conjunta de geometría y vecinos también tiene antecedentes directos. Caspari et al. (2024) la realizaron en conjuntos de datos de búsqueda; Imel and Hafen (2025) relacionaron la densidad y la asimetría locales de distintos embeddings y disciplinas con las tasas de citación. Me apoyo en esos enfoques para seguir conclusiones generales, locales y geométricas en un conjunto fijo de modelos. Mantener la identidad de los artículos, explicitar las condiciones de texto y representación y controlar los candidatos permite referir la comparación a cambios definidos, en lugar de a una diferencia sin especificar entre sistemas.

2.2. Acuerdo, estabilidad e interpretación

Utilizo acuerdo y estabilidad para preguntas distintas. El acuerdo pregunta qué comparten dos representaciones de los mismos artículos. La estabilidad pregunta si un resultado persiste cuando cambia una parte concreta de la comparación. Un orden de áreas puede superar esta última comprobación dentro de cada modelo y aun así ser distinto entre modelos. Llamar temáticamente válido a cualquiera de esos resultados exige evidencia sobre cómo sus relaciones corresponden a la investigación. Held and Velden (2022) muestran este problema de interpretación en biología de las invasiones, donde los métodos pueden combinar relaciones distintas entre artículos. Ni un resultado repetido ni un consenso aportan esa interpretación que falta.

También hay que precisar el objeto al que llamamos *forma*. Todas las comparaciones se realizan aquí antes de proyectar los datos en dos dimensiones. Los centros de las áreas describen la organización general; sus artículos describen las relaciones internas; los vecinos identifican qué publicaciones siguen siendo las más próximas a un artículo. La apertura angular y la dimensión lineal efectiva añaden descripciones de la separación de los vectores y del reparto de la variación entre direcciones. Mantengo esos significados geométricos a lo largo del texto. Una mayor apertura no permite establecer por sí sola más diversidad de temas, y una dimensión no puede leerse como un recuento de temas. Cada propiedad responde a una parte de la pregunta sobre el mapa.

2.3. Preguntas de investigación y alcance

Tres preguntas organizan el análisis:

- PI1.** ¿Qué relaciones estructurales comparten los modelos de embeddings y cómo varía el acuerdo entre los centros de las áreas, los artículos dentro de cada área y los vecinos locales?
- PI2.** ¿Cuánto cambian la geometría y los vecinos al modificar el texto de entrada o la regla de combinación de las salidas, en comparación con cambiar el modelo?
- PI3.** ¿Qué comparaciones geométricas entre áreas se mantienen, se invierten o quedan sin resolver al cambiar de modelo y de selección de artículos, y qué tamaño tienen las diferencias?

El alcance es descriptivo y se limita a los artículos y modelos seleccionados. La tercera pregunta se añadió en una ampliación exploratoria posterior a las primeras comparaciones; los métodos y el suplemento conservan esa cronología. Las etiquetas de OpenAlex organizan el trabajo, incluidos sus errores conocidos, sin aportar una referencia independiente de corrección temática. Por tanto, evalúo la persistencia de las conclusiones dentro de este diseño. El estudio carece de un criterio externo con el que designar el modelo que recupera un único mapa correcto de la ciencia.

3. Datos y diseño de la comparación

3.1. Corpus y muestras de análisis

El corpus contiene 500.000 identificadores distintos de trabajos de OpenAlex, recogidos y limpiados hasta el 15 de septiembre de 2026. OpenAlex proporciona los metadatos y los textos (Priem et al., 2022). La consulta a su catálogo principal se limitó a artículos, revisiones y trabajos de congresos publicados entre 2000 y 2024, etiquetados como ingleses, con título no vacío, un resumen reconstruible de al menos 50 palabras y un área principal conocida. Se excluyeron las marcas de retractación y paratexto. Se eliminaron los fallos claros de idioma y contenido; los casos inciertos y las posibles versiones duplicadas se conservaron con marcas. La clasificación por tema principal de cada registro quedó fijada al extraerlo. Estas etiquetas automáticas utilizan texto, citas e información de la revista (OpenAlex, 2026); sirven para organizar el análisis, no como criterio independiente de corrección.

La muestra general de 400.000 registros válidos se obtuvo mediante consultas aleatorias a la API con semillas registradas. Otros 100.000 registros reforzaron los grupos más pequeños de área y período, asignando repetidamente nuevas plazas al grupo menos poblado. Los grupos

grandes no se redujeron al tamaño del menor. Los 130 grupos resultantes cubren 26 áreas y cinco períodos: 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Todos contienen al menos 2.165 registros. Las comparaciones globales utilizan la muestra general; las comparaciones entre grupos pueden usar ambas partes. Las medias que dan el mismo peso a cada grupo describen una comparación equilibrada, no las proporciones de la investigación mundial.

Utilizo muestras separadas para cambios que necesitan controles distintos (Tabla 1). La muestra de tres entradas contiene 52.000 artículos equilibrados por grupo de área y período e incluye el piloto de 26.000. Otra muestra de 52.000 compara las entradas habituales con un mismo fragmento literal que cabe en todos los tokenizadores. Las comparaciones con grupos iguales abordan el tamaño; las búsquedas de vecinos emparejadas controlan la oportunidad de búsqueda. La identidad de los artículos se mantiene entre modelos en todo el análisis. El Suplemento S1 registra extracción, limpieza, recuentos y las marcas de calidad conservadas.

Tabla 1: Corpus y muestras de análisis.

Muestra	Artículos y representación	Comparación y alcance
Corpus original	500.000 identificadores: 400.000 base + 100.000 de refuerzo. Diez modelos; título y resumen.	26 áreas, cinco períodos. Los resúmenes globales usan la base; el corpus completo no es proporcional a la población.
Tres entradas de texto	52.000 identificadores; 400 por área y período, 2.000 por área. Título, resumen y ambos.	Mismos artículos y candidatos entre modelos. Incluye el piloto de 26.000 artículos.
Fragmento común	Otra muestra distinta de 52.000 identificadores; 400 por área y período.	Contenido habitual y común emparejado; tokenización propia de cada modelo. Distinta de la muestra de tres entradas.
Grupos de igual tamaño	256 artículos por centro; 26 áreas, 217 especialidades o 26 centros de especialidades.	Dentro de grupos: 26 áreas y las mismas 183 especialidades con 128, 256 y 512 artículos. Objetos distintos de los centros.
Búsquedas emparejadas	217 especialidades; 50 consultas fijas por cada una (10.850 en total). Diez selecciones de candidatos.	256 candidatos en cada ámbito, incluidas las 50 consultas. El conjunto del área está condicionado por esas consultas.
Geometría / parejas de áreas	2.000 por área; veinte mitades de 1.000 y cinco selecciones de 2.000.	325 parejas y dos propiedades; 26 condiciones guardadas. Las medidas alternativas tienen distinta cobertura.

Las filas se solapan y no deben sumarse. Períodos: 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Cada comparación usa los mismos identificadores entre modelos. En la búsqueda, cada artículo de consulta se excluye a sí mismo. Los 1.300 artículos de prueba técnica no forman otra muestra científica. Filtros y cuotas completos: Tabla S1.

3.2. Modelos y representaciones del texto

Los diez modelos ofrecen representaciones académicas distintas y abarcan documentos científicos, frases generales y modelos de palabras biomédicas o científicas (Tabla 2). Los utilizo como un conjunto fijo de comparación elegido por su relevancia y sus diferencias de entrenamiento. No constituyen una muestra aleatoria de modelos ni una clasificación de los sistemas más nuevos. Las versiones de modelos, tokenizadores y formatos de texto se fijaron antes del cálculo. Cada modelo recibió el mismo título y resumen con su formato habitual y su límite propio de entrada. El límite original de 256 tokens de MiniLM se mantiene como principal, con una variante separada de 512 como sensibilidad. El recorte habitual afectó al 49,58 % de las entradas de MiniLM y al 20,16 % de las de MPNet.

En BERT, SciBERT, BioBERT y PubMedBERT, el vector principal del documento es la media de los estados de los tokens de la última capa que no son relleno, incluidos los símbolos especiales. Estos modelos no se entrenaron específicamente para medir similitud entre documentos. Como alternativas se usaron el estado de la primera posición (CLS, antes del *pooler*) y el de la última posición sin relleno (SEP). La media se fijó antes de las comparaciones principales y se mantuvo tras los primeros controles; no se eligió para maximizar el acuerdo. Los otros seis modelos usan sus reglas documentadas de representación. Las entradas de solo título y solo resumen utilizan los mismos 52.000 identificadores que la comparación con ambos textos. Al mantener los límites propios de cada modelo, se comparan formas prácticas de utilizarlos, sin aislar la arquitectura de la longitud del texto.

Tabla 2: Modelos de embeddings y reglas principales de representación.

Modelo	Dim.	Tokens	Representación	Referencia
SPECTER	768	512	CLS	(Cohan et al., 2020)
SPECTER2	768	512	CLS + adaptador	(Singh et al., 2023)
SciNCL	768	512	CLS	(Ostendorff et al., 2022)
SciBERT	768	512	Media	(Beltagy et al., 2019)
BERT	768	512	Media	(Devlin et al., 2019)
MPNet	768	384	Media	(Reimers and Gurevych, 2019)
MiniLM	384	256	Media	(Reimers and Gurevych, 2019)
PubMedBERT / BiomedBERT	768	512	Media	(Gu et al., 2022)
BioBERT	768	512	Media	(Lee et al., 2020)
SimCSE	768	512	CLS, antes del pooler	(Gao et al., 2021)

MPNet y MiniLM utilizan all-mpnet-base-v2 y all-MiniLM-L6-v2, respectivamente. Los límites cuentan tokens, incluidos los símbolos especiales. Media: promedio de posiciones sin relleno de la última capa, con símbolos especiales. CLS: primera posición antes del pooler; SPECTER2 añade su adaptador de proximidad. En MPNet/MiniLM, la referencia describe el marco Sentence-BERT, no el entrenamiento exacto de esas versiones. Las reglas alternativas no son modelos adicionales. Versiones, formatos y recorte: Tabla S2.

3.3. Objetos y medidas

Todas las medidas utilizan las dimensiones originales de los embeddings, sin proyectarlos en dos dimensiones. Primero se ajusta cada vector de artículo para que tenga longitud uno. El acuerdo de forma se mide principalmente mediante la alineación lineal centrada de kernels corregida, o CKA, que compara las relaciones entre los mismos artículos (Kornblith et al., 2019; Murphy et al., 2024). Un valor mayor indica más acuerdo. La corrección por tamaño de muestra reduce una fuente conocida de aumento artificial del acuerdo; no convierte el cociente completo en un estimador exactamente insesgado. La alineación de Procrustes y las correlaciones entre los rangos de las distancias aportan comprobaciones con sensibilidades distintas. Sus definiciones y la fórmula de corrección aparecen en el Suplemento S2. Son medidas relacionadas, no votos independientes sobre la validez (Williams et al., 2021; Williams, 2024).

El centro es la media de los vectores de artículos de longitud uno de un grupo. Esta operación reduce deliberadamente una colección de artículos a un solo objeto para la comparación general. Las comparaciones internas conservan la variación entre artículos. Para comprobar

cuánto acuerdo puede acompañar al propio promedio, los grupos aleatorios conservan los tamaños y períodos observados, pero prescinden de la asignación observada de etiquetas. La asignación aleatoria se comparte entre modelos.

El acuerdo de vecinos es la fracción de los k artículos más próximos que comparten dos modelos. La elección principal es $k = 25$, con 10 y 50 como controles. Las búsquedas usan similitud del coseno y excluyen el propio artículo consultado. En cada resultado se indica qué candidatos pueden aparecer: todos los artículos de un grupo de área y período, una selección de tamaño igualado, un conjunto emparejado de área y especialidad (*Subfield*) o el corpus general. El cálculo exacto por bloques evita almacenar todas las distancias por parejas. Comprobaciones independientes mediante ordenación completa verifican las listas de vecinos guardadas. Ni la coincidencia ni su ajuste simple por azar eliminan todos los efectos de la composición o el tamaño del conjunto de candidatos.

Otras dos propiedades describen geométricamente cada área. La *apertura angular* es la mediana del ángulo entre vectores de artículos distintos. La *dimensión lineal efectiva* es el cociente de participación de la matriz de covarianza centrada C , $PR = (\text{tr } C)^2 / \text{tr}(C^2)$. Es mayor cuando la variación se reparte entre más direcciones. Como alternativas se utilizan cuantiles angulares, ángulos respecto al centro, el rango efectivo basado en entropía y el número de direcciones que contienen el 80 % de la varianza. Las dos últimas proceden del mismo espectro de covarianza que PR; no aportan una validación temática independiente. También se probaron medidas de conexión de grafos, pero sus contraejemplos con nubes sintéticas impidieron interpretarlas como fragmentación general (Suplemento S6).

3.4. Comparaciones emparejadas y estabilidad

La comparación estricta de vecinos entre área y especialidad fija 50 artículos de consulta en cada una de 217 especialidades. Ambas búsquedas contienen 256 candidatos, incluidas esas mismas 50 consultas, y las mismas cantidades por período. Diez selecciones cambian los 206 candidatos restantes dentro de la especialidad o de su área principal. Por tanto, la búsqueda más amplia está condicionada por las consultas; no es una selección libre de 256 artículos del área. El diseño cubre 10.850 consultas y mantiene constantes las oportunidades de búsqueda mientras cambia su ámbito.

Para la geometría de las áreas comparo todas las parejas no ordenadas de las 26 áreas, lo que da 325 parejas por propiedad. Una dirección es persistente en un modelo solo si se mantiene con los 2.000 artículos por área de la selección principal, veinte medias muestras de 1.000 y cinco selecciones adicionales de 2.000 del mismo corpus. El acuerdo de los diez exige una dirección persistente común en todos los modelos. La oposición exige al menos dos modelos fijos que sostengan de forma persistente direcciones contrarias. Todo lo demás queda sin resolver, una categoría que no implica igualdad. La magnitud relativa es $2(B - A)/(A + B)$,

con A y B como valores de las dos áreas. Los mínimos de 0, 1, 5 y 10 % muestran cómo depende la clasificación de las diferencias pequeñas.

Estas repeticiones comprueban qué ocurre al cambiar artículos dentro del corpus ya recogido. Sus selecciones solapadas no producen muestras poblacionales independientes ni intervalos de confianza. Los controles operativos conservan como alertas los desplazamientos excesivos de la mediana y los rangos amplios de selección, con reglas y denominadores separados en el suplemento. Las comparaciones por parejas también comparten componentes: un modelo pertenece a varias parejas de modelos, y un área a varias parejas de áreas. Presento sus recuentos de forma descriptiva y no utilizo ninguna prueba de significación que trate las parejas como independientes.

3.5. Secuencia de las comprobaciones

Las comparaciones se desarrollaron por etapas, y ese orden importa para interpretarlas. Tras el análisis inicial de forma y vecinos se ampliaron las entradas, las búsquedas emparejadas de especialidades y el atlas de casos. La morfología llegó después como ampliación exploratoria; el resumen de todas las parejas siguió a sus primeros ejemplos. Cada nuevo cálculo tuvo reglas registradas localmente de antemano, pero no se hizo un prerregistro externo del estudio completo. Algunos controles, incluidos los centros de grupos aleatorios y la comparación con una fracción fija de vecinos, se añadieron después de resultados anteriores. El Suplemento S2 mantiene explícita esa secuencia. Los Suplementos S3–S7 contienen las comprobaciones de tiempo, composición, características de los modelos, errores de la fuente y procesamiento, incluidas las que limitan las conclusiones.

4. Resultados

4.1. Estructura general compartida y variación dentro de las áreas

Los modelos coinciden mucho en la disposición de los centros de los grupos. Con 256 artículos por centro, la CKA corregida media es de 0,939 para las 26 áreas y de 0,911 para 217 especialidades (Figura 1A). Al restringir la segunda comparación a 26 centros de especialidades, el valor es 0,902. Los grupos aleatorios con tamaños y fechas iguales también presentan acuerdo positivo, alrededor de 0,63–0,64, pero no alcanzan el nivel observado. El promedio contribuye, por tanto, al acuerdo, aunque no basta para explicar el asociado a los grupos definidos por estas etiquetas.

La comparación interna da un resultado más plano. La CKA media se mantiene cerca de 0,63 en las áreas y 0,64 en las mismas 183 especialidades disponibles en todos los tamaños (Figura 1B). Pasar de 128 a 512 artículos apenas cambia esas medias. Una etiqueta más específica no implica, por tanto, menos acuerdo aquí. La diferencia amplía con el panel de

centros exige una lectura más acotada: los centros de los grupos y los artículos individuales son objetos distintos, por lo que los paneles no permiten estimar un efecto causal de la escala. Las medidas alternativas respaldan en términos generales el orden del acuerdo entre parejas de modelos. En los 130 grupos originales de área y período, la correlación media de rangos con la CKA corregida es 0,891 para Procrustes y 0,881 para los rangos de distancias. El acuerdo no es completo, y el control original de selección conserva 50 alertas entre 5.850 comparaciones de pareja de modelos y grupo (Tabla S4). Estas limitaciones afectan a comparaciones concretas; una media global no las elimina.




Figura 1: Acuerdo entre los centros de los grupos y dentro de los grupos. (A) CKA corregida media de las parejas fijas de modelos y las comparaciones de centros guardadas; cada centro contiene 256 artículos. Los grupos aleatorios conservan tamaños y fechas. La condición de 26 especialidades controla el número de centros. (B) Acuerdo interno con tres cantidades de artículos, para 26 áreas y las mismas 183 especialidades válidas. Los puntos y las etiquetas muestran medias; las líneas abarcan los percentiles 2,5–97,5 entre comparaciones de grupo y pareja de modelos (1.170 para áreas; 8.235 para especialidades). Son rangos descriptivos, no intervalos de confianza; las parejas de modelos no son independientes. Todos los ejes de CKA van de 0 a 1. Los paneles comparan objetos distintos, por lo que su diferencia no es un efecto causal estimado.

4.2. Acuerdo de vecinos en comparaciones emparejadas

En las búsquedas completas dentro de los grupos de área y período, dos modelos conservan de media el 30,3 % de los 25 vecinos más próximos: unos 7,6 artículos de 25. Esta media da el mismo peso a cada grupo y pareja de modelos. Restringir cada grupo a 2.048 candidatos comunes aumenta la coincidencia al 31,9 %. En la búsqueda separada sobre el corpus general de 400.000 artículos, 13.000 consultas equilibradas conservan el 17,5 %. Este último resultado cambia tanto el ámbito como el número de candidatos, por lo que no demuestra por sí solo que haya menos acuerdo al cruzar fronteras disciplinares.

El experimento emparejado de área y especialidad aborda directamente esa ambigüedad (Figura 2). Con las mismas consultas, fechas y 256 candidatos, el acuerdo es menor en la especialidad en 127 de 217 casos y mayor en 90. La diferencia media es pequeña: $-1,35$ puntos porcentuales. Con 50 vecinos, el reparto pasa a 109 casos con menos acuerdo y 108 con más. Una búsqueda más estrecha puede conservar más vecinos o menos, según el grupo y el número de vecinos elegido. No hay una pérdida universal de acuerdo al pasar de área a especialidad.

También sería engañoso tratar forma y vecinos como pruebas sin relación. Entre las 45 medias por pareja de modelos del análisis inicial, su correlación descriptiva de rangos es 0,920. Su uso conjunto tiene otra justificación. La CKA describe relaciones distribuidas por el espacio, mientras que la coincidencia de vecinos indica si un lector encontraría los mismos artículos. Ambas importan para interpretar el mapa, incluso cuando varían juntas.

El atlas permite examinar esas diferencias locales. Sus ejemplos de especialidades se seleccionan mediante una regla registrada de persistencia en 27 combinaciones de tamaño, regla de representación y número de vecinos. Los ejemplos de artículos muestran después relaciones que se mantienen entre modelos y otras cuya inclusión cambia mucho (Suplemento S4). Algunos casos extremos revelan problemas de la fuente: un libro de historia aparece en Física, un registro sobre infección aparece en Ciencia Política y un anuncio sigue en el corpus. La comparación con los registros originales confirma que son problemas de la fuente o de clasificación, no filas de embeddings mal alineadas. Los ejemplos son exploratorios y se han seleccionado deliberadamente; no estiman la frecuencia de esos errores ni la precisión de las relaciones.

4.3. Texto de entrada y decisiones de representación

Una decisión sobre la entrada puede importar tanto como la elección del modelo. Para los mismos 52.000 artículos, cambiar de modelo da un cambio medio de forma de 0,370, medido como uno menos la CKA corregida. Mantener el modelo y dejar solo el título da 0,366. Las fracciones correspondientes de vecinos sustituidos son 68,8 % y 70,7 % (Figura 3). Interpreto




Figura 2: Acuerdo de vecinos en búsquedas emparejadas de área y especialidad. Cada punto es una de las 217 especialidades, con el promedio de las parejas de modelos y diez selecciones de candidatos. Ambos ámbitos contienen las mismas 50 consultas fijas entre 256 candidatos y fechas igualadas; se excluye el propio artículo. El conjunto del área está condicionado por estas consultas. Los puntos por encima de la diagonal tienen más coincidencia en la búsqueda estrecha; los situados por debajo tienen menos. La dispersión describe diferencias entre grupos, no intervalos de confianza.

estas medias próximas como evidencia de que ambas decisiones pueden tener consecuencias de tamaño comparable dentro de este diseño. No establecen equivalencia entre sus efectos.

Quitar solo el título cambia menos. Las entradas de solo resumen tienen un cambio medio de forma de 0,027, pero sustituyen el 22,1 % de los 25 vecinos. Por tanto, un cambio pequeño en la geometría general puede alterar los artículos recuperados localmente. También hay diferencias importantes entre modelos: al usar solo el título, la sustitución de vecinos va del 51,7 % en MPNet al 84,2 % en SciBERT (Tabla S5). Una única media conjunta ocultaría esas diferencias.

Esa propia comparación depende de la combinación de las salidas. Con la regla principal de la media, quitar el título tiene un efecto relativamente pequeño, mientras que quitar el resumen supera ligeramente al cambio de modelo en la sustitución media de vecinos. Con




Figura 3: Cambios asociados al modelo y al texto de entrada. Los mismos 52.000 identificadores aportan 2.000 candidatos por área. La entrada de referencia es título y resumen: quitar el resumen deja el título, y quitar el título deja el resumen. (A) Uno menos la CKA corregida. (B) Fracción de los 25 vecinos sustituidos. Cada punto es la media de un área sobre el conjunto fijo de modelos. Las cajas muestran la mediana y el rango intercuartílico, con bigotes de 1,5 veces ese rango; se muestran todas las áreas. No son intervalos de confianza. Se mantienen los límites propios de texto.

CLS o SEP para los cuatro BERT de palabras, este último orden se invierte. Esos escenarios mueven cuatro representaciones a la vez, incluida la referencia entre modelos. No aíslan un efecto puro de la combinación de las salidas. Seleccionar la regla que hiciera coincidir más a los modelos cambiaría el propósito de la comparación.

La muestra ampliada reduce la sensibilidad a la selección de artículos. Con 100 selecciones comparables en cada tamaño, el control del contraste de forma pasa de 72 alertas entre 520 contrastes de modelo, área y entrada con 26.000 artículos a cinco con 52.000. La comprobación anterior de 20 selecciones da 31 y cuatro, respectivamente (Figura S1). Se conservan ambos registros. Superar este control no significa que el contraste sea distinto de cero ni certifica todos los resultados de vecinos o variantes de representación. Los controles de fragmento común y longitud de MiniLM también distinguen la exposición desigual al texto de un error de programación: el límite original de MiniLM era su ajuste documentado, no un fallo de implementación.

4.4. Persistencia e inversión de las comparaciones geométricas entre áreas

La ampliación geométrica pregunta qué ocurre con una afirmación concreta sobre dos áreas al cambiar su representación. Antes de comparar modelos, la selección de artículos ofrece una comprobación interna. La apertura angular no conserva alertas entre los 260 casos de modelo y área, ni en el control de medias muestras ni en el de igual tamaño. La dimensión lineal efectiva conserva cuatro alertas en medias muestras, aunque no aparece ninguna en las cinco selecciones de igual tamaño (Tabla S12). Mantengo visibles esos cuatro casos; la segunda comprobación no anula la primera.

La estabilidad dentro de un modelo no asegura acuerdo entre modelos. Entre las 325 parejas de áreas, la apertura angular presenta una dirección común persistente en los diez modelos para 42 parejas, oposición persistente para 262 y un resultado sin resolver para 21. En la dimensión lineal efectiva, los recuentos son 54, 221 y 50 (Figura 4). La oposición significa que al menos dos modelos concretos mantienen direcciones contrarias en las 26 condiciones de selección guardadas. No exige que discrepen todos los modelos, y las parejas sin resolver pueden contener acuerdo parcial.

Muchas diferencias angulares son pequeñas. Exigir que cada dirección opuesta supere una diferencia relativa simétrica del 5 % reduce la oposición angular a 96 parejas; al 10 % quedan 19. La dimensión lineal efectiva conserva 177 y 126 oposiciones en esos umbrales. Por tanto, los totales basados solo en la dirección no deben leerse como desacuerdos del mismo tamaño. El mínimo es una elección explícita para comprobar sensibilidad, no una definición universal de diferencia científicamente relevante. La Figura 4 conserva las 325 parejas en cada fila para que siga visible el aumento de la categoría sin resolver.

Las medidas alternativas conservan buena parte del patrón. Al exigir que los mismos modelos opuestos mantengan sus direcciones en las alternativas angulares, permanecen 225 de las 262 oposiciones originales. Las alternativas espectrales conservan 196 de 221. Su cobertura es distinta: las alternativas angulares tienen las 26 condiciones de selección, mientras que el rango basado en entropía y el recuento del 80 % de varianza están disponibles para tres. Estas alternativas también comparten buena parte de su construcción matemática. Su acuerdo respalda una descripción geométrica, sin convertirla en una medida de diversidad temática.

El resultado no se limita a los cuatro BERT de palabras. Al restringir el conjunto a SPECTER, SPECTER2, SciNCL, MPNet, MiniLM y SimCSE, siguen apareciendo 231 oposiciones angulares y 160 de dimensión efectiva con mínimo cero. Un conjunto menor tiene menos oportunidades de contener modelos opuestos, por lo que el cambio en los recuentos no aísla un efecto del objetivo de entrenamiento. Las Tablas S14–S15 incluyen las omisiones de cada modelo y todas las clasificaciones de parejas.

Las decisiones de procesamiento añaden otro límite. Después de restar el centro global y volver a normalizar, la misma pareja original de modelos opuestos y sus direcciones se con-




Figura 4: Persistencia, oposición y magnitud de las comparaciones entre áreas. Cada fila contiene las 325 parejas para una propiedad y diez modelos. La dirección de un modelo debe mantenerse en la selección principal, veinte medias muestras y cinco selecciones adicionales de igual tamaño del mismo corpus. El acuerdo de los diez requiere una dirección común persistente; la oposición exige al menos dos modelos fijos con direcciones contrarias persistentes. Las demás parejas quedan sin resolver. La magnitud utiliza $2(B - A)/(A + B)$. Los cuatro mínimos son cortes operativos, no umbrales de significación o precisión. Las 26 condiciones se solapan; los controles puntuales se presentan por separado.

servan en 145 de 262 oposiciones angulares y en 218 de 221 oposiciones de dimensión efectiva, dentro del control puntual emparejado. La ordenación angular depende, por tanto, más de esa elección. Cambiar la regla de combinación también puede invertir comparaciones (Tabla S16). Son controles puntuales con referencias emparejadas, no otra serie de confirmaciones con 26 repeticiones. Las conclusiones se refieren a representaciones definidas explícitamente, no a propiedades que deban sobrevivir a cualquier transformación.

La conexión no cumplió el requisito de interpretación. Las nubes sintéticas alargadas y los puntos extremos aislados podían producir señales parecidas a la fragmentación, mientras que el tamaño de muestra y el número de vecinos alteraban sustancialmente las medidas. El control de igual tamaño conservó 51 alertas de conexión entre 260 casos. Por eso presento

los resultados de conexión y sus comprobaciones fallidas de significado en el Suplemento S6, sin utilizarlos para inferir que un área contenga más grupos temáticos separados.

5. Discusión

5.1. Del acuerdo entre mapas a la persistencia de una afirmación

El resultado más útil es la coexistencia de estructura compartida y desacuerdo persistente sobre una afirmación concreta. El acuerdo entre centros supera la referencia de grupos aleatorios. Aun así, modelos que comparten esa organización general pueden ordenar repetidamente una pareja de áreas en direcciones contrarias mientras cambian los artículos. Por eso vincularía la evaluación de robustez a la comparación que se está interpretando. Un conjunto estable de vecinos, una relación entre grupos y un orden sobre una propiedad geométrica necesitan cada uno su comprobación; una puntuación global no puede resolverlos todos.

Esta lectura se apoya en una preocupación establecida en los mapas de la ciencia (Gläser et al., 2017; Boyack and Klavans, 2020). Constantino et al. (2025) evalúan representaciones frente a una clasificación externa concreta. Caspari et al. (2024) comparan la geometría y las relaciones de búsqueda que comparten las representaciones. Aquí conecto esos niveles con la persistencia y el tamaño de comparaciones concretas entre áreas sobre artículos emparejados. La aportación descansa en esa conexión y en sus controles. Tanto las medidas de acuerdo como la preocupación por elegir la representación tienen antecedentes claros.

Las medidas geométricas son útiles dentro de esa interpretación deliberadamente limitada. Un ángulo describe separación; PR describe cómo ocupa la varianza las direcciones lineales. Llamar a cualquiera de ellas interdisciplinariedad o diversidad semántica añadiría una afirmación sobre contenido que estos cálculos no han contrastado. El trabajo sobre isotropía de embeddings plantea un problema relacionado: hacer corresponder una cantidad geométrica con su interpretación (Rudman et al., 2022). Las comprobaciones de conexión muestran el coste práctico: unas diferencias repetibles entre nubes no bastaron para sostener la lectura propuesta como fragmentación.

5.2. Implicaciones para comparar mapas de la ciencia

En una aplicación de mapas de la ciencia, empezaría por la comparación que se espera que el lector interprete. Una afirmación de búsqueda necesita un conjunto de candidatos y un número de vecinos especificados. Una comparación geométrica de áreas necesita una regla explícita de representación, equilibrio de artículos y diferencia mínima. Esas decisiones deberían guiar la comprobación de robustez. El experimento de entrada también ofrece una lección concreta de documentación: junto al nombre del modelo deben aparecer la elección

de título o resumen, el límite de texto y la regla de combinación de las salidas, porque cada una ayuda a determinar la representación que se interpreta.

Los análisis suplementarios se resisten a una explicación fácil de por qué discrepan los modelos. Medicina tiene menor acuerdo de forma que Energía, pero no es siempre la más baja en vecinos. La diferencia entre Medicina y Energía permanece al equilibrar especialidades y al retirar BioBERT y PubMedBERT (Suplemento S5). Esas comprobaciones acotan posibles explicaciones sin establecer una causa única. Las familias de modelos también dependen de cómo se obtiene el vector. Como arquitectura, fuente de entrenamiento y objetivo varían de forma ligada entre estos modelos, las similitudes observadas no permiten asignar un papel causal separado a cada factor.

El tiempo deja especialmente clara la dependencia del diseño de comparación. El acuerdo medio de forma aumenta ligeramente entre el primer y el último período. El acuerdo medio de vecinos baja 0,87 puntos porcentuales con todos los candidatos y sube 0,91 puntos con 2.048 candidatos por grupo. La oportunidad de búsqueda cambia el signo. Por tanto, evitaría leer esto como evidencia de que la ciencia ha convergido históricamente. Los modelos utilizan sus parámetros actuales para representar publicaciones antiguas y recientes; el cálculo no reconstruye el conocimiento disponible cuando aparecieron esos artículos.

5.3. Límites y siguiente validación

Las afirmaciones terminan en los límites del corpus, además de los de la comparación. Son registros seleccionados de OpenAlex con resúmenes utilizables y texto predominantemente inglés. El refuerzo, las muestras equilibradas y el mismo peso por grupo permiten comparar áreas, sin estimar la composición de la investigación mundial. El atlas identifica errores de clasificación y contenido que sobreviven a la limpieza. Las comprobaciones abordan fallos concretos en lugar de certificar cada registro. Las selecciones y versiones guardadas permiten inspeccionar el trabajo, pero repetir selecciones no corrige lo que el corpus deja fuera.

Los diez modelos ofrecen un conjunto acotado de alternativas. Varios comparten arquitecturas, fuentes de entrenamiento y objetivos, y varios no son modelos especializados en similitud. Restringir el análisis a seis modelos orientados a similitud o cambiar las reglas de representación aborda algunos problemas sin producir una muestra representativa de modelos. La oposición persistente establece una dependencia dentro de este conjunto. Decidir qué dirección describe mejor la investigación subyacente exigiría evidencia más allá de esa oposición.

La secuencia del trabajo es otro límite que mantengo. La ampliación geométrica y el resumen de todas las parejas siguieron a resultados anteriores; conservar los registros completos no cambia su carácter exploratorio. Como siguiente paso, elegiría una comparación relevante y la evaluaría frente a relaciones entre artículos juzgadas de forma independiente o una pregunta propia de una disciplina. Esto abordaría la conexión entre geometría y contenido que sigue

abierta. Añadir modelos por sí solo ampliaría la comparación de acuerdo sin aportar esa conexión.

6. Conclusión

El acuerdo general entre modelos puede coexistir con vecinos distintos y órdenes geométricos opuestos entre áreas. Elegir el texto de entrada puede importar tanto como cambiar de modelo, y repetir la selección de artículos puede conservar un resultado que se invierte entre modelos. Por eso propongo contrastar la afirmación extraída del mapa junto con la similitud general. La apertura angular y la dimensión lineal efectiva lo permiten en comparaciones geométricas concretas, siempre que queden explícitas sus definiciones, magnitudes y sensibilidades al procesamiento. El paso pendiente es sustantivo: interpretar esas geometrías producidas por modelos como propiedades del conocimiento científico requiere más validación.

Declaraciones

Contribuciones del autor. Alejandro Treny Ortega concibió el proyecto y dirigió la investigación y la preparación del manuscrito como investigador independiente. La ayuda computacional y editorial se declara a continuación.

Conflictos de interés. El autor declara que no tiene conflictos de interés.

Financiación. Esta investigación no recibió financiación externa.

Disponibilidad de datos y código. El repositorio del proyecto es <https://github.com/aleetreny/Shape-of-Science-Robustness>. Este borrador se acompaña de las tablas utilizadas en las figuras y de las fuentes editables del manuscrito. El corpus fijo, los vectores y los registros locales completos de ejecución no se han depositado en un archivo público persistente. Publicar el código por sí solo no permite reproducir por completo este análisis. El Suplemento S8 detalla el inventario de acceso y los requisitos pendientes; aquí no se afirma que exista un depósito de datos ni un identificador persistente.

Uso de herramientas de inteligencia artificial. OpenAI Codex ayudó con las búsquedas bibliográficas, el desarrollo de software y los análisis, la visualización y la redacción y edición del manuscrito. El autor es responsable del contenido.

Referencias

- Iz Beltagy, Kyle Lo, and Arman Cohan. SciBERT: A pretrained language model for scientific text. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3615–3620, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1371. URL <https://aclanthology.org/D19-1371/>.
- Kevin W. Boyack and Richard Klavans. A comparison of large-scale science models based on textual, direct citation and hybrid relatedness. *Quantitative Science Studies*, 1(4):1570–1585, 2020. ISSN 2641-3337. doi: 10.1162/qss_a_00085.
- Laura Caspari, Kanishka Ghosh Dastidar, Saber Zerhoubi, Jelena Mitrovic, and Michael Granitzer. Beyond benchmarks: Evaluating embedding model similarity for retrieval augmented generation systems. arXiv:2407.08275, 2024. URL <https://arxiv.org/abs/2407.08275>. Preprint.
- Arman Cohan, Sergey Feldman, Iz Beltagy, Doug Downey, and Daniel Weld. SPECTER: Document-level representation learning using citation-informed transformers. In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2270–2282, Online, jul 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.207. URL <https://aclanthology.org/2020.acl-main.207/>.
- Isabel Constantino, Sadamori Kojaku, Santo Fortunato, and Yong-Yeol Ahn. Representing the disciplinary structure of physics: A comparative evaluation of graph and text embedding methods. *Quantitative Science Studies*, 6:263–280, 2025. ISSN 2641-3337. doi: 10.1162/qss_a_00349.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Jill Burstein, Christy Doran, and Thamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, jun 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423/>.
- Tianyu Gao, Xingcheng Yao, and Danqi Chen. SimCSE: Simple contrastive learning of sentence embeddings. In Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih, editors, *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6894–6910, Online and Punta Cana, Dominican Republic, nov 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.emnlp-main.552. URL <https://aclanthology.org/2021.emnlp-main.552/>.
- Jochen Gläser, Wolfgang Glänzel, and Andrea Scharnhorst. Same data—different results? towards a comparative approach to the identification of thematic structures in science. *Scientometrics*, 111(2):981–998, 2017. ISSN 0138-9130. doi: 10.1007/s11192-017-2296-z.
- Rita González-Márquez, Luca Schmidt, Benjamin M. Schmidt, Philipp Berens, and Dmitry Kobak. The landscape of biomedical research. *Patterns*, 5(6):100968, 2024. ISSN 2666-3899. doi: 10.1016/j.patter.2024.100968.

- Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23, 2022. ISSN 2691-1957. doi: 10.1145/3458754.
- Matthias Held and Theresa Velden. How to interpret algorithmically constructed topical structures of scientific fields? a case study of citation-based mappings of the research specialty of invasion biology. *Quantitative Science Studies*, 3(3):651–671, 2022. ISSN 2641-3337. doi: 10.1162/qss_a_00194.
- Nathaniel Imel and Zachary Hafen. Density, asymmetry and citation dynamics in scientific literature. arXiv:2506.23366, 2025. URL <https://arxiv.org/abs/2506.23366>. Preprint.
- Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529. PMLR, 09–15 Jun 2019. URL <https://proceedings.mlr.press/v97/kornblith19a.html>.
- Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240, 2020. ISSN 1367-4803. doi: 10.1093/bioinformatics/btz682.
- Alex Murphy, Joel Zylberberg, and Alona Fyshe. Correcting biased centered kernel alignment measures in biological and artificial neural networks. arXiv:2405.01012, 2024. URL <https://arxiv.org/abs/2405.01012>. Preprint.
- OpenAlex. Topics. OpenAlex Help Center, 2026. URL <https://help.openalex.org/data/topics/>. Accessed 18 September 2026.
- Malte Ostendorff, Nils Rethmeier, Isabelle Augenstein, Bela Gipp, and Georg Rehm. Neighborhood contrastive learning for scientific document representations with citation embeddings. In Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11670–11688, Abu Dhabi, United Arab Emirates, dec 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.802. URL <https://aclanthology.org/2022.emnlp-main.802/>.
- Jason Priem, Heather Piwowar, and Richard Orr. OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts, 2022. URL <https://arxiv.org/abs/2205.01833v2>. Preprint, version 2.
- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL <https://aclanthology.org/D19-1410/>.
- William Rudman, Nate Gillman, Taylor Rayne, and Carsten Eickhoff. IsoScore: Measuring the uniformity of embedding space utilization. In Smaranda Muresan, Preslav Nakov, and Aline

- Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3325–3339, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.262. URL <https://aclanthology.org/2022.findings-acl.262/>.
- Amanpreet Singh, Mike D’Arcy, Arman Cohan, Doug Downey, and Sergey Feldman. SciRe-pEval: A multi-format benchmark for scientific document representations. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5548–5566, Singapore, dec 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.338. URL <https://aclanthology.org/2023.emnlp-main.338/>.
- Shruti Singh and Mayank Singh. The inefficiency of language models in scholarly retrieval: An experimental walk-through. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3153–3173, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.249. URL <https://aclanthology.org/2022.findings-acl.249/>.
- Alex H Williams. Equivalence between representational similarity analysis, centered kernel alignment, and canonical correlations analysis. In Marco Fumero, Clementine Domine, Zorah Lähner, Donato Crisostomi, Luca Moschella, and Kimberly Stachenfeld, editors, *Proceedings of UniReps: the Second Edition of the Workshop on Unifying Representations in Neural Models*, volume 285 of *Proceedings of Machine Learning Research*, pages 10–23. PMLR, 14 Dec 2024. URL <https://proceedings.mlr.press/v285/williams24a.html>.
- Alex H Williams, Erin Kunz, Simon Kornblith, and Scott Linderman. Generalized shape metrics on neural representations. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, volume 34, pages 4738–4750. Curran Associates, Inc., 2021. URL https://proceedings.neurips.cc/paper_files/paper/2021/file/252a3dbaeb32e7690242ad3b556e626b-Paper.pdf.