

¿Cuánto depende el mapa de la ciencia del modelo de embeddings?

Alejandro Treny Ortega

Investigador independiente

Versión española para revisión personal • 20 de septiembre de 2026

Resumen

Los mapas de la ciencia usan las relaciones entre artículos para describir cómo se organiza la investigación. Cuando esas relaciones proceden de embeddings de texto, un modelo convierte cada artículo en una lista de números. ¿Otro modelo daría la misma imagen? Comparo diez modelos con 500.000 publicaciones de OpenAlex de 2000–2024, repartidas en 26 disciplinas, como Medicina o Física. Al representar cada disciplina mediante la posición media de sus artículos, los modelos muestran una organización parecida. Esto se mantiene al elegir otros artículos para calcular esas medias. Sin embargo, dentro de una disciplina y período, dos modelos comparten, en promedio, solo ocho de los 25 artículos que sitúan más cerca de un mismo artículo. Dar a un modelo solo el título de cada artículo, en vez del título y el resumen, también cambia buena parte de esa lista. El efecto varía según el modelo. Un modelo puede situar los artículos de una disciplina más juntos que los de otra, mientras otro modelo invierte ese orden. Esta comparación utiliza los ángulos entre las posiciones asignadas a los artículos. Mover el punto desde el que medimos esos ángulos puede cambiar la respuesta, incluso cuando elegir otros artículos no la cambia. Estas pruebas muestran qué relaciones comparten las representaciones y cuáles dependen del modelo, del texto de entrada o del punto de referencia. El acuerdo sobre la organización general puede convivir con respuestas distintas sobre artículos cercanos y comparaciones entre disciplinas.

Palabras clave: mapas de la ciencia; embeddings de documentos; robustez; acuerdo de vecindarios; comparaciones geométricas.

1. Introducción

Un mapa de la ciencia puede ayudar a encontrar artículos relacionados o a comparar áreas de investigación. Su utilidad depende de las relaciones que muestra. Si dos modelos colocan artículos distintos cerca de un mismo trabajo, el lector puede acabar siguiendo caminos diferentes por la literatura. Si discrepan sobre lo dispersos que están los artículos de un área, también pueden llevar a describirla de formas distintas. En este estudio pregunto cuánto cambia todo esto cuando mantenemos los artículos y cambiamos únicamente su representación.

Los embeddings de texto son una forma de construir estos mapas. Un modelo lee el texto de un artículo y lo convierte en una lista de números, llamada vector. Esos números le dan una posición en un espacio donde podemos calcular distancias. Los artículos que quedan cerca se consideran relacionados. Este procedimiento se ha usado para cartografiar la literatura biomédica y la estructura de la física (González-Márquez et al., 2024; Constantino et al., 2025). Pero la posición la produce el modelo. No es una relación observada con independencia de él.

Esta preocupación tiene una trayectoria en los estudios de mapas de la ciencia. Gläser et al. (2017) preguntaron cuánto refleja una estructura temática reconstruida el conocimiento científico y cuánto refleja el método utilizado para recuperarla. Boyack and Klavans (2020) encontraron que distintos métodos podían lograr una precisión global parecida y, al mismo tiempo, asignar artículos diferentes a cada grupo. Por tanto, una puntuación general puede dejar sin respuesta una pregunta importante: ¿otro método respaldaría la comparación concreta que quiere hacer el lector?

Abordo esta pregunta con diez modelos y una colección fija de 500.000 publicaciones. Primero comparo la organización general de las áreas y los artículos que quedan cerca unos de otros. Después examino si cambiar el texto que recibe un modelo importa tanto como cambiar el propio modelo. Una exploración posterior estudia comparaciones concretas entre áreas: ¿todos los modelos señalan la misma área como la que tiene representaciones más dispersas? Repetir estas comparaciones con otros artículos permite distinguir la dependencia de los artículos elegidos de la dependencia del modelo.

2. Antecedentes y preguntas de investigación

2.1. Qué aportan las comparaciones anteriores

Los trabajos previos evalúan los embeddings científicos con varios criterios útiles. Constantino et al. (2025) los comparan con clasificaciones disciplinares de física; González-Márquez et al. (2024) examinan artículos biomédicos relacionados y sus etiquetas. Estas comprobaciones preguntan si una representación coincide con información sobre la literatura. Este estudio plantea una pregunta complementaria: ¿qué relaciones se mantienen cuando cambia la representación?

Elegir el modelo es solo una de las decisiones. Un título y un resumen completo contienen cantidades distintas de información. Los modelos también leen textos de distinta longitud y combinan sus salidas de formas diferentes. Singh and Singh (2022) muestran que la búsqueda académica puede ser sensible a cómo se redactan las consultas cortas. Por eso, el texto que recibe el modelo forma parte de la comparación y no debería quedar sin especificar.

Comparar tanto la estructura general como los artículos cercanos tampoco es nuevo. Caspari et al. (2024) combinan comparaciones geométricas y de vecinos, mientras que Imel and Hafen (2025) estudian propiedades de los espacios de embeddings científicos junto con relaciones de citación. Parto de estos enfoques y mantengo los mismos artículos entre modelos, cambio de forma explícita el texto y las decisiones de procesamiento, y compruebo comparaciones concretas entre áreas con otras selecciones de artículos y otras medidas.

2.2. Qué permite afirmar el acuerdo

En este artículo, una *selección de artículos* es un conjunto elegido de la colección fija. Repetir la selección significa elegir otro conjunto con las mismas reglas de tamaño y fechas, sin descargar artículos nuevos. El *acuerdo* indica si distintos modelos dan resultados parecidos para los mismos artículos. La *estabilidad ante la selección* indica si el resultado se repite al cambiar los artículos elegidos. Una comparación puede ser estable dentro de cada modelo y, aun así, dar respuestas opuestas entre modelos.

Ninguna de estas dos propiedades demuestra que la respuesta sea correcta sobre la investigación. Los modelos pueden compartir un error, y un patrón que se repite puede ser difícil de interpretar. En un estudio de biología de invasiones, Held and Velden (2022) muestran por qué las agrupaciones temáticas necesitan una interpretación que vaya más allá de las comprobaciones numéricas. Aquí, el acuerdo indica que un resultado se mantiene al cambiar de modelo; no demuestra que describa correctamente los temas.

Comparo las representaciones numéricas antes de reducirlas a un dibujo en una página. Cada vector tiene cientos de coordenadas. Pasarlo a un gráfico de dos dimensiones añadiría otra transformación que podría alterar las distancias aparentes. En este artículo, la forma del mapa se refiere a las relaciones en ese espacio original.

2.3. Preguntas de investigación

PI1. Al cambiar de modelo, ¿qué se mantiene de la organización de las áreas y de los artículos que quedan cerca unos de otros?

PI2. ¿Cuánto importa cambiar el texto de entrada, o la regla para obtener un único vector por artículo, en comparación con cambiar de modelo?

PI3. ¿Los modelos coinciden sobre qué área tiene representaciones más dispersas o variación repartida entre más direcciones? ¿Se repiten estas comparaciones con otros artículos?

La tercera pregunta se añadió después de las comparaciones iniciales y es exploratoria. Las tres se refieren a una colección y un conjunto de modelos concretos. No buscan elegir un modelo ganador ni estimar la estructura de toda la literatura científica.

3. Datos y métodos

3.1. Una colección, varias preguntas

La colección de partida contiene 500.000 identificadores distintos de trabajos de OpenAlex, descargados y limpiados hasta el 15 de septiembre de 2026 (Priem et al., 2022). Los registros estaban etiquetados como artículos, revisiones o trabajos de congreso en inglés, publicados entre 2000 y 2024. Cada uno debía tener título, un resumen reconstruido de al menos 50 palabras y un área principal. Se excluyeron retractaciones, material accesorio y fallos claros de contenido. Los casos menos seguros y las posibles versiones duplicadas se conservaron con marcas de revisión, sin darlos por resueltos. El Suplemento S1 recoge las reglas y los recuentos.

OpenAlex asigna los artículos a áreas amplias, llamadas *Fields*, y a categorías más estrechas, llamadas *Subfields*, a partir de información del texto, las citas y las revistas (OpenAlex, 2026). Aquí las denomino áreas y especialidades. Por ejemplo, Medicina es un área; Cardiología y Medicina Cardiovascular es una de sus especialidades. Las 26 áreas son las unidades principales de comparación. Estas etiquetas de la base de datos permiten organizar el análisis; no son descripciones de cada artículo verificadas de forma independiente.

La colección tiene dos partes. Las peticiones aleatorias a la API, con semillas registradas, proporcionaron 400.000 registros que cumplían los requisitos. Otros 100.000 reforzaron los grupos con pocos artículos de una misma área y período de cinco años. Los cinco períodos son 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Así se obtienen 130 grupos de área y período, con al menos 2.165 artículos cada uno. Las búsquedas generales utilizan los 400.000 registros iniciales. Las comparaciones por área utilizan ambas partes. Ni la colección reforzada ni una media que da el mismo peso a cada área estiman las proporciones de la producción científica mundial.

No todas las preguntas requieren volver a procesar los 500.000 artículos. Para comparar el título, el resumen y ambos juntos, utilizo los mismos 52.000 artículos: 2.000 por área, con 400 de cada período. Esta selección incluye los 26.000 usados en una primera prueba más pequeña de esa misma comparación. El análisis posterior de la dispersión dentro de las áreas reutiliza estos 52.000 artículos. Otro conjunto distinto de 52.000 sirve para una pregunta diferente: comprobar qué cambia cuando todos los modelos leen el mismo fragmento de texto. La Tabla 1 distingue estos usos. En cada comparación entre modelos, ambos reciben los mismos identificadores de artículos.

Tabla 1: Preguntas, comparaciones y conjuntos de artículos.

Pregunta	Qué se compara	Artículos utilizados
¿Se conserva la organización general?	Diez modelos: relaciones entre centros de áreas o especialidades y entre artículos dentro de los grupos.	256 artículos por centro; elecciones repetidas y controles con 128 y 512.
¿Encuentran los modelos los mismos artículos cercanos?	Cuánto coinciden las listas de 25 vecinos de dos modelos.	Todos los artículos de cada área y período; otro control fija 2.048 candidatos por grupo. Búsqueda global: 13.000 artículos de partida entre 400.000 candidatos.
¿Importa cambiar el texto de entrada?	El mismo modelo lee solo el título, solo el resumen o ambos.	52.000: 2.000 por área, 400 por período. Incluye la primera prueba de 26.000.
¿Importa que todos lean el mismo fragmento?	La entrada habitual de cada modelo frente a un fragmento común que cabe en todos.	Otro conjunto de 52.000, con 400 por área y período.
¿Qué área tiene más dispersión o más direcciones de variación?	Dos propiedades geométricas para las 325 parejas de áreas, con diez modelos.	Los mismos 52.000 del experimento de texto; otras elecciones de artículos comprueban si las comparaciones se repiten.
¿Importa limitar la búsqueda a una especialidad?	Por ejemplo, Cardiología y Medicina Cardiovascular frente a Medicina, con 256 candidatos en cada búsqueda.	50 artículos de partida fijos por especialidad; diez elecciones de los otros 206 candidatos. En total, 10.850 artículos de partida en 217 especialidades.

Todos los conjuntos proceden de la misma colección de 500.000 artículos: 400.000 registros generales y 100.000 para reforzar grupos pequeños de área y período. Las filas no se suman. Los modelos usan los mismos identificadores en cada comparación. En la comparación de alcance, ambos conjuntos incluyen los mismos 50 artículos de partida. Los métodos y los Suplementos S1–S4 y S9 detallan los controles. Los 1.300 artículos de prueba del programa no son otra muestra científica.

3.2. Cómo representa cada modelo un artículo

Los diez modelos de la Tabla 2 abarcan documentos científicos, semejanza entre frases de uso general y lenguaje científico o biomédico. Se eligieron por su uso para representar literatura académica y por sus distintas formas de entrenamiento. Son un conjunto fijo de comparación, no una muestra aleatoria de modelos ni una clasificación de los sistemas más recientes. Sus versiones, los formatos de texto y la configuración de los programas se fijaron antes de calcular las representaciones.

La entrada principal es el título seguido del resumen, con el formato habitual de cada modelo. Los modelos leen piezas pequeñas de texto llamadas *tokens*, que pueden ser palabras enteras o partes de palabras. Por tanto, sus límites de entrada no equivalen a un número de palabras. En su configuración habitual, MiniLM lee como máximo 256 tokens y MPNet 384. Estos límites recortan parte de la entrada en el 49,58 % y el 20,16 % de los artículos, respectivamente. Mantengo esas configuraciones y pruebo MiniLM con 512 tokens por separado. La comprobación del fragmento común descrita antes permite que todos lean el mismo contenido, aunque cada modelo lo divida en tokens a su manera.

Algunos modelos producen un vector por token. Hace falta entonces una regla que convierta esas salidas en un único vector para el artículo. Este paso se llama *pooling*. Para BERT, SciBERT, BioBERT y PubMedBERT, la regla principal calcula la media de las salidas de la última capa en todas las posiciones con texto o símbolos especiales, sin incluir el relleno. Estos cuatro modelos no se entrenaron específicamente para comparar documentos completos. Dos comprobaciones usan, en su lugar, la salida de la primera posición, llamada CLS, o la de la última posición sin relleno, llamada SEP. CLS se toma antes de la transformación adicional del modelo llamada *pooler*. La regla de la media se fijó antes de las comparaciones principales y se mantuvo tras las primeras comprobaciones; no se eligió para maximizar el acuerdo. Los otros seis modelos utilizan sus reglas documentadas. El Suplemento S1 detalla la configuración.

3.3. Del conjunto de áreas a los artículos individuales

Antes de comparar las representaciones, cada vector se ajusta para que tenga longitud uno. Así, las comparaciones dependen de su dirección y no de su longitud. Para resumir un área, calculo la media de sus vectores y ajusto también ese centro a longitud uno. La posición de estos centros describe las relaciones generales entre áreas. Comparar los vectores individuales dentro de cada área permite conservar el detalle que esa media oculta.

La comparación original utiliza 256 artículos por centro: 26 áreas, 217 especialidades o una especialidad de cada área. Después repito cincuenta veces la elección de artículos, conservando los recuentos por período de cada grupo. Otra comprobación utiliza 128, 256 y 512 artículos, con las mismas 26 áreas y 183 especialidades que tienen suficientes trabajos. Ca-

Tabla 2: Modelos de embeddings y reglas principales de representación.

Modelo	Tamaño	Límite de tokens	Vector del artículo	Referencia
SPECTER	768	512	CLS	(Cohan et al., 2020)
SPECTER2	768	512	CLS + adaptador	(Singh et al., 2023)
SciNCL	768	512	CLS	(Ostendorff et al., 2022)
SciBERT	768	512	Media	(Beltagy et al., 2019)
BERT	768	512	Media	(Devlin et al., 2019)
MPNet	768	384	Media	(Reimers and Gurevych, 2019)
MiniLM	384	256	Media	(Reimers and Gurevych, 2019)
PubMedBERT / BiomedBERT	768	512	Media	(Gu et al., 2022)
BioBERT	768	512	Media	(Lee et al., 2020)
SimCSE	768	512	CLS, antes del pooler	(Gao et al., 2021)

Tamaño indica cuántas coordenadas contiene el vector. MPNet y MiniLM utilizan all-mpnet-base-v2 y all-MiniLM-L6-v2, respectivamente. Los límites cuentan tokens, incluidos los símbolos especiales. Media: promedio de posiciones sin relleno de la última capa, con símbolos especiales. CLS: primera posición antes del pooler; SPECTER2 añade su adaptador de proximidad. En MPNet/MiniLM, la referencia describe el marco Sentence-BERT, no el entrenamiento exacto de esas versiones. Las reglas alternativas no son modelos adicionales. Versiones, formatos y recorte: Tabla S2.

da selección tiene una referencia de grupos aleatorios formada con exactamente los mismos artículos y fechas. Otras pruebas omiten cada área y separan la elección de especialidades de la elección de sus artículos. Comparar estos centros es distinto de comparar los vectores individuales dentro de los grupos (Suplemento S9).

Los *vecinos* de un artículo son los artículos que quedan más cerca de él. El *artículo de partida* es aquel para el que buscamos vecinos; los *candidatos* son los artículos entre los que podemos buscarlos. Comparo las listas de los 25 vecinos más próximos que producen dos modelos, con listas de 10 y 50 como comprobaciones. La cercanía se mide con la similitud coseno, que compara las direcciones de los vectores. El artículo de partida no puede ser su propio vecino. Las listas se calculan de forma exacta y se comprueban mediante una ordenación independiente. Cada resultado indica si los candidatos son todos los del área y período, una selección de tamaño fijo dentro de ese grupo o los 400.000 registros generales.

La comprobación de calidad aplica las marcas y la regla de duplicados existentes, y conserva 448.886 registros. Compara los mismos artículos de partida antes y después de filtrar los

candidatos. Los controles de tamaño fijo usan 1.024 candidatos en los 130 grupos y 2.048 en los 63 que siguen teniendo suficientes artículos después del filtro. Ambos conjuntos incluyen los mismos 100 artículos de partida limpios. Otra prueba de texto iguala fechas y candidatos dentro del experimento de 52.000 artículos. Estos controles comprueban el filtro registrado, no todos los posibles errores de origen.

Otra comparación pregunta si los modelos comparten más vecinos al buscar dentro de una especialidad o al ampliar la búsqueda a su área. Pensemos en 50 artículos fijos de Cardiología y Medicina Cardiovascular. Para cada uno, comparamos una búsqueda entre 256 artículos de esa especialidad con otra entre 256 de Medicina. Ambos conjuntos incluyen los mismos 50 artículos de partida; quedan 206 plazas para otros artículos. Cada búsqueda excluye al propio artículo de partida. Repito diez veces la elección de los otros 206, manteniendo fijos los 50 y el mismo reparto de fechas entre ambas búsquedas. Este procedimiento se aplica a 217 especialidades: 10.850 artículos de partida en total. Por tanto, la selección amplia de Medicina también contiene obligatoriamente esos 50 artículos de Cardiología; no se elige libremente de toda el área.

3.4. Cómo se mide la estructura compartida y la dispersión de un área

Para comparar la estructura general, examino si los mismos artículos mantienen un patrón parecido de relaciones en dos representaciones. La medida principal es la alineación lineal de núcleos centrados con corrección, abreviada CKA (Kornblith et al., 2019; Murphy et al., 2024). Un valor cercano a uno, como 0,9, indica que esos patrones se parecen mucho según esta medida: los modelos organizan los mismos objetos de forma parecida. Es una puntuación de acuerdo, no un porcentaje de ciencia representada correctamente. La corrección reduce una inflación conocida debida al tamaño finito de la muestra; no elimina todo el sesgo estadístico. Otras dos comprobaciones permiten girar y cambiar de escala las representaciones para compararlas, mediante la alineación de Procrustes, o comparan el orden de las distancias entre artículos. Responden a aspectos distintos de las representaciones (Williams et al., 2021; Williams, 2024). El Suplemento S2 contiene las fórmulas.

También describo dos propiedades dentro de cada área. La *apertura angular* mide cuánto se separan las direcciones de los vectores: resume los ángulos entre vectores distintos, con la regla de distancia mediana del Suplemento S6. Ángulos mayores indican direcciones más separadas. La *dimensión lineal efectiva*, medida con la razón de participación o PR, indica cómo se reparte la variación entre las direcciones. Para entenderlo, una nube concentrada a lo largo de una línea varía sobre todo en una dirección; una nube extendida sobre un plano varía en más. La medida lleva esta idea al espacio completo de los vectores. Ninguna de las dos propiedades cuenta temas de investigación ni establece lo diversa que es un área.

Otras formas de resumir los ángulos y la variación permiten comprobar cuánto depende el resultado de la fórmula elegida. Para dimensión, una alternativa mide cómo se reparte la variación (dimensión por entropía); otra cuenta las direcciones necesarias para explicar el 80 % de ella (D80). Estas alternativas utilizan la misma variación de partida, por lo que no validan de forma independiente una interpretación temática. También probé si los enlaces entre artículos cercanos permitían identificar grupos separados. Sin embargo, las comprobaciones con ejemplos artificiales impidieron interpretar esa medida como fragmentación general. El Suplemento S6 recoge las definiciones y los controles.

3.5. Cómo se comprueba si una comparación se repite

Con 26 áreas hay 325 formas de elegir dos áreas distintas, contando cada comparación una sola vez. Para cada propiedad geométrica, examino qué área tiene el valor mayor según cada modelo. Repito el cálculo con veinte medias muestras de 1.000 artículos por área y cinco selecciones adicionales de 2.000. Una dirección se considera persistente solo si se mantiene en todas esas selecciones y en la principal de 2.000: 26 condiciones en total. Las dos alternativas de dimensión usan las mismas condiciones. Otra comprobación cambia el punto desde el que medimos las direcciones. Para cada modelo, calculo la media de los 52.000 vectores unitarios equilibrados, resto esa media común a cada vector y vuelvo a ajustar su longitud a uno. Esta operación, llamada centrado global seguido de normalización, lleva el punto de referencia a la posición media de la colección. Cambia la representación antes de medir apertura y dimensión; es distinta del centrado de la covarianza que forma parte del cálculo de PR.

Así se distinguen tres resultados: los diez modelos señalan siempre la misma área como la de mayor valor; al menos dos modelos concretos dan siempre respuestas opuestas; o no se cumple ninguna de esas condiciones. Llamo *sin resolver* al tercer caso. Por ejemplo, algunos modelos pueden cambiar el orden al elegir otros artículos, sin que haya una pareja fija que mantenga respuestas opuestas. Un empate o un cambio de orden no cuenta como dirección persistente. Si no queda acuerdo completo ni oposición fija, la pareja queda sin resolver; esto no significa que las áreas sean iguales. Además de cualquier diferencia distinta de cero, examino diferencias mínimas del 1, 5 y 10 % de la media de los dos valores. Una diferencia que no alcanza el mínimo exigido también queda sin resolver. Estos cortes permiten ver si el resultado depende de diferencias muy pequeñas.

Dos selecciones pueden contener muchos de los mismos artículos porque ambas proceden de la colección fija. El rango de sus resultados describe qué cambia al elegir otros artículos disponibles; no es un intervalo de confianza para toda la literatura científica. Una *alerta de selección* señala que un resultado varía entre elecciones de artículos, o cambia entre los tamaños probados, más de lo permitido por una tolerancia registrada. Indica sensibilidad a los artículos elegidos, no un error en los registros de origen. El suplemento conserva las reglas y recuentos de cada comprobación. Las comparaciones también reutilizan modelos y

áreas, por lo que sus resultados no se tratan como observaciones independientes en pruebas de significación.

El trabajo se desarrolló por etapas. Las primeras comparaciones de estructura y vecinos precedieron a la ampliación del experimento de texto y a las búsquedas por especialidad. El análisis geométrico fue una exploración posterior; el resumen de las 325 comparaciones se hizo después de conocer sus primeros ejemplos. Las reglas se registraron antes de los nuevos cálculos correspondientes, con resultados anteriores ya conocidos. Algunos controles se añadieron durante este proceso. El Suplemento S2 recoge la secuencia; el estudio completo no se prerregistró externamente.

4. Resultados

4.1. La organización general se comparte más que el detalle

La organización general se repite al elegir otros artículos. Las medias originales de CKA corregida de 0,939 para centros de áreas y 0,911 para centros de especialidades pasan a 0,940 y 0,911 en cincuenta selecciones. Sus rangos centrales del 95 % entre selecciones son 0,937–0,943 y 0,910–0,912 (Figura 1A). Los grupos aleatorios dan medias de 0,627 y 0,636; ninguna de sus medias alcanza la menor media observada.

La comprobación de tamaño da medias entre centros de áreas de 0,938, 0,940 y 0,941 con 128, 256 y 512 artículos; las mismas 183 especialidades dan 0,913, 0,914 y 0,915. Omitir un área de la comparación original da 0,933–0,946. Ninguna área por sí sola explica el alto acuerdo general. Elegir una especialidad por área da una media de 0,904: importa más qué especialidad se elige que qué artículos se eligen dentro de ella (Tabla S18).

Dentro de los grupos, la CKA media sigue rondando 0,63 para las áreas y 0,64 para las mismas 183 especialidades al pasar de 128 a 512 artículos (Figura 1B). Esta media estable oculta comparaciones locales sensibles: el 31,9 % de las 8.235 comparaciones de especialidad y pareja de modelos activa la alerta de selección (2.628 casos). Su acuerdo varía más de lo permitido por la tolerancia registrada al cambiar los artículos o el tamaño probado. Así, una media general estable puede convivir con resultados de especialidades que dependen de qué artículos se elijan. La diferencia entre centros y artículos individuales también compara objetos distintos, sin aislar únicamente la escala.

Las medidas alternativas respaldan en general el orden del acuerdo entre modelos. En los 130 grupos originales de área y período, sus correlaciones de rangos medias con la CKA corregida son 0,891 para Procrustes y 0,881 para el orden de las distancias. La coincidencia no es completa, y la comprobación original de selección conserva 50 alertas entre 5.850 comparaciones de pareja de modelos y grupo (Tabla S4). Estos casos concretos siguen siendo relevantes aunque cambie poco la media general.




Figura 1: Acuerdo sobre los resúmenes de áreas y sobre sus artículos. Una CKA corregida mayor indica más acuerdo entre modelos. (A) Cada centro usa 256 artículos. Los resultados de áreas y especialidades promedian cincuenta selecciones de artículos. La condición de 26 especialidades elige una especialidad de cada una de las 26 áreas, repite cincuenta veces esa elección y escoge diez conjuntos de artículos por elección. Los grupos aleatorios usan los mismos artículos, tamaños y fechas. Las líneas muestran los percentiles 2,5–97,5 de las medias entre selecciones. (B) Acuerdo entre artículos individuales con tres tamaños, dentro de 26 áreas y las mismas 183 especialidades. Los puntos son medias; las líneas abarcan los percentiles 2,5–97,5 de los resultados de grupo y pareja de modelos: 1.170 para áreas y 8.235 para especialidades. Los paneles resumen objetos y fuentes de variación distintos; estos rangos no son intervalos de confianza.

4.2. Cambiar el modelo cambia qué artículos aparecen cerca

Dentro de la misma área y período, dos modelos conservan en promedio el 30,3 % de los 25 vecinos más próximos: unos ocho artículos de 25. Esta media da el mismo peso a cada grupo y pareja de modelos. Limitar cada grupo de área y período a 2.048 candidatos eleva el acuerdo al 31,9 %. Todos los grupos tienen la misma cantidad; los artículos son los mismos entre modelos dentro de cada grupo, no entre disciplinas distintas. Otra búsqueda toma 100 artículos de partida de cada uno de los 130 grupos, 13.000 en total, y busca sus vecinos entre los 400.000 registros generales. Aquí, el acuerdo es del 17,5 %. Esta búsqueda admite artículos de otras disciplinas y períodos y, además, ofrece muchos más candidatos. Cualquiera de esos cambios puede afectar al acuerdo; esta comparación no permite separar sus efectos.

Después retiro los registros con las marcas de revisión incluidas en el filtro y conservo un representante de cada grupo de duplicados detectado. Para los mismos artículos de partida conservados, el acuerdo de vecinos pasa del 30,58 % al 31,43 %: sube 0,85 puntos porcentuales.

Ambas medias siguen siendo unos ocho artículos compartidos en una lista de 25. Al mantener fija la cantidad de candidatos, el cambio es menor: 0,28 puntos con 1.024 y 0,19 con 2.048. Los problemas que retira este filtro explican, por tanto, poco del desacuerdo general, aunque algunas áreas cambian más que otras (Tabla S19).

Las búsquedas emparejadas permiten cambiar el alcance disciplinar manteniendo iguales la cantidad de candidatos y las fechas (Figura 2). Al buscar solo dentro de la especialidad, los modelos comparten menos de sus 25 vecinos en 127 de las 217 especialidades (58,5 %), pero más en las otras 90 (41,5 %). El cambio medio frente a buscar en el área amplia es de $-1,35$ puntos porcentuales. Con listas de 50 vecinos, el reparto es casi igual: el acuerdo baja en 109 especialidades y sube en 108. Limitar la búsqueda no tiene, por tanto, el mismo efecto en todas ellas. Estos cambios describen cuánto coinciden las listas de los modelos, no lo útiles que son los artículos encontrados.

La estructura general y el acuerdo entre vecinos están relacionados: su correlación de rangos en las medias de las 45 parejas de modelos es 0,920. Es decir, las parejas que coinciden más en una cosa tienden a coincidir más en la otra. Aun así, una pareja puede conservar la estructura general y cambiar muchos vecinos individuales. Estas observaciones, que comparten modelos, son descriptivas y no pruebas independientes de fiabilidad.

El Suplemento S4 pasa de las medias a artículos concretos: comprueba si un artículo conserva sus vecinos al cambiar el tamaño de muestra, la regla que forma su vector o la longitud de la lista de vecinos. Leer esos ejemplos también permitió detectar problemas de origen. Un libro de historia aparece en Física, un texto sobre infección bacteriana en Política y otro registro es un anuncio. Los contrasté con los registros descargados de OpenAlex: esas etiquetas y contenidos ya estaban allí; no surgieron al confundir artículos entre las salidas de los modelos. Los ejemplos permanecen en el análisis. Como se eligieron casos concretos para examinarlos, su número no estima la frecuencia de esos problemas en la colección.




Figura 2: ¿Limitar una búsqueda a una especialidad cambia el acuerdo? Cada punto representa una de 217 especialidades. El eje horizontal muestra la fracción de vecinos compartidos al buscar en el área que la contiene, como Medicina; el vertical muestra esa fracción dentro de la rama más concreta, como Cardiología y Medicina Cardiovascular. Un punto por encima de la diagonal indica que los modelos comparten más vecinos en la búsqueda estrecha. Ambos conjuntos contienen 256 candidatos, incluidos los mismos 50 artículos de partida, y fechas emparejadas. Los valores promedian las parejas de modelos y diez elecciones de los otros 206 candidatos. La selección del área amplia incluye, por tanto, siempre esos 50 artículos de la especialidad. La dispersión de puntos muestra diferencias entre especialidades, no intervalos de confianza.

4.3. Medias parecidas ocultan comportamientos distintos entre modelos

Cada modelo recibe tres entradas para cada uno de los mismos 52.000 artículos: solo el título, solo el resumen y título más resumen. El texto combinado da la representación de partida. Comparo después dos cambios: mantener ese texto y usar otro modelo, o mantener el modelo y darle solo el título. En promedio, el primero sustituye el 68,8 % de los 25 vecinos y el segundo el 70,7 % (Figura 3). Los cambios correspondientes en la estructura general, medidos como uno menos la CKA, son 0,370 y 0,366. Son medias del conjunto de modelos, no el efecto en cada uno de ellos.




Figura 3: Cambiar el modelo o cambiar lo que lee. Todas las comparaciones utilizan los mismos 52.000 artículos, con 2.000 por área. La entrada de referencia es título más resumen. El cambio de modelo compara modelos distintos con esa entrada; el cambio de texto conserva el modelo y usa solo el título o solo el resumen. Valores mayores indican más cambio: (A) uno menos la CKA corregida; (B) la fracción de los 25 vecinos que se sustituye. Cada punto es una media de área. Las cajas muestran la mediana y la mitad central de los valores de área; los extremos llegan hasta valores situados a un máximo de 1,5 rangos intercuartílicos de la caja. Son distribuciones descriptivas, no intervalos de confianza. Los modelos conservan sus límites habituales de texto.

Usar solo el resumen cambia menos: 0,027 para la estructura y un 22,1 % de los vecinos. Las medias también ocultan diferencias entre modelos. Utilizar solo el título sustituye el 51,7 % de los vecinos con MPNet y el 84,2 % con SciBERT (Tabla S5).

Una comprobación directa de vecinos repite cincuenta selecciones equilibradas de 1.000 candidatos por área, la mitad de la muestra completa. Con 25 vecinos, cambiar de modelo sustituye el 64,93 % y dar solo el título sustituye el 66,49 %. La diferencia es de 1,56 puntos porcentuales, con un rango central del 95 % entre selecciones de 1,44–1,69; el signo nunca se invierte. Las diferencias medias son de 1,97 puntos con 10 vecinos y 1,04 con 50. Sin embargo, la diferencia por modelo va de $-14,04$ puntos para MPNet a $+16,59$ para SciBERT. La media general establece oculta resultados opuestos entre modelos (Suplemento S9).

El resultado también depende de cómo BERT, SciBERT, BioBERT y PubMedBERT producen un vector para todo el artículo. La regla principal calcula la media de sus salidas por token. Las alternativas usan solo la primera salida (CLS) o la última sin relleno (SEP), que también han procesado el contexto de entrada. Con estas alternativas, dar solo el título cambia menos vecinos que cambiar de modelo en todas las repeticiones: 3,13 puntos porcentuales

menos con CLS y 2,00 menos con SEP, para 25 vecinos. Las dos comparaciones se recalculan con la regla elegida; los otros seis modelos mantienen sus configuraciones habituales. Por tanto, el orden medio se invierte al cambiar esta forma práctica de usar los cuatro modelos. Este experimento de tres entradas comenzó con 26.000 artículos y añadió después otros 26.000 con el mismo diseño; los primeros están incluidos en los 52.000 finales. A ambos tamaños se aplicó la misma comprobación de estructura, eligiendo otros artículos 100 veces. Las alertas bajan de 72 de 520 comparaciones de modelo, área y entrada (13,8 %) a cinco de 520 (1,0 %). Así, menos resultados superan la tolerancia registrada, aunque esto no demuestra estabilidad para cada comparación de vecinos. El Suplemento S3 conserva por separado la comprobación anterior con veinte selecciones. Las pruebas del fragmento común y de MiniLM con 512 tokens estudian otra cuestión, la longitud de entrada; no revelan un error de código en el límite original de MiniLM.

4.4. Comparar dos áreas puede dar la respuesta contraria con otro modelo

El análisis geométrico reutiliza los 52.000 artículos del experimento de texto y sus representaciones de título más resumen. Pregunta, por ejemplo, si los vectores de un área apuntan en direcciones más separadas que los de otra. Primero comprobé cuánto cambia cada medida al elegir otros artículos. Entre diez modelos y 26 áreas, la apertura angular no tiene alertas ni con medias muestras ni con selecciones de igual tamaño. PR tiene cuatro alertas entre 260 casos (1,5 %) al usar veinte medias muestras de 1.000 artículos por área. No aparece ninguna en cinco selecciones adicionales de 2.000 por área. Son comprobaciones con tamaños y cantidades de repeticiones distintos; superar la segunda no borra la sensibilidad encontrada en la primera.

De las 325 parejas de áreas, el 80,6 % tiene respuestas opuestas persistentes de al menos dos modelos para la apertura angular; la proporción es del 68,0 % para PR (Figura 4). Por ejemplo, un modelo concreto da siempre mayor apertura a A que a B, mientras otro da siempre mayor apertura a B. *Mayor* se refiere al valor medido, no a una posición más alta en un dibujo ni a mejor investigación. Los demás modelos no tienen por qué discrepar entre sí. Los diez coinciden de forma persistente sobre el área de mayor valor en el 12,9 % de las parejas para apertura y el 16,6 % para PR. El 6,5 % y el 15,4 % restantes, respectivamente, no cumplen ninguna de las dos reglas y quedan sin resolver.

Muchas respuestas opuestas corresponden a diferencias pequeñas. Exigir que la diferencia supere el 5 % de la media de los dos valores reduce la oposición persistente al 29,5 % de las 325 parejas para apertura y al 54,5 % para PR. Con una diferencia mínima del 10 %, esas proporciones bajan al 5,8 % y al 38,8 %. Por tanto, conviene distinguir una inversión basada en una diferencia diminuta de otra con una diferencia mayor.




Figura 4: La respuesta depende de la representación además del modelo. Cada barra abarca las 325 parejas de áreas. Azul: los diez modelos dan siempre el mayor valor medido a la misma área. Naranja: al menos dos modelos concretos mantienen órdenes opuestos. Gris: no se cumple ninguna regla, incluidos empates y cambios de orden. Cada clasificación usa 26 condiciones: los 2.000 artículos principales por área, veinte medias muestras de 1.000 y cinco selecciones adicionales de 2.000. Las representaciones original y centrada usan los mismos artículos. El centrado resta la media de los 52.000 vectores unitarios equilibrados de cada modelo y reajusta cada vector resultante a longitud uno. Los cortes de 0 y 5 % exigen diferencias relativas superiores a esos valores en todas las condiciones. La Tabla S20 recoge los cuatro cortes y comprueba si los mismos modelos opuestos conservan sus direcciones.

Otras formas de resumir los ángulos conservan al menos una pareja de los modelos opuestos originales y sus direcciones en el 85,9 % de las oposiciones angulares originales (225/262). Para dimensión, la medida de entropía resume cuánto se reparte la variación entre direcciones; D80 cuenta el mínimo de direcciones necesario para explicar el 80 % de esa variación. En las mismas 26 condiciones, entropía conserva una de esas parejas opuestas en el 94,6 % de las oposiciones originales de PR y D80 en el 86,0 %; ese mismo 86,0 % se mantiene con ambas alternativas (190/221). D80 puede dar empates porque devuelve números enteros, dejando esas comparaciones sin resolver. Estas pruebas muestran cuánto depende el orden de la fórmula. Al limitar el análisis a los seis modelos entrenados para similitud, todavía

hay respuestas opuestas en el 71,1 % de las 325 parejas para apertura y el 49,2 % para PR (Tablas S14–S15).

Llevar el punto de referencia a la posición media de la colección cambia muchas comparaciones angulares (Figura 4). Tras restar esa media y devolver cada vector a longitud uno, la oposición persistente baja del 80,6 % al 46,5 % de las 325 parejas (de 262 a 151). Menos de la mitad de las oposiciones originales, el 48,9 % (128/262), conserva al menos una de las mismas parejas de modelos opuestos en las mismas direcciones; la Tabla S20 distingue estos casos de las oposiciones nuevas o cambiadas. Exigir diferencias superiores al 5 % deja solo 11 parejas opuestas en lugar de 96. PR cambia menos: las parejas opuestas pasan de 221 a 211, y el 92,3 % de las oposiciones originales conserva al menos una de las mismas parejas de modelos opuestos y sus direcciones (204/221). Así, una comparación angular que se repite con otros artículos puede seguir dependiendo mucho de dónde se sitúa el punto de referencia común.

También pregunté si la red que enlaza artículos cercanos podía detectar un área dividida en grupos separados. Sería útil si una conexión débil indicara una división entre temas de investigación. Las pruebas no respaldaron esa lectura: las nubes artificiales alargadas y los puntos extremos aislados pueden dar señales de conexión débil sin que existan grupos temáticos. La señal también cambia con el tamaño de muestra y la regla para enlazar vecinos, con alertas de selección en 51 de 260 casos. El Suplemento S6 conserva esta comprobación fallida para evitar que una conexión geométrica débil se interprete como prueba de fragmentación temática.

5. Discusión

5.1. Qué conviene comprobar antes de utilizar un mapa

Los modelos comparten una organización general, pero pueden discrepar sobre artículos cercanos o comparaciones entre áreas. Supongamos que un modelo da mayor apertura angular a A que a B y que esto se repite con otros artículos. Eso muestra estabilidad ante la elección de artículos dentro de ese modelo. Si otro modelo invierte el orden de forma consistente, repetir las selecciones del primero no resuelve el desacuerdo. Por tanto, una afirmación extraída del mapa necesita comprobarse cambiando el modelo además de los artículos.

Esta preocupación continúa trabajos anteriores sobre la dependencia de los mapas respecto al método (Gläser et al., 2017; Boyack and Klavans, 2020) y complementa las evaluaciones con clasificaciones y relaciones externas (González-Márquez et al., 2024; Constantino et al., 2025). Combinar estructura y vecinos también tiene antecedentes (Caspari et al., 2024). La aportación aquí es la comparación controlada entre niveles, decisiones de texto y comparaciones repetidas de áreas, incluidos los casos en que un resultado se mantiene dentro de cada modelo y se invierte entre modelos.

La interpretación sigue dependiendo de lo que describe la medida. Un ángulo mayor significa que los vectores apuntan en direcciones más separadas. Una dimensión lineal efectiva mayor significa que la variación se concentra menos en unas pocas direcciones. Ninguna de las dos cosas demuestra por sí sola más diversidad temática o interdisciplinariedad. Otros trabajos sobre la geometría de los embeddings también advierten contra atribuir un significado amplio a una medida conveniente (Rudman et al., 2022). La comprobación fallida de fragmentación lo muestra de forma concreta: una diferencia que se repite puede seguir respaldando una explicación equivocada.

5.2. Qué cambian las comprobaciones adicionales

Las comprobaciones ayudan a separar lo que se repite de las decisiones que todavía afectan al resultado. Recalcular las medias de las áreas con otros artículos, con 128, 256 o 512 artículos, u omitiendo un área cada vez mantiene el alto acuerdo sobre la organización general. Retirar los registros marcados y los duplicados apenas cambia la coincidencia general de vecinos: dos modelos siguen compartiendo unos ocho artículos de una lista de 25.

Para el texto de entrada, repetir la elección de artículos mantiene la comparación media, pero esa media reúne comportamientos distintos. Dar solo los títulos cambia menos vecinos que cambiar de modelo en algunos modelos, y más en otros. Sustituir la media por CLS o SEP en los cuatro BERT también invierte el orden general. La consecuencia práctica es indicar tanto qué texto recibe el modelo como la regla que convierte sus salidas en un vector; la media no representa todas las configuraciones.

Para la apertura angular, el punto de referencia es otra decisión que importa. Los mismos artículos pueden dar una respuesta distinta sobre qué área está más dispersa al medir los ángulos desde la posición media de la colección y reajustar los vectores. Repetir la elección de artículos no elimina esa dependencia. PR cambia menos con esa transformación, pero sus fórmulas alternativas tampoco conservan todas las comparaciones. Por tanto, afirmar que un área está más dispersa exige identificar la representación y la medida utilizadas, sin dejar implícitas esas decisiones.

Las comprobaciones por disciplina preguntan por qué difieren Medicina y Energía (Suplemento S5). Con la regla principal, los modelos coinciden menos sobre las relaciones entre artículos de Medicina que entre los de Energía, aunque Medicina no siempre tiene el menor acuerdo de vecinos. La diferencia permanece al equilibrar la presencia de especialidades dentro de cada área y al excluir BioBERT y PubMedBERT. Estas comprobaciones no permiten, por tanto, identificar una única explicación. Los modelos con entrenamientos relacionados también dan a veces resultados parecidos, pero esas aparentes familias cambian al modificar la regla que forma el vector del artículo. Con solo diez modelos que difieren en varias cosas a la vez, no se puede aislar como causa el texto de entrenamiento, la arquitectura o el objetivo de entrenamiento.

La comparación temporal aplica los mismos modelos actuales a artículos de períodos antiguos y recientes. El acuerdo de estructura aumenta ligeramente en promedio. El de vecinos baja 0,87 puntos porcentuales si cada grupo ofrece todos sus artículos disponibles, pero sube 0,91 puntos si todos ofrecen 2.048 candidatos. Los grupos antiguos y recientes contienen cantidades distintas de artículos; fijar esa cantidad invierte el sentido del resultado. Esto muestra por qué hay que controlar el número de candidatos antes de interpretar una tendencia temporal. No demuestra que la ciencia haya convergido históricamente.

5.3. Qué queda abierto

La colección exige registros etiquetados como ingleses y con resúmenes utilizables. Reforzar los grupos pequeños de área y período ayuda a compararlos, pero cambia las proporciones. Persisten errores de origen, y la limpieza no certifica cada registro. Repetir las selecciones no puede reparar la falta de cobertura ni hacer que estos resultados representen todo el trabajo científico.

Los diez modelos también fijan un límite. Cuatro no se entrenaron específicamente para comparar documentos. La comprobación con seis modelos ayuda a mostrar que el desacuerdo no se limita a esos cuatro, pero no hace que el conjunto represente todos los modelos de embeddings. Decidir qué dirección tiene mejor respaldo requiere pruebas externas a los embeddings, como relaciones entre artículos evaluadas de forma independiente.

Por último, varias ampliaciones y controles se hicieron después de conocer resultados anteriores. Registrar sus reglas antes de los nuevos cálculos permite seguir las decisiones, sin convertir el estudio completo en un diseño confirmatorio. Un siguiente paso útil sería contrastar una afirmación concreta extraída del mapa con juicios independientes en un área de investigación. Añadir modelos, por sí solo, no resolvería qué significa su geometría compartida o contradictoria.

6. Conclusión

Cambiar el modelo de embeddings puede conservar la organización general de la ciencia y cambiar qué artículos aparecen cerca y qué área tiene representaciones más dispersas. Dar al modelo solo los títulos también puede producir cambios grandes, cuyo tamaño depende del modelo y de la regla que forma el vector del artículo. Repetir el análisis con otros artículos es útil, pero no demuestra que otro modelo o punto de referencia dé la misma respuesta. Antes de usar un mapa para describir una relación, hay que comprobar esa relación con esas decisiones y mostrar cuánto cambia. Estas comparaciones identifican lo que comparten las representaciones probadas; juzgar si la relación describe bien la investigación sigue necesitando evidencia independiente.

Declaraciones

Contribuciones del autor. Alejandro Treny Ortega concibió el proyecto y dirigió la investigación y la preparación del manuscrito como investigador independiente.

Conflictos de interés. El autor declara que no tiene conflictos de interés.

Financiación. Esta investigación no recibió financiación externa.

Disponibilidad de datos y código. El repositorio del proyecto es <https://github.com/aleetreny/Shape-of-Science-Robustness>. Este borrador se acompaña de las tablas utilizadas en las figuras y de las fuentes editables del manuscrito. El corpus fijo, los vectores y los registros locales completos de ejecución no se han depositado en un archivo público persistente. Publicar el código por sí solo no permite reproducir por completo este análisis. El Suplemento S8 detalla el inventario de acceso y los requisitos pendientes; aquí no se afirma que exista un depósito de datos ni un identificador persistente.

Referencias

- Iz Beltagy, Kyle Lo, and Arman Cohan. SciBERT: A pretrained language model for scientific text. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3615–3620, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1371. URL <https://aclanthology.org/D19-1371/>.
- Kevin W. Boyack and Richard Klavans. A comparison of large-scale science models based on textual, direct citation and hybrid relatedness. *Quantitative Science Studies*, 1(4):1570–1585, 2020. ISSN 2641-3337. doi: 10.1162/qss_a_00085.
- Laura Caspari, Kanishka Ghosh Dastidar, Saber Zerhouni, Jelena Mitrovic, and Michael Granitzer. Beyond benchmarks: Evaluating embedding model similarity for retrieval augmented generation systems. arXiv:2407.08275, 2024. URL <https://arxiv.org/abs/2407.08275>. Preprint.
- Arman Cohan, Sergey Feldman, Iz Beltagy, Doug Downey, and Daniel Weld. SPECTER: Document-level representation learning using citation-informed transformers. In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2270–2282, Online, jul 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.207. URL <https://aclanthology.org/2020.acl-main.207/>.
- Isabel Constantino, Sadamori Kojaku, Santo Fortunato, and Yong-Yeol Ahn. Representing the disciplinary structure of physics: A comparative evaluation of graph and text embedding methods. *Quantitative Science Studies*, 6:263–280, 2025. ISSN 2641-3337. doi: 10.1162/qss_a_00349.

- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Jill Burstein, Christy Doran, and Thamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, jun 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423/>.
- Tianyu Gao, Xingcheng Yao, and Danqi Chen. SimCSE: Simple contrastive learning of sentence embeddings. In Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih, editors, *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6894–6910, Online and Punta Cana, Dominican Republic, nov 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.emnlp-main.552. URL <https://aclanthology.org/2021.emnlp-main.552/>.
- Jochen Gläser, Wolfgang Glänzel, and Andrea Scharnhorst. Same data—different results? towards a comparative approach to the identification of thematic structures in science. *Scientometrics*, 111(2):981–998, 2017. ISSN 0138-9130. doi: 10.1007/s11192-017-2296-z.
- Rita González-Márquez, Luca Schmidt, Benjamin M. Schmidt, Philipp Berens, and Dmitry Kobak. The landscape of biomedical research. *Patterns*, 5(6):100968, 2024. ISSN 2666-3899. doi: 10.1016/j.patter.2024.100968.
- Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23, 2022. ISSN 2691-1957. doi: 10.1145/3458754.
- Matthias Held and Theresa Velden. How to interpret algorithmically constructed topical structures of scientific fields? a case study of citation-based mappings of the research specialty of invasion biology. *Quantitative Science Studies*, 3(3):651–671, 2022. ISSN 2641-3337. doi: 10.1162/qss_a_00194.
- Nathaniel Imel and Zachary Hafén. Density, asymmetry and citation dynamics in scientific literature. arXiv:2506.23366, 2025. URL <https://arxiv.org/abs/2506.23366>. Preprint.
- Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529. PMLR, 09–15 Jun 2019. URL <https://proceedings.mlr.press/v97/kornblith19a.html>.
- Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240, 2020. ISSN 1367-4803. doi: 10.1093/bioinformatics/btz682.
- Alex Murphy, Joel Zylberberg, and Alona Fyshe. Correcting biased centered kernel alignment measures in biological and artificial neural networks. arXiv:2405.01012, 2024. URL <https://arxiv.org/abs/2405.01012>. Preprint.
- OpenAlex. Topics. OpenAlex Help Center, 2026. URL <https://help.openalex.org/data/topics/>. Accessed 18 September 2026.

- Malte Ostendorff, Nils Rethmeier, Isabelle Augenstein, Bela Gipp, and Georg Rehm. Neighborhood contrastive learning for scientific document representations with citation embeddings. In Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11670–11688, Abu Dhabi, United Arab Emirates, dec 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.802. URL <https://aclanthology.org/2022.emnlp-main.802/>.
- Jason Priem, Heather Piwowar, and Richard Orr. OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts, 2022. URL <https://arxiv.org/abs/2205.01833v2>. Preprint, version 2.
- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL <https://aclanthology.org/D19-1410/>.
- William Rudman, Nate Gillman, Taylor Rayne, and Carsten Eickhoff. IsoScore: Measuring the uniformity of embedding space utilization. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3325–3339, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.262. URL <https://aclanthology.org/2022.findings-acl.262/>.
- Amanpreet Singh, Mike D’Arcy, Arman Cohan, Doug Downey, and Sergey Feldman. SciRepEval: A multi-format benchmark for scientific document representations. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5548–5566, Singapore, dec 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.338. URL <https://aclanthology.org/2023.emnlp-main.338/>.
- Shruti Singh and Mayank Singh. The inefficiency of language models in scholarly retrieval: An experimental walk-through. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3153–3173, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.249. URL <https://aclanthology.org/2022.findings-acl.249/>.
- Alex H Williams. Equivalence between representational similarity analysis, centered kernel alignment, and canonical correlations analysis. In Marco Fumero, Clementine Domine, Zorah Löhner, Donato Crisostomi, Luca Moschella, and Kimberly Stachenfeld, editors, *Proceedings of UniReps: the Second Edition of the Workshop on Unifying Representations in Neural Models*, volume 285 of *Proceedings of Machine Learning Research*, pages 10–23. PMLR, 14 Dec 2024. URL <https://proceedings.mlr.press/v285/williams24a.html>.
- Alex H Williams, Erin Kunz, Simon Kornblith, and Scott Linderman. Generalized shape metrics on neural representations. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, volume 34, pages 4738–4750. Curran Associates, Inc., 2021. URL https://proceedings.neurips.cc/paper_files/paper/2021/file/252a3dbaeb32e7690242ad3b556e626b-Paper.pdf.