

¿Cuánto depende el mapa de la ciencia del modelo de embeddings?

Alejandro Treny Ortega

Investigador independiente

Versión española para revisión personal • 18 de septiembre de 2026

Resumen

Los embeddings de documentos permiten representar la literatura científica en un mapa, pero las conclusiones que extraemos de su geometría pueden depender del modelo utilizado. Este estudio compara diez modelos sobre un corpus fijo de 500.000 registros de OpenAlex, de 26 áreas y del período 2000–2024. Las muestras emparejadas distinguen el acuerdo entre los centros de las áreas, dentro de cada área y entre los vecinos más próximos; otras comparaciones cambian el texto de entrada y la forma de obtener la representación. Los modelos comparten una estructura general, pero solo conservan, en promedio, el 30,3 % de los 25 vecinos más próximos dentro de los grupos de área y período. Quitar el resumen cambia los vecinos casi tanto como cambiar el modelo; quitar el título tiene un efecto menor. Un análisis exploratorio de las 325 parejas de áreas encuentra ordenaciones opuestas persistentes entre modelos en 262 parejas para la apertura angular y en 221 para la dimensión lineal efectiva. Al exigir una diferencia relativa superior al 5 %, los recuentos bajan a 96 y 177. Las medidas alternativas conservan muchas oposiciones, aunque el centrado y la combinación de las salidas del modelo también importan. Estos resultados describen propiedades geométricas, no la corrección temática. Repetir la selección de artículos puede dar un resultado estable dentro de un modelo cuya dirección siga dependiendo de la representación. Por ello, además del acuerdo general del mapa, los estudios deberían comprobar la comparación concreta que pretenden interpretar.

Palabras clave: mapas de la ciencia; embeddings de documentos; robustez; acuerdo entre vecinos; comparaciones geométricas.

1. Introducción

Los mapas de la ciencia ayudan a explorar las relaciones de un conjunto de publicaciones. Permiten ver qué áreas están próximas, localizar artículos relacionados y comparar disciplinas. Cuando se usan embeddings de texto, estas relaciones parten de un modelo que convierte el texto de cada artículo en un vector, es decir, en una lista de números. Así podemos comparar artículos mediante distancias en un espacio numérico. Estas representaciones se

han utilizado para cartografiar la literatura biomédica y estudiar la estructura disciplinar de la física (González-Márquez et al., 2024; Constantino et al., 2025). Pero el modelo forma parte de cómo se construye el mapa. ¿Cuánto cambiarían sus conclusiones si representáramos los mismos artículos con otro modelo?

El problema general ya es conocido en este ámbito. Gläser et al. (2017) plantearon hasta qué punto una estructura temática reconstruida refleja el conocimiento científico y hasta qué punto refleja el método utilizado para identificarla. Al comparar relaciones basadas en texto, citas y una combinación de ambos, Boyack and Klavans (2020) encontraron diferencias importantes en los artículos que integraban cada grupo, incluso cuando las medidas globales de precisión eran parecidas. Esto importa cuando el mapa se usa para sostener una afirmación concreta: un resumen del acuerdo general puede decir poco sobre si dos métodos sitúan juntos los mismos artículos.

La comparación que presentamos sigue este problema en un corpus fijo de 500.000 publicaciones etiquetadas como inglesas en OpenAlex, publicadas entre 2000 y 2024 y asignadas a 26 áreas amplias, los *Fields*. Diez modelos de embeddings representan los mismos artículos. Los análisis examinan las relaciones entre los centros de las áreas, la organización interna de cada área y los vecinos de cada artículo. Otras muestras emparejadas comprueban qué ocurre al cambiar el texto de entrada o la forma de reducir la salida del modelo a un único vector por artículo. Un análisis geométrico posterior pregunta si las comparaciones entre áreas conservan su dirección cuando cambian tanto el modelo como los artículos seleccionados. El objetivo es identificar qué afirmaciones sobre el mapa se mantienen ante estos cambios.

Los resultados muestran relaciones generales compartidas junto con cambios en los vecinos y en las comparaciones geométricas entre áreas. Algunos modelos sitúan repetidamente un área por encima de otra en una medida geométrica, mientras que otros dan repetidamente el orden contrario. Importa el tamaño de estas diferencias y también cómo responden a las decisiones de procesamiento. Por tanto, repetir una comparación con otros artículos solo comprueba una parte de su fiabilidad. El acuerdo entre representaciones aporta información útil sobre lo que comparten, pero no establece cuál recoge mejor el contenido de los artículos.

2. Antecedentes y preguntas de investigación

2.1. Decisiones de representación en los mapas de la ciencia

Las comparaciones de embeddings de documentos ya abordan varias partes de este problema. Constantino et al. (2025) evaluaron representaciones de texto y de grafos frente a la clasificación jerárquica de artículos de física, incluidas representaciones basadas en títulos y resúmenes. En biomedicina, González-Márquez et al. (2024) compararon modelos y formas de reducir sus salidas antes de seleccionar una representación para un gran mapa de publicaciones. Su evaluación midió hasta qué punto los artículos próximos compartían etiquetas de

área. Ambos estudios dejan claro que una representación debe evaluarse con un propósito y un criterio explícitos.

Incluso dentro de un mismo modelo, su nombre no define por completo cómo se representa el documento. El título y el resumen aportan información diferente. Los modelos también admiten cantidades distintas de texto, y algunos requieren decidir cómo combinar las representaciones de cada fragmento de texto, o *token*, en un solo vector. Esta operación, llamada habitualmente *pooling*, puede usar una media o una posición concreta de la salida. Singh and Singh (2022) examinaron cómo responden los modelos de lenguaje científico a consultas cortas y a modificaciones del texto, y mostraron que cambiar la redacción puede alterar los resultados de búsqueda. Estas decisiones forman parte de la comparación entre los mapas que producen los modelos.

También existen antecedentes directos de comparación conjunta de la geometría de los embeddings y de los vecinos recuperados. Caspari et al. (2024) utilizaron ambos tipos de comparación en conjuntos de datos de búsqueda. Imel and Hafen (2025) examinaron la densidad y la asimetría locales en varias representaciones y disciplinas, en relación con las tasas de citación. Este estudio parte de esos trabajos y pregunta qué conclusiones generales, locales y geométricas se mantienen en un conjunto fijo de modelos, usando los mismos artículos y controles explícitos del texto, de la representación y de los artículos disponibles como vecinos.

2.2. Acuerdo, estabilidad e interpretación

Aquí, acuerdo y estabilidad responden a preguntas distintas. El acuerdo describe lo que comparten dos representaciones al aplicarlas a los mismos artículos. La estabilidad describe si un resultado concreto se mantiene ante un cambio concreto, como seleccionar otros artículos del corpus. Una ordenación de áreas puede ser estable dentro de cada modelo y, aun así, diferir entre modelos. La validez temática requiere pruebas adicionales sobre la relación entre lo representado y la investigación que se pretende describir. En su estudio sobre biología de las invasiones, Held and Velden (2022) mostraron por qué interpretar grupos construidos mediante algoritmos exige atender a los distintos tipos de relación entre artículos que puede combinar un método. Ni repetir el análisis ni obtener consenso entre modelos resuelve por sí solo esa interpretación.

El término *forma* también necesita un objeto concreto. Aquí se refiere a las relaciones en los espacios de embeddings, antes de reducirlos a dos dimensiones. Comparar los centros de las áreas describe una organización general; comparar artículos dentro de un área examina su estructura interna. El acuerdo de vecinos pregunta si los mismos artículos siguen siendo los más próximos a uno dado. Otras dos propiedades describen la apertura angular de los vectores de un área y su dimensión lineal efectiva, que resume cómo se reparte la variación entre distintas direcciones. Una mayor apertura geométrica no implica más diversidad temática, y la dimensión lineal efectiva no cuenta temas. Las comparaciones siguientes mantienen estas

distinciones, de modo que cambiar una propiedad no se interprete como prueba de que ha cambiado todo el mapa.

2.3. Preguntas de investigación y alcance

Tres preguntas organizan el análisis:

- PI1.** ¿Qué relaciones estructurales comparten los modelos de embeddings y cómo varía el acuerdo entre los centros de las áreas, los artículos dentro de cada área y los vecinos locales?
- PI2.** ¿Cuánto cambian la geometría y los vecinos al modificar el texto de entrada o la regla de combinación de las salidas, en comparación con cambiar el modelo?
- PI3.** ¿Qué comparaciones geométricas entre áreas se mantienen, se invierten o quedan sin resolver al cambiar de modelo y de selección de artículos, y qué tamaño tienen las diferencias?

Son preguntas descriptivas sobre el corpus y los modelos seleccionados. La tercera surgió en una ampliación exploratoria posterior a las comparaciones iniciales; la secuencia de comprobaciones se documenta en los métodos y en el suplemento. Las etiquetas de OpenAlex organizan las comparaciones y se conservan con sus errores conocidos. No son una referencia independiente de corrección temática. Por tanto, el estudio evalúa la persistencia de las conclusiones dentro de este diseño, sin ordenar los modelos por su capacidad de recuperar un único mapa correcto de la ciencia.

3. Datos y diseño de la comparación

3.1. Corpus y muestras de análisis

El corpus contiene 500.000 identificadores distintos de trabajos de OpenAlex, recogidos y limpiados hasta el 15 de septiembre de 2026. OpenAlex proporciona los metadatos y los textos (Priem et al., 2022). La consulta a su catálogo principal se limitó a artículos, revisiones y trabajos de congresos publicados entre 2000 y 2024, etiquetados como ingleses, con título no vacío, un resumen reconstruible de al menos 50 palabras y un área principal conocida. Se excluyeron las marcas de retractación y paratexto. Se eliminaron los fallos claros de idioma y contenido; los casos inciertos y las posibles versiones duplicadas se conservaron con marcas. La clasificación por tema principal de cada registro quedó fijada al extraerlo. Estas etiquetas automáticas utilizan texto, citas e información de la revista (OpenAlex, 2026); sirven para organizar el análisis, no como criterio independiente de corrección.

La muestra general de 400.000 registros válidos se obtuvo mediante consultas aleatorias a la API con semillas registradas. Otros 100.000 registros reforzaron los grupos más pequeños de área y período, asignando repetidamente nuevas plazas al grupo menos poblado. Los grupos grandes no se redujeron al tamaño del menor. Los 130 grupos resultantes cubren 26 áreas y cinco períodos: 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Todos contienen al menos 2.165 registros. Las comparaciones globales utilizan la muestra general; las comparaciones entre grupos pueden usar ambas partes. Las medias que dan el mismo peso a cada grupo describen una comparación equilibrada, no las proporciones de la investigación mundial.

La Tabla 1 distingue las muestras utilizadas. La muestra de tres entradas contiene 52.000 artículos, repartidos por igual entre los grupos de área y período, e incluye un piloto anterior de 26.000. Otra muestra distinta de 52.000 artículos compara la entrada habitual de cada modelo con un mismo fragmento literal de texto que cabe en todos sus sistemas de división en tokens. Las comparaciones de grupos con igual tamaño y las búsquedas emparejadas de vecinos controlan fuentes diferentes de variación. En todas las comparaciones se mantienen los mismos artículos entre modelos. Las reglas de extracción y limpieza, los recuentos y las marcas conservadas aparecen en el Suplemento S1.

Tabla 1: Corpus y muestras de análisis.

Muestra	Artículos y representación	Comparación y alcance
Corpus original	500.000 identificadores: 400.000 base + 100.000 de refuerzo. Diez modelos; título y resumen.	26 áreas, cinco períodos. Los resúmenes globales usan la base; el corpus completo no es proporcional a la población.
Tres entradas de texto	52.000 identificadores; 400 por área y período, 2.000 por área. Título, resumen y ambos.	Mismos artículos y candidatos entre modelos. Incluye el piloto de 26.000 artículos.
Fragmento común	Otra muestra distinta de 52.000 identificadores; 400 por área y período.	Contenido habitual y común emparejado; tokenización propia de cada modelo. Distinta de la muestra de tres entradas.
Grupos de igual tamaño	256 artículos por centro; 26 áreas, 217 especialidades o 26 centros de especialidades.	Dentro de grupos: 26 áreas y las mismas 183 especialidades con 128, 256 y 512 artículos. Objetos distintos de los centros.
Búsquedas emparejadas	217 especialidades; 50 consultas fijas por cada una (10.850 en total). Diez selecciones de candidatos.	256 candidatos en cada ámbito, incluidas las 50 consultas. El conjunto del área está condicionado por esas consultas.
Geometría / parejas de áreas	2.000 por área; veinte mitades de 1.000 y cinco selecciones de 2.000.	325 parejas y dos propiedades; 26 condiciones guardadas. Las medidas alternativas tienen distinta cobertura.

Las filas se solapan y no deben sumarse. Períodos: 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Cada comparación usa los mismos identificadores entre modelos. En la búsqueda, cada artículo de consulta se excluye a sí mismo. Los 1.300 artículos de prueba técnica no forman otra muestra científica. Filtros y cuotas completos: Tabla S1.

3.2. Modelos y representaciones del texto

Los diez modelos cubren representaciones de documentos científicos, de frases generales y de palabras en textos biomédicos o científicos (Tabla 2). Es un conjunto fijo elegido por su relevancia para representar publicaciones y por sus distintos enfoques de entrenamiento; no es una muestra aleatoria de modelos ni una clasificación de los sistemas más recientes. Las versiones de los modelos, de los tokenizadores y de los formatos de texto se fijaron antes del cálculo. Cada modelo representó el mismo título y resumen con su formato habitual y su

límite propio de entrada. Se conservó como principal el límite de 256 tokens de MiniLM y se preparó una variante separada de 512 para comprobar su efecto. El recorte habitual afectó al 49,58 % de las entradas de MiniLM y al 20,16 % de las de MPNet.

En BERT, SciBERT, BioBERT y PubMedBERT, el vector principal del documento es la media de los estados de los tokens de la última capa que no son relleno, incluidos los símbolos especiales. Estos modelos no se entrenaron específicamente para medir similitud entre documentos. Como alternativas se usaron el estado de la primera posición (CLS, antes del *pooler*) y el de la última posición sin relleno (SEP). La media se fijó antes de las comparaciones principales y se mantuvo tras los primeros controles; no se eligió para maximizar el acuerdo. Los otros seis modelos usan sus reglas documentadas de representación. Las entradas de solo título y solo resumen utilizan los mismos 52.000 identificadores que la comparación con ambos textos. Al mantener los límites propios de cada modelo, se comparan formas prácticas de utilizarlos, sin aislar la arquitectura de la longitud del texto.

Tabla 2: Modelos de embeddings y reglas principales de representación.

Modelo	Dim.	Tokens	Representación	Referencia
SPECTER	768	512	CLS	(Cohan et al., 2020)
SPECTER2	768	512	CLS + adaptador	(Singh et al., 2023)
SciNCL	768	512	CLS	(Ostendorff et al., 2022)
SciBERT	768	512	Media	(Beltagy et al., 2019)
BERT	768	512	Media	(Devlin et al., 2019)
MPNet	768	384	Media	(Reimers and Gurevych, 2019)
MiniLM	384	256	Media	(Reimers and Gurevych, 2019)
PubMedBERT / BiomedBERT	768	512	Media	(Gu et al., 2022)
BioBERT	768	512	Media	(Lee et al., 2020)
SimCSE	768	512	CLS, antes del pooler	(Gao et al., 2021)

MPNet y MiniLM utilizan all-mpnet-base-v2 y all-MiniLM-L6-v2, respectivamente. Los límites cuentan tokens, incluidos los símbolos especiales. Media: promedio de posiciones sin relleno de la última capa, con símbolos especiales. CLS: primera posición antes del pooler; SPECTER2 añade su adaptador de proximidad. En MPNet/MiniLM, la referencia describe el marco Sentence-BERT, no el entrenamiento exacto de esas versiones. Las reglas alternativas no son modelos adicionales. Versiones, formatos y recorte: Tabla S2.

3.3. Objetos y medidas

Todas las medidas utilizan las dimensiones originales de los embeddings, sin proyectarlos en dos dimensiones. Primero se ajusta cada vector de artículo para que tenga longitud uno. El acuerdo de forma se mide principalmente mediante la alineación lineal centrada de kernels corregida, o CKA, que compara las relaciones entre los mismos artículos (Kornblith et al., 2019; Murphy et al., 2024). Un valor mayor indica más acuerdo. La corrección por tamaño de muestra reduce una fuente conocida de aumento artificial del acuerdo; no convierte el cociente completo en un estimador exactamente insesgado. La alineación de Procrustes y las correlaciones entre los rangos de las distancias aportan comprobaciones con sensibilidades distintas. Sus definiciones y la fórmula de corrección aparecen en el Suplemento S2. Son medidas relacionadas, no votos independientes sobre la validez (Williams et al., 2021; Williams, 2024).

El centro de un grupo es la media de sus vectores de artículos de longitud uno. Comparar centros describe la organización general; comparar dentro de los grupos conserva la variación entre artículos. Las agrupaciones aleatorias mantienen los tamaños y los períodos de publicación, con la misma asignación en todos los modelos. Así se examina cuánto acuerdo entre centros acompaña al promedio cuando no se utilizan las etiquetas observadas.

El acuerdo de vecinos es la fracción de los k artículos más próximos que comparten dos modelos. La elección principal es $k = 25$, con 10 y 50 como controles. Las búsquedas usan similitud del coseno y excluyen el propio artículo consultado. En cada resultado se indica qué candidatos pueden aparecer: todos los artículos de un grupo de área y período, una selección de tamaño igualado, un conjunto emparejado de área y especialidad (*Subfield*) o el corpus general. El cálculo exacto por bloques evita almacenar todas las distancias por parejas. Comprobaciones independientes mediante ordenación completa verifican las listas de vecinos guardadas. Ni la coincidencia ni su ajuste simple por azar eliminan todos los efectos de la composición o el tamaño del conjunto de candidatos.

Otras dos propiedades describen geométricamente cada área. La *apertura angular* es la mediana del ángulo entre vectores de artículos distintos. La *dimensión lineal efectiva* es el cociente de participación de la matriz de covarianza centrada C , $PR = (\text{tr } C)^2 / \text{tr}(C^2)$. Es mayor cuando la variación se reparte entre más direcciones. Como alternativas se utilizan cuantiles angulares, ángulos respecto al centro, el rango efectivo basado en entropía y el número de direcciones que contienen el 80 % de la varianza. Las dos últimas proceden del mismo espectro de covarianza que PR; no aportan una validación temática independiente. También se probaron medidas de conexión de grafos, pero sus contraejemplos con nubes sintéticas impidieron interpretarlas como fragmentación general (Suplemento S6).

3.4. Comparaciones emparejadas y estabilidad

La comparación estricta de vecinos entre área y especialidad fija 50 artículos de consulta en cada una de 217 especialidades. Ambas búsquedas contienen 256 candidatos, incluidas esas mismas 50 consultas, y las mismas cantidades por período. Diez selecciones cambian los 206 candidatos restantes dentro de la especialidad o de su área principal. Por tanto, la búsqueda más amplia está condicionada por las consultas; no es una selección libre de 256 artículos del área. El diseño cubre 10.850 consultas y mantiene constantes las oportunidades de búsqueda mientras cambia su ámbito.

Para las comparaciones geométricas se evalúan todas las parejas no ordenadas de las 26 áreas: 325 por propiedad. Un modelo tiene una dirección persistente solo si esta se mantiene en los 2.000 artículos por área de la selección principal, en veinte medias muestras de 1.000 y en cinco selecciones adicionales de 2.000 del mismo corpus. El acuerdo de los diez requiere la misma dirección persistente en todos los modelos. La oposición exige al menos dos modelos concretos con direcciones opuestas persistentes. Las demás parejas quedan sin resolver, lo que no significa igualdad. La magnitud relativa es $2(B - A)/(A + B)$, donde A y B son los valores de las dos áreas; los mínimos de 0, 1, 5 y 10% comprueban la sensibilidad a diferencias pequeñas.

Las selecciones repetidas miden la sensibilidad dentro del corpus fijo. Son subconjuntos que se solapan, no muestras poblacionales independientes ni intervalos de confianza. Los controles operativos conservan los casos con desplazamientos excesivos de la mediana o rangos de selección demasiado amplios; el suplemento recoge sus reglas y denominadores por separado. Las parejas de modelos comparten modelos y las de áreas comparten áreas, por lo que sus recuentos se tratan de forma descriptiva. Ninguna prueba de significación considera esas parejas como observaciones independientes.

3.5. Secuencia de las comprobaciones

El análisis se desarrolló por etapas. Las comparaciones principales de forma y vecinos precedieron a la ampliación de entradas, las búsquedas emparejadas de especialidades y el atlas de casos concretos. La morfología fue una ampliación exploratoria; después de conocer sus primeros ejemplos se elaboró el resumen de todas las parejas. Las reglas se registraron localmente antes de los nuevos cálculos correspondientes; esto no es un preregistro externo de todo el estudio. Algunos controles, como los centros de grupos aleatorios y la comprobación con una fracción fija de vecinos, se añadieron tras resultados anteriores. El Suplemento S2 recoge esa secuencia. El tiempo, la composición disciplinar, las características de los modelos, los errores de la fuente y las sensibilidades al procesamiento se conservan en los Suplementos S3–S7, incluidas las comprobaciones que limitan la interpretación.

4. Resultados

4.1. Estructura general compartida y variación dentro de las áreas

Los modelos coinciden mucho en la disposición de los centros de los grupos. Con 256 artículos por centro, la CKA corregida media es de 0,939 para las 26 áreas y de 0,911 para 217 especialidades (Figura 1A). Al restringir la segunda comparación a 26 centros de especialidades, el valor es 0,902. Los grupos aleatorios con tamaños y fechas iguales también presentan acuerdo positivo, alrededor de 0,63–0,64, pero no alcanzan el nivel observado. El promedio contribuye, por tanto, al acuerdo, aunque no basta para explicar el asociado a los grupos definidos por estas etiquetas.

Dentro de los grupos, la CKA media se mantiene alrededor de 0,63 en las áreas y 0,64 en las mismas 183 especialidades disponibles en los tres tamaños (Figura 1B). Aumentar los artículos de 128 a 512 apenas cambia estas medias. En esta comparación, usar etiquetas más específicas no reduce el acuerdo de forma general. Sin embargo, los centros y los artículos que los forman son objetos distintos: la diferencia entre los paneles no es un efecto causal aislado de la escala.

Las medidas alternativas respaldan en términos generales el orden del acuerdo entre parejas de modelos. En los 130 grupos originales de área y período, la correlación media de rangos con la CKA corregida es 0,891 para Procrustes y 0,881 para los rangos de distancias. El acuerdo no es completo, y el control original de selección conserva 50 alertas entre 5.850 comparaciones de pareja de modelos y grupo (Tabla S4). Estas limitaciones afectan a comparaciones concretas; una media global no las elimina.

4.2. Acuerdo de vecinos en comparaciones emparejadas

En las búsquedas completas dentro de los grupos de área y período, dos modelos conservan de media el 30,3 % de los 25 vecinos más próximos: unos 7,6 artículos de 25. Esta media da el mismo peso a cada grupo y pareja de modelos. Restringir cada grupo a 2.048 candidatos comunes aumenta la coincidencia al 31,9 %. En la búsqueda separada sobre el corpus general de 400.000 artículos, 13.000 consultas equilibradas conservan el 17,5 %. Este último resultado cambia tanto el ámbito como el número de candidatos, por lo que no demuestra por sí solo que haya menos acuerdo al cruzar fronteras disciplinares.

El experimento emparejado de área y especialidad aborda directamente esa ambigüedad (Figura 2). Con las mismas consultas, fechas y 256 candidatos, el acuerdo es menor en la especialidad en 127 de 217 casos y mayor en 90. La diferencia media es pequeña: $-1,35$ puntos porcentuales. Con 50 vecinos, el reparto pasa a 109 casos con menos acuerdo y 108 con más. Una búsqueda más estrecha puede conservar más vecinos o menos, según el grupo




Figura 1: Acuerdo entre los centros de los grupos y dentro de los grupos. (A) CKA corregida media de las parejas fijas de modelos y las comparaciones de centros guardadas; cada centro contiene 256 artículos. Los grupos aleatorios conservan tamaños y fechas. La condición de 26 especialidades controla el número de centros. (B) Acuerdo interno con tres cantidades de artículos, para 26 áreas y las mismas 183 especialidades válidas. Los puntos y las etiquetas muestran medias; las líneas abarcan los percentiles 2,5–97,5 entre comparaciones de grupo y pareja de modelos (1.170 para áreas; 8.235 para especialidades). Son rangos descriptivos, no intervalos de confianza; las parejas de modelos no son independientes. Todos los ejes de CKA van de 0 a 1. Los paneles comparan objetos distintos, por lo que su diferencia no es un efecto causal estimado.

y el número de vecinos elegido. No hay una pérdida universal de acuerdo al pasar de área a especialidad.

Aun así, el acuerdo de forma y el de vecinos varían juntos. Entre las 45 medias por pareja de modelos del análisis original, su correlación descriptiva de rangos es 0,920. Informar de ambos resulta útil porque describen consecuencias distintas de elegir una representación, no porque sean dimensiones independientes de fiabilidad. CKA compara relaciones distribuidas por el conjunto; una lista de vecinos indica qué artículos concretos encontraría el lector.

El atlas permite examinar esas diferencias locales. Sus ejemplos de especialidades se seleccionan mediante una regla registrada de persistencia en 27 combinaciones de tamaño, regla de representación y número de vecinos. Los ejemplos de artículos muestran después relaciones que se mantienen entre modelos y otras cuya inclusión cambia mucho (Suplemento S4). Algunos casos extremos revelan problemas de la fuente: un libro de historia aparece en Física, un registro sobre infección aparece en Ciencia Política y un anuncio sigue en el corpus. La comparación con los registros originales confirma que son problemas de la fuente o de

clasificación, no filas de embeddings mal alineadas. Los ejemplos son exploratorios y se han seleccionado deliberadamente; no estiman la frecuencia de esos errores ni la precisión de las relaciones.




Figura 2: Acuerdo de vecinos en búsquedas emparejadas de área y especialidad. Cada punto es una de las 217 especialidades, con el promedio de las parejas de modelos y diez selecciones de candidatos. Ambos ámbitos contienen las mismas 50 consultas fijas entre 256 candidatos y fechas igualadas; se excluye el propio artículo. El conjunto del área está condicionado por estas consultas. Los puntos por encima de la diagonal tienen más coincidencia en la búsqueda estrecha; los situados por debajo tienen menos. La dispersión describe diferencias entre grupos, no intervalos de confianza.

4.3. Texto de entrada y decisiones de representación

Quitar el resumen puede cambiar la representación casi tanto como cambiar el modelo. En los mismos 52.000 artículos, el cambio medio de forma, medido como uno menos la CKA corregida, es 0,370 al cambiar de modelo y 0,366 al mantenerlo pero usar solo el título. Las fracciones de vecinos sustituidos son, respectivamente, 68,8 % y 70,7 % (Figura 3). Que estas medias estén próximas no demuestra equivalencia. Muestra que, dentro de este diseño, una

decisión aparentemente simple sobre el texto puede tener una magnitud comparable a la elección del modelo.




Figura 3: Cambios asociados al modelo y al texto de entrada. Los mismos 52.000 identificadores aportan 2.000 candidatos por área. La entrada de referencia es título y resumen: quitar el resumen deja el título, y quitar el título deja el resumen. (A) Uno menos la CKA corregida. (B) Fracción de los 25 vecinos sustituidos. Cada punto es la media de un área sobre el conjunto fijo de modelos. Las cajas muestran la mediana y el rango intercuartílico, con bigotes de 1,5 veces ese rango; se muestran todas las áreas. No son intervalos de confianza. Se mantienen los límites propios de texto.

Quitar solo el título cambia menos. Las entradas de solo resumen tienen un cambio medio de forma de 0,027, pero sustituyen el 22,1 % de los 25 vecinos. Por tanto, un cambio pequeño en la geometría general puede alterar los artículos recuperados localmente. También hay diferencias importantes entre modelos: al usar solo el título, la sustitución de vecinos va del 51,7 % en MPNet al 84,2 % en SciBERT (Tabla S5). Una única media conjunta ocultaría esas diferencias.

La regla de combinación de las salidas también afecta a la propia comparación. Con la media como representación principal, quitar el título tiene un efecto relativamente pequeño, mientras que quitar el resumen supera ligeramente al cambio de modelo en la sustitución media de vecinos. Al pasar los cuatro BERT de palabras a CLS o SEP se invierte esta última ordenación media. Esos escenarios también cambian la referencia entre modelos, porque cuatro representaciones cambian a la vez. No aíslan un efecto puro del *pooling*, ni justifican elegir la regla que produzca más acuerdo.

La muestra ampliada reduce la sensibilidad a la selección de artículos. Con 100 selecciones comparables en cada tamaño, el control del contraste de forma pasa de 72 alertas entre 520 contrastes de modelo, área y entrada con 26.000 artículos a cinco con 52.000. La comprobación anterior de 20 selecciones da 31 y cuatro, respectivamente (Figura S1). Se conservan ambos registros. Superar este control no significa que el contraste sea distinto de cero ni certifica todos los resultados de vecinos o variantes de representación. Los controles de fragmento común y longitud de MiniLM también distinguen la exposición desigual al texto de un error de programación: el límite original de MiniLM era su ajuste documentado, no un fallo de implementación.

4.4. Persistencia e inversión de las comparaciones geométricas entre áreas

La ampliación geométrica plantea una pregunta más concreta que si dos mapas se parecen: ¿cambiar de modelo invierte una comparación entre dos áreas? Cambiar solo la selección de artículos suele conservar la apertura y la dimensión lineal efectiva medidas. La apertura angular no produce alertas en los 260 casos de modelo y área, ni en las medias muestras ni en las selecciones de igual tamaño. La dimensión efectiva conserva cuatro alertas en las medias muestras, aunque ninguna aparece en las cinco selecciones de igual tamaño (Tabla S12). Esos cuatro casos siguen formando parte de la evidencia.

La estabilidad dentro de un modelo no asegura acuerdo entre modelos. Entre las 325 parejas de áreas, la apertura angular presenta una dirección común persistente en los diez modelos para 42 parejas, oposición persistente para 262 y un resultado sin resolver para 21. En la dimensión lineal efectiva, los recuentos son 54, 221 y 50 (Figura 4). La oposición significa que al menos dos modelos concretos mantienen direcciones contrarias en las 26 condiciones de selección guardadas. No exige que discrepen todos los modelos, y las parejas sin resolver pueden contener acuerdo parcial.

Muchas diferencias angulares son pequeñas. Exigir que cada dirección opuesta supere una diferencia relativa simétrica del 5 % reduce la oposición angular a 96 parejas; al 10 % quedan 19. La dimensión lineal efectiva conserva 177 y 126 oposiciones en esos umbrales. Por tanto, los totales basados solo en la dirección no deben leerse como desacuerdos del mismo tamaño. El mínimo es una elección explícita para comprobar sensibilidad, no una definición universal de diferencia científicamente relevante. La Figura 4 conserva las 325 parejas en cada fila para que siga visible el aumento de la categoría sin resolver.

Las medidas alternativas conservan buena parte del patrón. Al exigir que los mismos modelos opuestos mantengan sus direcciones en las alternativas angulares, permanecen 225 de las 262 oposiciones originales. Las alternativas espectrales conservan 196 de 221. Su cobertura es distinta: las alternativas angulares tienen las 26 condiciones de selección, mientras que el rango basado en entropía y el recuento del 80 % de varianza están disponibles para tres. Estas




Figura 4: Persistencia, oposición y magnitud de las comparaciones entre áreas. Cada fila contiene las 325 parejas para una propiedad y diez modelos. La dirección de un modelo debe mantenerse en la selección principal, veinte medias muestras y cinco selecciones adicionales de igual tamaño del mismo corpus. El acuerdo de los diez requiere una dirección común persistente; la oposición exige al menos dos modelos fijos con direcciones contrarias persistentes. Las demás parejas quedan sin resolver. La magnitud utiliza $2(B - A)/(A + B)$. Los cuatro mínimos son cortes operativos, no umbrales de significación o precisión. Las 26 condiciones se solapan; los controles puntuales se presentan por separado.

alternativas también comparten buena parte de su construcción matemática. Su acuerdo respalda una descripción geométrica, sin convertirla en una medida de diversidad temática.

El resultado no se limita a los cuatro BERT de palabras. Al restringir el conjunto a SPECTER, SPECTER2, SciNCL, MPNet, MiniLM y SimCSE, siguen apareciendo 231 oposiciones angulares y 160 de dimensión efectiva con mínimo cero. Un conjunto menor tiene menos oportunidades de contener modelos opuestos, por lo que el cambio en los recuentos no aísla un efecto del objetivo de entrenamiento. Las Tablas S14–S15 incluyen las omisiones de cada modelo y todas las clasificaciones de parejas.

Las decisiones de procesamiento añaden otro límite. Después de restar el centro global y volver a normalizar, la misma pareja original de modelos opuestos y sus direcciones se conservan en 145 de 262 oposiciones angulares y en 218 de 221 oposiciones de dimensión efectiva,

dentro del control puntual emparejado. La ordenación angular depende, por tanto, más de esa elección. Cambiar la regla de combinación también puede invertir comparaciones (Tabla S16). Son controles puntuales con referencias emparejadas, no otra serie de confirmaciones con 26 repeticiones. Las conclusiones se refieren a representaciones definidas explícitamente, no a propiedades que deban sobrevivir a cualquier transformación.

Las medidas de conexión fueron menos defendibles. Bajo algunas reglas, las nubes alargadas y los puntos extremos aislados podían parecer fragmentación, y cambiar el tamaño de muestra o el número de vecinos alteraba mucho el resultado. Solo el control de selecciones de igual tamaño conservó 51 alertas de conexión entre 260 casos. Por ello, la conexión se presenta junto con las comprobaciones fallidas de su interpretación en el Suplemento S6 y no se utiliza para afirmar que un área contiene más grupos temáticos separados.

5. Discusión

5.1. Del acuerdo entre mapas a la persistencia de una afirmación

Un modelo puede reproducir la organización general de un corpus y, al mismo tiempo, cambiar una comparación concreta dentro de él. Los resultados de centros muestran una estructura compartida importante, por encima de la referencia de grupos aleatorios. Los resultados por parejas de áreas muestran por qué eso no basta para interpretar ordenaciones geométricas. Incluso después de cambiar repetidamente los artículos, un modelo puede dar de forma consistente el orden contrario a otro. La pregunta útil sobre robustez debe ligarse a la afirmación que se quiere sostener: ¿qué relación, conjunto de vecinos o comparación entre áreas necesita mantenerse al cambiar la representación?

Esto amplía un problema comparativo ya reconocido en los mapas de la ciencia (Gläser et al., 2017; Boyack and Klavans, 2020). Evaluar frente a una clasificación, como hacen Constantino et al. (2025), examina cuánto sirve una representación para un criterio externo concreto. Comparar alineación geométrica y recuperación, como en Caspari et al. (2024), establece qué relaciones comparten los modelos. La aportación de este trabajo es conectar esos niveles con la persistencia y la magnitud de comparaciones concretas entre áreas, usando artículos emparejados. No se basa en introducir medidas de acuerdo ni en afirmar que los estudios anteriores ignoraron la elección de representación.

La apertura angular y la dimensión lineal efectiva son útiles precisamente cuando se mantiene acotado su significado. Un ángulo mide separación geométrica; PR mide cómo se reparte la varianza entre direcciones lineales. Interpretarlas como interdisciplinariedad o diversidad semántica requeriría pruebas adicionales sobre el contenido. Algo parecido ocurre con las afirmaciones sobre isotropía de embeddings, es decir, sobre la uniformidad de sus direcciones (Rudman et al., 2022). La interpretación descartada de fragmentación muestra el coste de

saltarse ese paso: una medida puede distinguir nubes de forma fiable y, aun así, no identificar la propiedad sustantiva que su nombre sugiere.

5.2. Implicaciones para comparar mapas de la ciencia

Un análisis práctico debería fijar la afirmación, la entrada y las oportunidades de comparación antes de elegir cómo resumir la robustez. En la búsqueda de documentos, los candidatos y el número de vecinos forman parte de la pregunta. En la geometría de las áreas importan la regla de representación, el equilibrio de artículos y la diferencia mínima. El experimento de entrada también deja una exigencia sencilla de documentación: no basta con nombrar el modelo. Hay que registrar además si usa título o resumen, su límite de tokens y su regla de combinación.

Las comparaciones adicionales desaconsejan explicaciones simples del acuerdo. Medicina tiene menos acuerdo de forma que Energía, pero no ocupa de manera consistente la posición más baja en acuerdo de vecinos. Equilibrar las especialidades y excluir BioBERT y PubMedBERT mantiene la diferencia entre Medicina y Energía; ninguno de esos factores aporta una causa única (Suplemento S5). Las familias aparentes de modelos también cambian con la regla de representación. Los diez modelos difieren en varios aspectos ligados entre sí, por lo que sus semejanzas no aíslan la influencia del corpus o del objetivo de entrenamiento.

El tiempo ofrece otro ejemplo de por qué importa el diseño de comparación. El acuerdo medio de forma aumenta ligeramente entre el primer y el último período. El acuerdo medio de vecinos baja 0,87 puntos porcentuales con todos los candidatos, pero sube 0,91 puntos con 2.048 candidatos por grupo. El signo depende, por tanto, de las oportunidades de búsqueda. Estos modelos representan publicaciones antiguas y recientes usando sus parámetros actuales; no reconstruyen el conocimiento disponible cuando se publicaron. El resultado no aporta evidencia causal de que la ciencia en sí haya convergido.

5.3. Límites y siguiente validación

El corpus cubre registros seleccionados de OpenAlex con resúmenes utilizables y texto predominantemente inglés. La muestra de refuerzo, las muestras equilibradas y los resúmenes con pesos iguales sirven para comparar áreas; no estiman la distribución mundial de la investigación. Persisten errores de clasificación y contenido, como muestra el atlas. Los controles de calidad eliminan problemas concretos, pero no demuestran que cada artículo esté bien etiquetado. Las selecciones locales y las versiones fijas de los modelos permiten auditar la comparación, aunque repetir el muestreo dentro de este corpus no elimina el sesgo de cobertura.

El conjunto fijo de modelos también tiene límites. Sus miembros comparten arquitecturas, fuentes de entrenamiento y objetivos, y varios no están especializados en similitud. Los con-

troles con seis modelos orientados a similitud y con reglas alternativas de representación acotan algunos problemas, pero no hacen que el conjunto represente todos los modelos posibles. La oposición persistente establece dependencia del modelo dentro de ese conjunto; no dice cuál de las dos direcciones es correcta en términos de contenido.

Por último, la ampliación geométrica y el resumen de todas las parejas se hicieron después de resultados anteriores. La secuencia registrada y las tablas completas permiten examinar esas decisiones, pero no convierten la exploración en confirmación. Un siguiente estudio acotado podría comprobar una comparación relevante frente a relaciones entre artículos evaluadas de forma independiente o una pregunta concreta de una disciplina. Así se abordaría la interpretación temática que aquí queda abierta, en lugar de añadir simplemente más modelos al mismo cálculo de acuerdo.

6. Conclusión

Los diez modelos comparten una estructura general, pero ese acuerdo no garantiza que conserven los mismos vecinos ni el mismo orden de las áreas en una propiedad geométrica. Elegir el texto de entrada puede importar tanto como elegir el modelo, y una comparación puede mantenerse al repetir la selección de artículos mientras se invierte entre modelos. Por tanto, comprobar la afirmación científica que se quiere sostener en distintas representaciones informa más que ofrecer una única medida global de similitud. La apertura angular y la dimensión lineal efectiva permiten hacerlo cuando sus definiciones, magnitudes y sensibilidades al procesamiento quedan explícitas. Describen la geometría que producen los modelos; interpretar esa geometría como una propiedad del conocimiento científico requiere validación adicional.

Declaraciones

Contribuciones del autor. Alejandro Treny Ortega concibió el proyecto y dirigió la investigación y la preparación del manuscrito como investigador independiente. La ayuda computacional y editorial se declara a continuación.

Conflictos de interés. El autor declara que no tiene conflictos de interés.

Financiación. Esta investigación no recibió financiación externa.

Disponibilidad de datos y código. El repositorio del proyecto es <https://github.com/aleetreny/Shape-of-Science-Robustness>. Este borrador se acompaña de las tablas utilizadas en las figuras y de las fuentes editables del manuscrito. El corpus fijo, los vectores y los registros locales completos de ejecución no se han depositado en un archivo público persistente. Publicar el código por sí solo no permite reproducir por completo este análisis.

El Suplemento S8 detalla el inventario de acceso y los requisitos pendientes; aquí no se afirma que exista un depósito de datos ni un identificador persistente.

Uso de herramientas de inteligencia artificial. OpenAI Codex ayudó con las búsquedas bibliográficas, el desarrollo de software y los análisis, la visualización y la redacción y edición del manuscrito. El autor es responsable del contenido.

Referencias

- Iz Beltagy, Kyle Lo, and Arman Cohan. SciBERT: A pretrained language model for scientific text. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3615–3620, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1371. URL <https://aclanthology.org/D19-1371/>.
- Kevin W. Boyack and Richard Klavans. A comparison of large-scale science models based on textual, direct citation and hybrid relatedness. *Quantitative Science Studies*, 1(4):1570–1585, 2020. ISSN 2641-3337. doi: 10.1162/qss_a_00085.
- Laura Caspari, Kanishka Ghosh Dastidar, Saber Zerhoubi, Jelena Mitrovic, and Michael Granitzer. Beyond benchmarks: Evaluating embedding model similarity for retrieval augmented generation systems. arXiv:2407.08275, 2024. URL <https://arxiv.org/abs/2407.08275>. Preprint.
- Arman Cohan, Sergey Feldman, Iz Beltagy, Doug Downey, and Daniel Weld. SPECTER: Document-level representation learning using citation-informed transformers. In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2270–2282, Online, jul 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.207. URL <https://aclanthology.org/2020.acl-main.207/>.
- Isabel Constantino, Sadamori Kojaku, Santo Fortunato, and Yong-Yeol Ahn. Representing the disciplinary structure of physics: A comparative evaluation of graph and text embedding methods. *Quantitative Science Studies*, 6:263–280, 2025. ISSN 2641-3337. doi: 10.1162/qss_a_00349.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Jill Burstein, Christy Doran, and Thamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, jun 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423/>.
- Tianyu Gao, Xingcheng Yao, and Danqi Chen. SimCSE: Simple contrastive learning of sentence embeddings. In Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih, editors, *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6894–6910, Online and Punta Cana, Dominican Republic, nov 2021.

- Association for Computational Linguistics. doi: 10.18653/v1/2021.emnlp-main.552. URL <https://aclanthology.org/2021.emnlp-main.552/>.
- Jochen Gläser, Wolfgang Glänzel, and Andrea Scharnhorst. Same data—different results? towards a comparative approach to the identification of thematic structures in science. *Scientometrics*, 111(2):981–998, 2017. ISSN 0138-9130. doi: 10.1007/s11192-017-2296-z.
- Rita González-Márquez, Luca Schmidt, Benjamin M. Schmidt, Philipp Berens, and Dmitry Kobak. The landscape of biomedical research. *Patterns*, 5(6):100968, 2024. ISSN 2666-3899. doi: 10.1016/j.patter.2024.100968.
- Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23, 2022. ISSN 2691-1957. doi: 10.1145/3458754.
- Matthias Held and Theresa Velden. How to interpret algorithmically constructed topical structures of scientific fields? a case study of citation-based mappings of the research specialty of invasion biology. *Quantitative Science Studies*, 3(3):651–671, 2022. ISSN 2641-3337. doi: 10.1162/qss__a_00194.
- Nathaniel Imel and Zachary Hafen. Density, asymmetry and citation dynamics in scientific literature. arXiv:2506.23366, 2025. URL <https://arxiv.org/abs/2506.23366>. Preprint.
- Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529. PMLR, 09–15 Jun 2019. URL <https://proceedings.mlr.press/v97/kornblith19a.html>.
- Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240, 2020. ISSN 1367-4803. doi: 10.1093/bioinformatics/btz682.
- Alex Murphy, Joel Zylberberg, and Alona Fyshe. Correcting biased centered kernel alignment measures in biological and artificial neural networks. arXiv:2405.01012, 2024. URL <https://arxiv.org/abs/2405.01012>. Preprint.
- OpenAlex. Topics. OpenAlex Help Center, 2026. URL <https://help.openalex.org/data/topics/>. Accessed 18 September 2026.
- Malte Ostendorff, Nils Rethmeier, Isabelle Augenstein, Bela Gipp, and Georg Rehm. Neighborhood contrastive learning for scientific document representations with citation embeddings. In Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11670–11688, Abu Dhabi, United Arab Emirates, dec 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.802. URL <https://aclanthology.org/2022.emnlp-main.802/>.
- Jason Priem, Heather Piwowar, and Richard Orr. OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts, 2022. URL <https://arxiv.org/abs/2205.01833v2>.

Preprint, version 2.

- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL <https://aclanthology.org/D19-1410/>.
- William Rudman, Nate Gillman, Taylor Rayne, and Carsten Eickhoff. IsoScore: Measuring the uniformity of embedding space utilization. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3325–3339, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.262. URL <https://aclanthology.org/2022.findings-acl.262/>.
- Amanpreet Singh, Mike D’Arcy, Arman Cohan, Doug Downey, and Sergey Feldman. SciRepeval: A multi-format benchmark for scientific document representations. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5548–5566, Singapore, dec 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.338. URL <https://aclanthology.org/2023.emnlp-main.338/>.
- Shruti Singh and Mayank Singh. The inefficiency of language models in scholarly retrieval: An experimental walk-through. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3153–3173, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.249. URL <https://aclanthology.org/2022.findings-acl.249/>.
- Alex H Williams. Equivalence between representational similarity analysis, centered kernel alignment, and canonical correlations analysis. In Marco Fumero, Clementine Domine, Zorah Löhner, Donato Crisostomi, Luca Moschella, and Kimberly Stachenfeld, editors, *Proceedings of UniReps: the Second Edition of the Workshop on Unifying Representations in Neural Models*, volume 285 of *Proceedings of Machine Learning Research*, pages 10–23. PMLR, 14 Dec 2024. URL <https://proceedings.mlr.press/v285/williams24a.html>.
- Alex H Williams, Erin Kunz, Simon Kornblith, and Scott Linderman. Generalized shape metrics on neural representations. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, volume 34, pages 4738–4750. Curran Associates, Inc., 2021. URL https://proceedings.neurips.cc/paper_files/paper/2021/file/252a3dbaeb32e7690242ad3b556e626b-Paper.pdf.