

¿Cuánto depende el mapa de la ciencia del modelo de embeddings?

Alejandro Treny Ortega

Investigador independiente

Versión española para revisión personal • 20 de septiembre de 2026

Resumen

Los mapas de la ciencia usan las relaciones entre artículos para describir cómo se organiza la investigación. Cuando esas relaciones proceden de embeddings de texto, un modelo convierte cada artículo en una lista de números. ¿Otro modelo daría la misma imagen? Comparo diez modelos con una misma colección de 500.000 registros de OpenAlex, de 26 áreas y del período 2000–2024. Examino la organización general, qué artículos quedan más cerca unos de otros y cómo se distribuyen dentro de cada área. Los modelos comparten una organización general, pero, al buscar dentro de la misma área y período, dos modelos conservan en promedio unos ocho de los mismos 25 artículos más cercanos. Usar solo el título, en lugar del título y el resumen, cambia esos vecinos casi tanto como cambiar el modelo. En una exploración posterior, los modelos también discrepan sobre cuál de dos áreas tiene representaciones más dispersas. Esas respuestas opuestas pueden repetirse al seleccionar otros artículos, aunque muchas diferencias son pequeñas y las decisiones de procesamiento importan. Repetir un resultado con otros artículos no garantiza, por tanto, que otro modelo lo respalde. Los resultados identifican dependencia de la representación; no establecen qué modelo describe mejor la investigación.

Palabras clave: mapas de la ciencia; embeddings de documentos; robustez; acuerdo entre vecinos; comparaciones geométricas.

1. Introducción

Un mapa de la ciencia puede ayudar a encontrar artículos relacionados o a comparar áreas de investigación. Su utilidad depende de las relaciones que muestra. Si dos modelos colocan artículos distintos cerca de un mismo trabajo, el lector puede acabar siguiendo caminos diferentes por la literatura. Si discrepan sobre lo dispersos que están los artículos de un área, también pueden llevar a describirla de formas distintas. En este estudio pregunto cuánto cambia todo esto cuando mantenemos los artículos y cambiamos únicamente su representación.

Los embeddings de texto son una forma de construir estos mapas. Un modelo lee el texto de un artículo y lo convierte en una lista de números, llamada vector. Esos números le dan una posición en un espacio donde podemos calcular distancias. Los artículos que quedan cerca se consideran relacionados. Este procedimiento se ha usado para cartografiar la literatura biomédica y la estructura de la física (González-Márquez et al., 2024; Constantino et al., 2025). Pero la posición la produce el modelo. No es una relación observada con independencia de él.

Esta preocupación tiene una trayectoria en los estudios de mapas de la ciencia. Gläser et al. (2017) preguntaron cuánto refleja una estructura temática reconstruida el conocimiento científico y cuánto refleja el método utilizado para recuperarla. Boyack and Klavans (2020) encontraron que distintos métodos podían lograr una precisión global parecida y, al mismo tiempo, asignar artículos diferentes a cada grupo. Por tanto, una puntuación general puede dejar sin respuesta una pregunta importante: ¿otro método respaldaría la comparación concreta que quiere hacer el lector?

Abordo esta pregunta con diez modelos y una colección fija de 500.000 publicaciones. Primero comparo la organización general de las áreas y los artículos que quedan cerca unos de otros. Después examino si cambiar el texto que recibe un modelo importa tanto como cambiar el propio modelo. Una exploración posterior estudia comparaciones concretas entre áreas: ¿todos los modelos señalan la misma área como la que tiene representaciones más dispersas? Repetir estas comparaciones con otros artículos permite distinguir la dependencia de los artículos elegidos de la dependencia del modelo.

2. Antecedentes y preguntas de investigación

2.1. Qué aportan las comparaciones anteriores

Los trabajos previos evalúan los embeddings científicos con varios criterios útiles. Constantino et al. (2025) los comparan con clasificaciones disciplinares de física; González-Márquez et al. (2024) examinan artículos biomédicos relacionados y sus etiquetas. Estas comprobaciones preguntan si una representación coincide con información sobre la literatura. Este estudio plantea una pregunta complementaria: ¿qué relaciones se mantienen cuando cambia la representación?

Elegir el modelo es solo una de las decisiones. Un título y un resumen completo contienen cantidades distintas de información. Los modelos también leen textos de distinta longitud y combinan sus salidas de formas diferentes. Singh and Singh (2022) muestran que la búsqueda académica puede ser sensible a cómo se redactan las consultas cortas. Por eso, el texto que recibe el modelo forma parte de la comparación y no debería quedar sin especificar.

Comparar tanto la estructura general como los artículos cercanos tampoco es nuevo. Caspari et al. (2024) combinan comparaciones geométricas y de vecinos, mientras que Imel and Hafen (2025) estudian propiedades de los espacios de embeddings científicos junto con relaciones de citación. Parto de estos enfoques y mantengo los mismos artículos entre modelos, cambio de forma explícita el texto y las decisiones de procesamiento, y compruebo comparaciones concretas entre áreas con otras selecciones de artículos y otras medidas.

2.2. Qué permite afirmar el acuerdo

Conviene separar dos ideas. El *acuerdo* indica si distintos modelos dan resultados parecidos para los mismos artículos. La *estabilidad ante la selección* indica si un resultado se repite al utilizar otros artículos de la colección. Una comparación puede ser estable dentro de cada modelo y, aun así, dar respuestas opuestas entre modelos.

Ninguna de estas dos propiedades demuestra que la respuesta sea correcta sobre la investigación. Los modelos pueden compartir un error, y un patrón que se repite puede ser difícil de interpretar. En un estudio de biología de invasiones, Held and Velden (2022) muestran por qué las agrupaciones temáticas necesitan una interpretación que vaya más allá de las comprobaciones numéricas. Aquí, el acuerdo indica que un resultado se mantiene al cambiar de modelo; no demuestra que describa correctamente los temas.

Comparo las representaciones numéricas antes de reducirlas a un dibujo en una página. Cada vector tiene cientos de coordenadas. Pasarlo a un gráfico de dos dimensiones añadiría otra transformación que podría alterar las distancias aparentes. En este artículo, la forma del mapa se refiere a las relaciones en ese espacio original.

2.3. Preguntas de investigación

PI1. Al cambiar de modelo, ¿qué se mantiene de la organización de las áreas y de los artículos que quedan cerca unos de otros?

PI2. ¿Cuánto importa cambiar el texto de entrada, o la regla para obtener un único vector por artículo, en comparación con cambiar de modelo?

PI3. ¿Los modelos coinciden sobre qué área tiene representaciones más dispersas o variación repartida entre más direcciones? ¿Se repiten estas comparaciones con otros artículos?

La tercera pregunta se añadió después de las comparaciones iniciales y es exploratoria. Las tres se refieren a una colección y un conjunto de modelos concretos. No buscan elegir un modelo ganador ni estimar la estructura de toda la literatura científica.

3. Datos y métodos

3.1. Una colección, varias preguntas

La colección de partida contiene 500.000 identificadores distintos de trabajos de OpenAlex, descargados y limpiados hasta el 15 de septiembre de 2026 (Priem et al., 2022). Los registros estaban etiquetados como artículos, revisiones o trabajos de congreso en inglés, publicados entre 2000 y 2024. Cada uno debía tener título, un resumen reconstruido de al menos 50 palabras y un área principal. Se excluyeron retractaciones, material accesorio y fallos claros de contenido. Los casos menos seguros y las posibles versiones duplicadas se conservaron con marcas de revisión, sin darlos por resueltos. El Suplemento S1 recoge las reglas y los recuentos.

OpenAlex asigna los artículos a áreas amplias, llamadas *Fields*, y a categorías más estrechas, llamadas *Subfields*, a partir de información del texto, las citas y las revistas (OpenAlex, 2026). Aquí las denomino áreas y especialidades, respectivamente. Las 26 áreas son las unidades principales de comparación. Estas etiquetas de la base de datos permiten organizar el análisis; no son descripciones de cada artículo verificadas de forma independiente.

La colección tiene dos partes. Las peticiones aleatorias a la API, con semillas registradas, proporcionaron 400.000 registros que cumplieran los requisitos. Otros 100.000 reforzaron los grupos con pocos artículos de una misma área y período de cinco años. Los cinco períodos son 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Así se obtienen 130 grupos de área y período, con al menos 2.165 artículos cada uno. Las búsquedas generales utilizan los 400.000 registros iniciales. Las comparaciones por área utilizan ambas partes. Ni la colección reforzada ni una media que da el mismo peso a cada área estiman las proporciones de la producción científica mundial.

No todas las preguntas requieren volver a procesar los 500.000 artículos. Para comparar el título, el resumen y ambos juntos, utilizo los mismos 52.000 artículos: 2.000 por área, con 400 de cada período. Esta selección incluye los 26.000 usados en una primera prueba más pequeña de esa misma comparación. El análisis posterior de la dispersión dentro de las áreas reutiliza estos 52.000 artículos. Otro conjunto distinto de 52.000 sirve para una pregunta diferente: comprobar qué cambia cuando todos los modelos leen el mismo fragmento de texto. La Tabla 1 distingue estos usos. En cada comparación entre modelos, ambos reciben los mismos identificadores de artículos.

Tabla 1: Qué pregunta hace cada comparación y qué artículos utiliza.

Propósito	Artículos utilizados	Qué se compara
Preparar la colección de partida	500.000: 400.000 registros generales y 100.000 para reforzar grupos pequeños de área y período.	Diez modelos representan cada título y resumen.
Comparar el mapa general y los artículos cercanos	Selecciones de esa colección; 256 artículos por centro de grupo. Cada resultado indica sus candidatos de búsqueda.	Centros de áreas, artículos dentro de grupos y listas de artículos cercanos.
Cambiar el texto de entrada	52.000: 2.000 por área, 400 por período. Incluye la primera prueba de 26.000.	Solo título, solo resumen y ambos, en los mismos artículos.
Dar a todos el mismo fragmento	Otro conjunto de 52.000, con 400 por área y período.	Entrada habitual frente a un fragmento común que cabe en todos los modelos.
Comparar la dispersión de las áreas	Los mismos 52.000 del experimento de texto; otras selecciones comprueban la estabilidad.	Las 325 comparaciones de dos áreas, para dos propiedades geométricas.
Cambiar el alcance de la búsqueda	10.850 artículos de partida: 50 por especialidad, en 217 especialidades.	Especialidad frente a área amplia, con 256 candidatos en cada una.

Todas las selecciones proceden de la colección inicial; estas filas no se suman. Cada comparación entre modelos utiliza los mismos identificadores. La comparación de alcance incluye los mismos 50 artículos de partida en ambos conjuntos y repite diez veces la elección de los otros 206. Los métodos y los Suplementos S1–S4 detallan tamaños, filtros y controles. Los 1.300 artículos de prueba del programa no son otra muestra científica.

3.2. Cómo representa cada modelo un artículo

Los diez modelos de la Tabla 2 abarcan documentos científicos, semejanza entre frases de uso general y lenguaje científico o biomédico. Se eligieron por su uso para representar literatura académica y por sus distintas formas de entrenamiento. Son un conjunto fijo de comparación, no una muestra aleatoria de modelos ni una clasificación de los sistemas más recientes. Sus versiones, los formatos de texto y la configuración de los programas se fijaron antes de calcular las representaciones.

La entrada principal es el título seguido del resumen, con el formato habitual de cada modelo. Los modelos leen piezas pequeñas de texto llamadas *tokens*, que pueden ser palabras

enteras o partes de palabras. Por tanto, sus límites de entrada no equivalen a un número de palabras. En su configuración habitual, MiniLM lee como máximo 256 tokens y MPNet 384. Estos límites recortan parte de la entrada en el 49,58 % y el 20,16 % de los artículos, respectivamente. Mantengo esas configuraciones y pruebo MiniLM con 512 tokens por separado. La comprobación del fragmento común descrita antes permite que todos lean el mismo contenido, aunque cada modelo lo divida en tokens a su manera.

Algunos modelos producen un vector por token. Hace falta entonces una regla que convierta esas salidas en un único vector para el artículo. Este paso se llama *pooling*. Para BERT, SciBERT, BioBERT y PubMedBERT, la regla principal calcula la media de las salidas de la última capa en todas las posiciones con texto o símbolos especiales, sin incluir el relleno. Estos cuatro modelos no se entrenaron específicamente para comparar documentos completos. Dos comprobaciones usan, en su lugar, la salida de la primera posición, llamada CLS, o la de la última posición sin relleno, llamada SEP. CLS se toma antes de la transformación adicional del modelo llamada *pooler*. La regla de la media se fijó antes de las comparaciones principales y se mantuvo tras las primeras comprobaciones; no se eligió para maximizar el acuerdo. Los otros seis modelos utilizan sus reglas documentadas. El Suplemento S1 detalla la configuración.

3.3. Del conjunto de áreas a los artículos individuales

Antes de comparar las representaciones, cada vector se ajusta para que tenga longitud uno. Así, las comparaciones dependen de su dirección y no de su longitud. Para resumir un área, calculo la media de sus vectores y obtengo un centro. La posición de estos centros describe las relaciones generales entre áreas. Comparar los vectores individuales dentro de cada área permite conservar el detalle que esa media oculta.

La comparación de centros utiliza 256 artículos por centro, con 26 centros de áreas, 217 de especialidades o un conjunto reducido de 26 centros de especialidades. Unos grupos aleatorios con los mismos tamaños y fechas permiten ver cuánto acuerdo puede aparecer al promediar sin utilizar las etiquetas observadas. Las comparaciones dentro de los grupos usan 128, 256 y 512 artículos. Las mismas 183 especialidades tienen suficientes artículos para los tres tamaños.

Los *vecinos* de un artículo son los artículos que quedan más cerca de él. Comparo las listas de los 25 vecinos más próximos que producen dos modelos, con listas de 10 y 50 como comprobaciones. La cercanía se mide con la similitud coseno, que compara las direcciones de los vectores. El artículo de partida no puede ser su propio vecino. Las listas se calculan de forma exacta y se comprueban mediante una ordenación independiente. Importa qué artículos pueden aparecer en ellas: buscar dentro de toda un área y período es distinto de limitarse a 2.048 artículos o ampliar la búsqueda a los 400.000 registros generales. Cada resultado indica qué búsqueda utiliza.

Tabla 2: Modelos de embeddings y reglas principales de representación.

Modelo	Tamaño	Límite de tokens	Vector del artículo	Referencia
SPECTER	768	512	CLS	(Cohan et al., 2020)
SPECTER2	768	512	CLS + adaptador	(Singh et al., 2023)
SciNCL	768	512	CLS	(Ostendorff et al., 2022)
SciBERT	768	512	Media	(Beltagy et al., 2019)
BERT	768	512	Media	(Devlin et al., 2019)
MPNet	768	384	Media	(Reimers and Gurevych, 2019)
MiniLM	384	256	Media	(Reimers and Gurevych, 2019)
PubMedBERT / BiomedBERT	768	512	Media	(Gu et al., 2022)
BioBERT	768	512	Media	(Lee et al., 2020)
SimCSE	768	512	CLS, antes del pooler	(Gao et al., 2021)

Tamaño indica cuántas coordenadas contiene el vector. MPNet y MiniLM utilizan all-mpnet-base-v2 y all-MiniLM-L6-v2, respectivamente. Los límites cuentan tokens, incluidos los símbolos especiales. Media: promedio de posiciones sin relleno de la última capa, con símbolos especiales. CLS: primera posición antes del pooler; SPECTER2 añade su adaptador de proximidad. En MPNet/MiniLM, la referencia describe el marco Sentence-BERT, no el entrenamiento exacto de esas versiones. Las reglas alternativas no son modelos adicionales. Versiones, formatos y recorte: Tabla S2.

Otra comparación mantiene el tamaño de la búsqueda y cambia su alcance. En cada una de 217 especialidades, 50 artículos de partida fijos se comparan con 256 candidatos de esa especialidad y con 256 de su área más amplia. Ambos conjuntos incluyen esos mismos 50 artículos y tienen el mismo reparto por períodos. Diez selecciones cambian los otros 206 candidatos. En total se utilizan 10.850 artículos de partida. Incluirlos en ambos conjuntos ayuda a igualar la comparación, pero también significa que el conjunto amplio no es una muestra aleatoria libre de toda el área.

3.4. Cómo se mide la estructura compartida y la dispersión de un área

Para comparar la estructura general, examino si las relaciones entre los mismos artículos son parecidas en dos representaciones. La medida principal es la alineación lineal de núcleos centrados con corrección, abreviada CKA (Kornblith et al., 2019; Murphy et al., 2024). Un

valor mayor indica más acuerdo. Un valor de 0,9 no significa que se haya representado correctamente el 90 % de la ciencia. La corrección reduce una inflación conocida debida al tamaño finito de la muestra; no elimina todo el sesgo estadístico. Otras dos comprobaciones permiten girar y cambiar de escala las representaciones para compararlas, mediante la alineación de Procrustes, o comparan el orden de las distancias entre artículos. Responden de forma distinta a los cambios, pero no son pruebas independientes de corrección temática (Williams et al., 2021; Williams, 2024). El Suplemento S2 contiene las fórmulas.

También describo dos propiedades dentro de cada área. La *apertura angular* mide cuánto se separan las direcciones de los vectores: es la mediana del ángulo entre vectores distintos. Ángulos mayores indican direcciones más separadas. La *dimensión lineal efectiva*, medida con la razón de participación o PR, indica cómo se reparte la variación entre las direcciones. Para entenderlo, una nube concentrada a lo largo de una línea varía sobre todo en una dirección; una nube extendida sobre un plano varía en más. La medida lleva esta idea al espacio completo de los vectores. Ninguna de las dos propiedades cuenta temas de investigación ni establece lo diversa que es un área.

Otras formas de resumir los ángulos y la variación permiten comprobar cuánto depende el resultado de la fórmula elegida. Las alternativas de dimensión utilizan la misma variación de partida, por lo que no validan de forma independiente una interpretación temática. También probé si los enlaces entre artículos cercanos permitían identificar grupos separados. Sin embargo, las comprobaciones con ejemplos artificiales impidieron interpretar esa medida como fragmentación general. El Suplemento S6 recoge las definiciones y los controles.

3.5. Cómo se comprueba si una comparación se repite

Con 26 áreas hay 325 formas de elegir dos áreas distintas, contando cada comparación una sola vez. Para cada propiedad geométrica, examino qué área tiene el valor mayor según cada modelo. Repito el cálculo con veinte medias muestras de 1.000 artículos por área y cinco selecciones adicionales de 2.000. Una dirección se considera persistente solo si se mantiene en todas esas selecciones y en la principal de 2.000.

Así se distinguen tres resultados. Los diez modelos pueden señalar de forma consistente la misma área como la mayor. Al menos dos modelos concretos pueden dar de forma consistente respuestas opuestas. O la comparación puede quedar sin resolver con estas reglas. Sin resolver no significa iguales. Además de comprobar cualquier diferencia distinta de cero, exijo que las diferencias superen el 1, el 5 o el 10 % de la media de los dos valores. Estos cortes permiten ver si el resultado depende de diferencias muy pequeñas; no son umbrales universales de importancia científica.

Las selecciones se solapan dentro de una misma colección. Sus rangos describen la sensibilidad a elegir otros artículos, no intervalos de confianza para una población más amplia. Otras comprobaciones marcan los casos que cambian demasiado entre selecciones; el suplemento

conserva sus reglas y recuentos. Las comparaciones también comparten modelos y áreas. Por eso se describen, en lugar de tratarlas como observaciones independientes en pruebas de significación.

El trabajo se desarrolló por etapas. Las primeras comparaciones de estructura y vecinos precedieron a la ampliación del experimento de texto y a las búsquedas por especialidad. El análisis geométrico fue una exploración posterior; el resumen de las 325 comparaciones se hizo después de conocer sus primeros ejemplos. Las reglas se registraron antes de los nuevos cálculos correspondientes, con resultados anteriores ya conocidos. Algunos controles se añadieron durante este proceso. El Suplemento S2 recoge la secuencia; el estudio completo no se prerregistró externamente.

4. Resultados

4.1. La organización general se comparte más que el detalle

Los modelos coinciden mucho en la posición relativa de los centros de los grupos. Con 256 artículos por centro, la CKA corregida media es 0,939 para las 26 áreas y 0,911 para 217 especialidades (Figura 1A). Al usar solo 26 centros de especialidades, el valor es 0,902. Los grupos aleatorios con los mismos tamaños y fechas también muestran cierto acuerdo, alrededor de 0,63–0,64, pero quedan por debajo de los grupos observados. Promediar contribuye a la comparación, sin explicar por completo el acuerdo asociado a las etiquetas de área.

Dentro de los grupos, la CKA media ronda 0,63 para las áreas y 0,64 para las mismas 183 especialidades en los tres tamaños (Figura 1B). Pasar de 128 a 512 artículos cambia poco estas medias. Por tanto, utilizar etiquetas más estrechas no reduce el acuerdo de forma general. Los análisis de centros y del interior de los grupos comparan objetos distintos; su diferencia no aísla un efecto causal de la escala.

Las medidas alternativas respaldan en general el orden del acuerdo entre modelos. En los 130 grupos originales de área y período, sus correlaciones de rangos medias con la CKA corregida son 0,891 para Procrustes y 0,881 para el orden de las distancias. La coincidencia no es completa, y la comprobación original de selección conserva 50 alertas entre 5.850 comparaciones de pareja de modelos y grupo (Tabla S4). Estos casos concretos siguen siendo relevantes aunque cambie poco la media general.




Figura 1: Acuerdo sobre los resúmenes de las áreas y los artículos que contienen. Una CKA corregida mayor indica más acuerdo entre modelos. (A) Acuerdo medio entre centros de grupos, cada uno formado por 256 artículos. Los grupos aleatorios conservan tamaños y fechas; la condición de 26 especialidades también iguala el número de centros. (B) Acuerdo dentro de los grupos con tres cantidades de artículos, usando 26 áreas y las mismas 183 especialidades. Los puntos y las etiquetas muestran las medias. Las líneas abarcan los percentiles 2,5–97,5 de las comparaciones entre grupo y pareja de modelos: 1.170 para áreas y 8.235 para especialidades. Muestran la dispersión de esos resultados, no intervalos de confianza. Las parejas comparten modelos y no son independientes. Ambos ejes abarcan 0–1; los paneles comparan objetos distintos, no un efecto causal de la escala.

4.2. Cambiar el modelo cambia qué artículos aparecen cerca

Dentro de la misma área y período, dos modelos conservan en promedio el 30,3 % de los 25 vecinos más próximos: unos ocho artículos de 25. Esta media da el mismo peso a cada grupo y pareja de modelos. Al usar 2.048 candidatos comunes en todos los grupos, el acuerdo sube al 31,9 %. Una búsqueda separada en los 400.000 registros generales da un 17,5 % para 13.000 artículos de partida repartidos de forma equilibrada. Esta última comparación cambia tanto el alcance de la búsqueda como el número de candidatos, por lo que no permite aislar el efecto de cruzar fronteras disciplinares.

Mantener iguales el tamaño de búsqueda y las fechas da un resultado menos uniforme (Figura 2). De 217 especialidades, 127 tienen menos acuerdo al buscar dentro de la especialidad que en el área amplia, mientras que 90 tienen más. El cambio medio es de $-1,35$ puntos porcentuales. Con 50 vecinos, el reparto es de 109 y 108. Por tanto, una búsqueda más estrecha no hace que los modelos discrepen más de forma general.




Figura 2: ¿Limitar una búsqueda a una especialidad cambia el acuerdo? Cada punto representa una de 217 especialidades. El eje horizontal muestra la fracción de vecinos compartidos al buscar en su área amplia; el vertical muestra esa fracción dentro de la especialidad. Un punto por encima de la diagonal tiene más acuerdo en la búsqueda estrecha. Ambas búsquedas contienen 256 candidatos, incluidos los mismos 50 artículos de partida, y fechas emparejadas. Los valores promedian las parejas de modelos y diez selecciones de los candidatos restantes. La búsqueda amplia queda, por tanto, condicionada por esos artículos de partida. La dispersión de puntos muestra diferencias entre especialidades, no intervalos de confianza.

La estructura general y el acuerdo entre vecinos están relacionados: su correlación de rangos en las medias de las 45 parejas de modelos es 0,920. Es decir, las parejas que coinciden más en una cosa tienden a coincidir más en la otra. Aun así, una pareja puede conservar la estructura general y cambiar muchos vecinos individuales. Estas observaciones, que comparten modelos, son descriptivas y no pruebas independientes de fiabilidad.

El análisis de casos del Suplemento S4 sigue especialidades, artículos y enlaces concretos al cambiar el tamaño de muestra, el pooling y la cantidad de vecinos. También muestra problemas de origen: entre los ejemplos seleccionados hay un libro de historia etiquetado como física, un texto sobre infección bacteriana etiquetado como política y un anuncio. Coinciden con los registros de OpenAlex descargados; no son errores al emparejar las salidas de los

modelos. Se conservan en los resultados y no permiten establecer lo frecuentes que son estos problemas.

4.3. Quitar el resumen puede importar tanto como cambiar el modelo

El experimento de texto utiliza los mismos 52.000 artículos para las tres entradas: título, resumen y título más resumen. El texto combinado es la referencia. En promedio, cambiar de modelo sustituye el 68,8 % de los 25 vecinos; mantener el modelo y usar solo el título sustituye el 70,7 % (Figura 3). Los cambios correspondientes en la estructura general, medidos como uno menos la CKA, son 0,370 y 0,366. Estas medias parecidas no demuestran equivalencia, pero indican que quitar el resumen puede importar casi tanto como elegir otro modelo.




Figura 3: Cambiar el modelo o cambiar lo que lee. Todas las comparaciones utilizan los mismos 52.000 artículos, con 2.000 por área. La entrada de referencia es título más resumen. El cambio de modelo compara modelos distintos con esa entrada; el cambio de texto conserva el modelo y usa solo el título o solo el resumen. Valores mayores indican más cambio: (A) uno menos la CKA corregida; (B) la fracción de los 25 vecinos que se sustituye. Cada punto es una media de área. Las cajas muestran la mediana y la mitad central de los valores de área; los extremos llegan hasta valores situados a un máximo de 1,5 rangos intercuartílicos de la caja. Son distribuciones descriptivas, no intervalos de confianza. Los modelos conservan sus límites habituales de texto.

Usar solo el resumen cambia menos: 0,027 para la estructura y un 22,1 % de los vecinos. Las medias también ocultan diferencias entre modelos. Utilizar solo el título sustituye el 51,7 % de los vecinos con MPNet y el 84,2 % con SciBERT (Tabla S5).

La forma de convertir las salidas de los tokens en un único vector también importa. Con la regla principal de la media, usar solo el título sustituye ligeramente más vecinos que cambiar de modelo; usar CLS o SEP para los cuatro BERT de palabras invierte ese orden. Estas reglas cambian tanto la comparación de entradas como su referencia de cambio de modelo. Se comparan formas prácticas de uso; no se aísla el efecto causal de un único paso de procesamiento.

La primera prueba de 26.000 artículos y su ampliación a 52.000 estudian la misma pregunta sobre el texto. En la comprobación con 100 selecciones repetidas, las comparaciones de modelo, área y entrada que activan una alerta bajan de 72 de 520 a cinco de 520. El Suplemento S3 también conserva la comprobación anterior con veinte selecciones. Superar este control no demuestra que una diferencia sea distinta de cero ni que todos los resultados de vecinos sean estables. Las comprobaciones separadas del fragmento común y de MiniLM con 512 tokens estudian la longitud de entrada; no revelan un error de código en el límite original de MiniLM.

4.4. Comparar dos áreas puede dar la respuesta contraria con otro modelo

El análisis geométrico reutiliza la muestra de 52.000 artículos del experimento de texto y sus representaciones de título más resumen. Pregunta, por ejemplo, si los vectores de los artículos de un área apuntan en direcciones más separadas que los de otra. Antes de comparar áreas, comprobé si el valor de cada propiedad se repetía al elegir otros artículos. La apertura angular no tiene alertas entre los 260 casos de modelo y área. La dimensión lineal efectiva tiene cuatro alertas en la comprobación con medias muestras y ninguna en las cinco selecciones de igual tamaño. El segundo resultado no elimina el primero.

De las 325 comparaciones entre dos áreas, 262 tienen respuestas opuestas persistentes de al menos dos modelos para la apertura angular; 221 las tienen para la dimensión lineal efectiva (Figura 4). Por ejemplo, un modelo concreto sitúa de forma consistente el área A por encima de B, mientras que otro sitúa B por encima de A. Esto no significa que los diez modelos discrepen. Los diez dan la misma dirección persistente en 42 y 54 comparaciones, respectivamente; las 21 y 50 restantes quedan sin resolver.

Muchas respuestas opuestas corresponden a diferencias pequeñas. Si exigimos que la diferencia supere el 5 % de la media de los dos valores de área, quedan 96 comparaciones opuestas para apertura angular y 177 para dimensión. Con el 10 %, los recuentos bajan a 19 y 126. Por eso, la dirección del desacuerdo y su tamaño deben presentarse juntos.




Figura 4: ¿Los modelos dan la misma respuesta al comparar dos áreas? Cada barra incluye las 325 formas de elegir dos de las 26 áreas. El azul indica que los diez modelos señalan de forma consistente la misma área como la de mayor valor. El naranja indica que al menos dos modelos concretos dan de forma consistente respuestas opuestas. El gris incluye las comparaciones restantes y no significa igualdad. La consistencia exige mantener la dirección en la selección principal, veinte medias muestras y cinco selecciones adicionales de igual tamaño. Los cortes del 0, 1, 5 y 10 % exigen diferencias respecto a la media de los dos valores de área; no son umbrales de significación. La apertura angular describe cuánto se separan las direcciones de los vectores. La dimensión lineal efectiva describe cómo se reparte la variación entre direcciones. Las medidas alternativas y las comprobaciones de procesamiento tienen su propia cobertura en las Tablas S15–S16.

Las medidas alternativas conservan los mismos modelos opuestos y sus direcciones en 225 de las 262 comparaciones angulares y 196 de las 221 de dimensión. La comprobación angular cubre las 26 selecciones; las alternativas de dimensión cubren tres. Describen propiedades relacionadas y no establecen qué resultado es correcto sobre la investigación. Limitar el análisis a los seis modelos entrenados para comparar documentos o frases todavía deja 231 oposiciones angulares y 160 de dimensión con el corte de diferencia distinta de cero (Tablas S14–S15). Un conjunto menor de modelos también ofrece menos oportunidades de encontrar oposición.

Las decisiones de procesamiento pueden cambiar la conclusión. Una comprobación que resta el vector medio global y después vuelve a ajustar los vectores a longitud uno conserva los mismos modelos opuestos y sus direcciones en 145 de las 262 comparaciones angulares y 218 de las 221 de dimensión. Son comprobaciones de los valores puntuales guardados, no otra serie completa de selecciones repetidas. Cambiar el pooling también puede invertir direcciones (Tabla S16).

El intento de medir la fragmentación muestra un límite útil. Las nubes artificiales alargadas o los puntos extremos pueden parecer desconectados sin que existan grupos temáticos separados. Los resultados también dependen del tamaño de muestra y de la regla para enlazar vecinos; 51 de 260 casos conservan alertas de selección. Por ello, presento estas comprobaciones en el Suplemento S6 sin interpretar la desconexión como prueba de que un área está fragmentada.

5. Discusión

5.1. Qué conviene comprobar antes de utilizar un mapa

Los modelos comparten una organización general y, aun así, pueden dar respuestas distintas sobre los artículos cercanos o la dispersión de las representaciones de dos áreas. Esto importa cuando usamos un mapa para sostener una afirmación concreta. Una puntuación general tranquilizadora no establece que esa afirmación se mantenga al cambiar de modelo. Repetir la selección de artículos responde a otra pregunta y no puede sustituir esa comprobación.

Esta preocupación continúa trabajos anteriores sobre la dependencia de los mapas respecto al método (Gläser et al., 2017; Boyack and Klavans, 2020) y complementa las evaluaciones con clasificaciones y relaciones externas (González-Márquez et al., 2024; Constantino et al., 2025). Combinar estructura y vecinos también tiene antecedentes (Caspari et al., 2024). La aportación aquí es la comparación controlada entre niveles, decisiones de texto y comparaciones repetidas de áreas, incluidos los casos en que un resultado se mantiene dentro de cada modelo y se invierte entre modelos.

La interpretación sigue dependiendo de lo que describe la medida. Un ángulo mayor significa que los vectores apuntan en direcciones más separadas. Una dimensión lineal efectiva mayor significa que la variación se concentra menos en unas pocas direcciones. Ninguna de las dos cosas demuestra por sí sola más diversidad temática o interdisciplinariedad. Otros trabajos sobre la geometría de los embeddings también advierten contra atribuir un significado amplio a una medida conveniente (Rudman et al., 2022). La comprobación fallida de fragmentación lo muestra de forma concreta: una diferencia que se repite puede seguir respaldando una explicación equivocada.

5.2. Qué cambian las comprobaciones adicionales

El texto y las decisiones de procesamiento deben describirse al presentar mapas de la ciencia. En esta colección, quitar el resumen puede importar casi tanto como cambiar de modelo. El nombre del modelo no basta para saber qué representación se utilizó; también hacen falta la entrada, el límite de texto y la regla de pooling.

Las comprobaciones adicionales por disciplina y tiempo desaconsejan una explicación única para todas las diferencias (Suplemento S5). Medicina tiene menos acuerdo de estructura que Energía con la regla principal, pero no siempre el menor acuerdo de vecinos. Equilibrar la composición por especialidades y quitar los dos modelos biomédicos no elimina la diferencia entre Medicina y Energía. Las aparentes familias de modelos también cambian con el pooling. Con diez modelos, los datos de entrenamiento, la arquitectura y los objetivos de entrenamiento siguen mezclados; estas asociaciones no aíslan una causa.

Entre períodos de publicación, el acuerdo de estructura aumenta ligeramente en promedio. El acuerdo de vecinos cambia $-0,87$ puntos porcentuales cuando están disponibles todos los candidatos, pero $+0,91$ puntos con 2.048 candidatos en cada grupo. El cambio de signo muestra por qué importan las posibilidades de búsqueda. Aplicar modelos actuales a artículos antiguos y recientes no demuestra por sí solo una convergencia histórica de la ciencia.

5.3. Qué queda abierto

La colección exige registros etiquetados como ingleses y con resúmenes utilizables. Reforzar los grupos pequeños de área y período ayuda a compararlos, pero cambia las proporciones. Persisten errores de origen, y la limpieza no certifica cada registro. Repetir las selecciones no puede reparar la falta de cobertura ni hacer que estos resultados representen todo el trabajo científico.

Los diez modelos también fijan un límite. Cuatro no se entrenaron específicamente para comparar documentos. La comprobación con seis modelos ayuda a mostrar que el desacuerdo no se limita a esos cuatro, pero no hace que el conjunto represente todos los modelos de embeddings. Decidir qué dirección tiene mejor respaldo requiere pruebas externas a los embeddings, como relaciones entre artículos evaluadas de forma independiente.

Por último, varias ampliaciones y controles se hicieron después de conocer resultados anteriores. Registrar sus reglas antes de los nuevos cálculos permite seguir las decisiones, sin convertir el estudio completo en un diseño confirmatorio. Un siguiente paso útil sería contrastar una afirmación concreta extraída del mapa con juicios independientes en un área de investigación. Añadir modelos, por sí solo, no resolvería qué significa su geometría compartida o contradictoria.

6. Conclusión

Cambiar el modelo de embeddings puede conservar la organización general de la ciencia y cambiar los artículos que encontramos cerca y el sentido de las comparaciones entre áreas. El texto que recibe el modelo puede importar tanto como esa elección. Algunos resultados se repiten con otros artículos y siguen dependiendo del modelo. Para una afirmación extraída de un mapa, conviene comprobar si se mantiene ante los cambios que podrían afectarla y mostrar el tamaño de la diferencia. El acuerdo identifica lo que comparten las representaciones probadas; establecer qué es correcto sobre la investigación requiere más pruebas.

Declaraciones

Contribuciones del autor. Alejandro Treny Ortega concibió el proyecto y dirigió la investigación y la preparación del manuscrito como investigador independiente. La ayuda computacional y editorial se declara a continuación.

Conflictos de interés. El autor declara que no tiene conflictos de interés.

Financiación. Esta investigación no recibió financiación externa.

Disponibilidad de datos y código. El repositorio del proyecto es <https://github.com/aleetreny/Shape-of-Science-Robustness>. Este borrador se acompaña de las tablas utilizadas en las figuras y de las fuentes editables del manuscrito. El corpus fijo, los vectores y los registros locales completos de ejecución no se han depositado en un archivo público persistente. Publicar el código por sí solo no permite reproducir por completo este análisis. El Suplemento S8 detalla el inventario de acceso y los requisitos pendientes; aquí no se afirma que exista un depósito de datos ni un identificador persistente.

Uso de herramientas de inteligencia artificial. OpenAI Codex ayudó con las búsquedas bibliográficas, el desarrollo de software y los análisis, la visualización y la redacción y edición del manuscrito. El autor es responsable del contenido.

Referencias

Iz Beltagy, Kyle Lo, and Arman Cohan. SciBERT: A pretrained language model for scientific text. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3615–3620, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1371. URL <https://aclanthology.org/D19-1371/>.

- Kevin W. Boyack and Richard Klavans. A comparison of large-scale science models based on textual, direct citation and hybrid relatedness. *Quantitative Science Studies*, 1(4):1570–1585, 2020. ISSN 2641-3337. doi: 10.1162/qss_a_00085.
- Laura Caspari, Kanishka Ghosh Dastidar, Saber Zerhoubi, Jelena Mitrovic, and Michael Granitzer. Beyond benchmarks: Evaluating embedding model similarity for retrieval augmented generation systems. arXiv:2407.08275, 2024. URL <https://arxiv.org/abs/2407.08275>. Preprint.
- Arman Cohan, Sergey Feldman, Iz Beltagy, Doug Downey, and Daniel Weld. SPECTER: Document-level representation learning using citation-informed transformers. In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2270–2282, Online, jul 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.207. URL <https://aclanthology.org/2020.acl-main.207/>.
- Isabel Constantino, Sadamori Kojaku, Santo Fortunato, and Yong-Yeol Ahn. Representing the disciplinary structure of physics: A comparative evaluation of graph and text embedding methods. *Quantitative Science Studies*, 6:263–280, 2025. ISSN 2641-3337. doi: 10.1162/qss_a_00349.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Jill Burstein, Christy Doran, and Thamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, jun 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423/>.
- Tianyu Gao, Xingcheng Yao, and Danqi Chen. SimCSE: Simple contrastive learning of sentence embeddings. In Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih, editors, *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6894–6910, Online and Punta Cana, Dominican Republic, nov 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.emnlp-main.552. URL <https://aclanthology.org/2021.emnlp-main.552/>.
- Jochen Gläser, Wolfgang Glänzel, and Andrea Scharnhorst. Same data—different results? towards a comparative approach to the identification of thematic structures in science. *Scientometrics*, 111(2):981–998, 2017. ISSN 0138-9130. doi: 10.1007/s11192-017-2296-z.
- Rita González-Márquez, Luca Schmidt, Benjamin M. Schmidt, Philipp Berens, and Dmitry Kobak. The landscape of biomedical research. *Patterns*, 5(6):100968, 2024. ISSN 2666-3899. doi: 10.1016/j.patter.2024.100968.
- Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23, 2022. ISSN 2691-1957. doi: 10.1145/3458754.
- Matthias Held and Theresa Velden. How to interpret algorithmically constructed topical structures of scientific fields? a case study of citation-based mappings of the research specialty of invasion biology. *Quantitative Science Studies*, 3(3):651–671, 2022. ISSN 2641-3337. doi: 10.1162/qss_a_00194.

- Nathaniel Imel and Zachary Hafen. Density, asymmetry and citation dynamics in scientific literature. arXiv:2506.23366, 2025. URL <https://arxiv.org/abs/2506.23366>. Preprint.
- Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529. PMLR, 09–15 Jun 2019. URL <https://proceedings.mlr.press/v97/kornblith19a.html>.
- Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240, 2020. ISSN 1367-4803. doi: 10.1093/bioinformatics/btz682.
- Alex Murphy, Joel Zylberberg, and Alona Fyshe. Correcting biased centered kernel alignment measures in biological and artificial neural networks. arXiv:2405.01012, 2024. URL <https://arxiv.org/abs/2405.01012>. Preprint.
- OpenAlex. Topics. OpenAlex Help Center, 2026. URL <https://help.openalex.org/data/topics/>. Accessed 18 September 2026.
- Malte Ostendorff, Nils Rethmeier, Isabelle Augenstein, Bela Gipp, and Georg Rehm. Neighborhood contrastive learning for scientific document representations with citation embeddings. In Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11670–11688, Abu Dhabi, United Arab Emirates, dec 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.802. URL <https://aclanthology.org/2022.emnlp-main.802/>.
- Jason Priem, Heather Piwowar, and Richard Orr. OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts, 2022. URL <https://arxiv.org/abs/2205.01833v2>. Preprint, version 2.
- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL <https://aclanthology.org/D19-1410/>.
- William Rudman, Nate Gillman, Taylor Rayne, and Carsten Eickhoff. IsoScore: Measuring the uniformity of embedding space utilization. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3325–3339, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.262. URL <https://aclanthology.org/2022.findings-acl.262/>.
- Amanpreet Singh, Mike D’Arcy, Arman Cohan, Doug Downey, and Sergey Feldman. SciRepeval: A multi-format benchmark for scientific document representations. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5548–5566, Singapore, dec 2023. Asso-

ciation for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.338. URL <https://aclanthology.org/2023.emnlp-main.338/>.

Shruti Singh and Mayank Singh. The inefficiency of language models in scholarly retrieval: An experimental walk-through. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3153–3173, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.249. URL <https://aclanthology.org/2022.findings-acl.249/>.

Alex H Williams. Equivalence between representational similarity analysis, centered kernel alignment, and canonical correlations analysis. In Marco Fumero, Clementine Domine, Zorah Löhner, Donato Crisostomi, Luca Moschella, and Kimberly Stachenfeld, editors, *Proceedings of UniReps: the Second Edition of the Workshop on Unifying Representations in Neural Models*, volume 285 of *Proceedings of Machine Learning Research*, pages 10–23. PMLR, 14 Dec 2024. URL <https://proceedings.mlr.press/v285/williams24a.html>.

Alex H Williams, Erin Kunz, Simon Kornblith, and Scott Linderman. Generalized shape metrics on neural representations. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, volume 34, pages 4738–4750. Curran Associates, Inc., 2021. URL https://proceedings.neurips.cc/paper_files/paper/2021/file/252a3dbaeb32e7690242ad3b556e626b-Paper.pdf.