

¿Cuánto depende el mapa de la ciencia del modelo de embeddings?

Alejandro Treny Ortega

Investigador independiente

Opción 3: Voz marcada y reflexiva • 19 de septiembre de 2026

Resumen

Una comparación entre áreas puede resistir la selección repetida de artículos e invertirse al cambiar de modelo de embeddings. Este estudio examina ese problema con diez modelos y un corpus fijo de 500.000 registros de OpenAlex, de 26 áreas y del período 2000–2024. Las muestras emparejadas comparan centros de áreas, relaciones internas y vecinos próximos, con controles del texto de entrada y de las reglas de representación. Los modelos comparten una estructura general, pero conservan de media solo el 30,3 % de los 25 vecinos más próximos dentro de los grupos de área y período. Quitar el resumen cambia los vecinos casi tanto como cambiar de modelo; quitar el título cambia menos. Un análisis exploratorio posterior examina las 325 parejas de áreas. Hay órdenes opuestos persistentes entre modelos en 262 parejas para la apertura angular y 221 para la dimensión lineal efectiva; al exigir diferencias relativas superiores al 5 %, quedan 96 y 177. Las medidas alternativas conservan muchas oposiciones, aunque el centrado y la combinación de las salidas afectan a las conclusiones. Los resultados describen dependencia geométrica, sin establecer corrección temática. Propongo seguir una afirmación a través de las decisiones que producen su mapa. Repetir un resultado al seleccionar artículos responde a una pregunta útil, pero no demuestra que otra representación de esos mismos artículos sostenga la misma interpretación.

Palabras clave: mapas de la ciencia; embeddings de documentos; robustez; acuerdo entre vecinos; comparaciones geométricas.

1. Introducción

Cambiar la representación de los documentos puede invertir una comparación entre áreas de investigación aunque los artículos sigan siendo los mismos. Esa es la dificultad que da origen a este estudio. Un mapa de la ciencia resulta útil porque convierte una colección de artículos en relaciones que pueden examinarse: trabajos próximos, áreas vecinas y contrastes entre disciplinas. Con embeddings de texto, un modelo transforma primero cada artículo en un vector. Las distancias y disposiciones que después interpretamos proceden de esos vectores. Las aplicaciones a literatura biomédica y física muestran lo que esto permite hacer

(González-Márquez et al., 2024; Constantino et al., 2025). Pregunto hasta dónde se sostiene una conclusión extraída de ese mapa cuando cambia el modelo de embeddings.

La dificultad es anterior a estos modelos. Gläser et al. (2017) preguntaron qué debe una estructura temática reconstruida al conocimiento científico y qué debe al método que la reconstruye. Boyack and Klavans (2020) encontraron que mapas de texto, citas y su combinación podían tener una precisión global parecida y asignar artículos sustancialmente distintos a sus grupos. Esos resultados sitúan el problema en la interpretación de una comparación. Una puntuación global favorable no dice al lector si la agrupación concreta que quiere utilizar resiste un cambio de método.

Examinó esto con 500.000 publicaciones etiquetadas como inglesas en OpenAlex, publicadas entre 2000 y 2024 y asignadas a 26 áreas amplias, los Fields. Los artículos se mantienen fijos entre diez modelos de embeddings. Los centros de las áreas, las relaciones internas y los vecinos de cada artículo ofrecen objetos sucesivos de comparación. Otras muestras emparejadas cambian el texto que se suministra y la regla que convierte la salida del modelo en un vector por artículo. Después, una ampliación geométrica exploratoria sigue una pregunta más concreta: si dos áreas mantienen su orden al cambiar la representación, una vez comprobado qué ocurre al cambiar los artículos.

Los modelos sí comparten relaciones generales. Las comparaciones locales y los órdenes geométricos entre áreas muestran cuánto queda por comprobar antes de utilizar ese acuerdo para sostener una afirmación concreta. Un modelo puede dar repetidamente un orden mientras cambian los artículos, y otro dar repetidamente el orden contrario. Trato el tamaño de esa diferencia y su respuesta al procesamiento como parte del resultado. Una dirección puede ser persistente y su magnitud pequeña. Las comparaciones revelan qué relaciones dependen de las decisiones probadas; decidir si una relación es correcta en términos de contenido requiere otra validación.

2. Antecedentes y preguntas de investigación

2.1. Decisiones de representación en los mapas de la ciencia

Las evaluaciones anteriores resultan útiles precisamente porque explicitan qué se pide a una representación. Constantino et al. (2025) compararon representaciones de texto y grafos con una clasificación jerárquica de artículos de física, incluidas entradas basadas en títulos y resúmenes. En un mapa de literatura biomédica, González-Márquez et al. (2024) compararon modelos y reglas de reducción de sus salidas a través de las etiquetas de área compartidas por artículos próximos. Son criterios concretos de evaluación. Ayudan a entender por qué el acuerdo entre modelos, que es lo que se estudia aquí, no puede ocupar sin más el lugar de una evaluación externa.

Dentro de una representación de documentos hay más que un modelo. Hay que decidir qué texto recibe, cuánto cabe y, en algunos casos, cómo se convierten las salidas de sus tokens en un único vector. Pooling es esta última decisión: promediar y seleccionar una posición concreta de la salida pueden conservar relaciones diferentes. La sensibilidad a consultas cortas y cambios de redacción documentada por Singh and Singh (2022) hace tangible el problema de la entrada. Incluyo estas decisiones porque, de otro modo, una comparación de modelos deja sin examinar parte de su propio procedimiento.

La comparación conjunta de geometría y vecinos ya forma parte de la literatura. Caspari et al. (2024) la utilizaron en conjuntos de datos de búsqueda, y Imel and Hafen (2025) examinaron densidad y asimetría entre embeddings de documentos y disciplinas en relación con las citas. La pregunta que persigo es qué ocurre con las conclusiones generales, locales y geométricas al hacer esas comparaciones dentro de un conjunto fijo de modelos. Los artículos emparejados, las condiciones explícitas de texto y representación y los candidatos controlados mantienen cada resultado ligado al cambio que se ha probado.

2.2. Acuerdo, estabilidad e interpretación

Evito tratar la robustez como una propiedad que se pueda asignar de una vez a todo el mapa. El acuerdo pregunta qué comparten dos representaciones de los mismos artículos. La estabilidad pregunta si un resultado determinado resiste un cambio determinado. Un orden estable dentro de cada modelo puede seguir siendo un orden en el que los modelos discrepan. La validez temática va más allá y pregunta cómo corresponden esas relaciones a la propia investigación. En biología de las invasiones, Held and Velden (2022) mostraron por qué interpretar grupos obtenidos por algoritmos exige atender a las relaciones que combina cada método. Una respuesta repetida o un acuerdo entre modelos no pueden hacer por sí solos ese trabajo de interpretación.

La palabra *forma* necesita un cuidado parecido. Aquí se refiere a relaciones en los espacios de embeddings antes de proyectarlos en dos dimensiones. Los centros resumen la disposición de las áreas; los artículos conservan su organización interna; los vecinos identifican las publicaciones más próximas a un artículo concreto. La apertura angular describe la separación de los vectores, y la dimensión lineal efectiva describe cómo ocupa la variación las direcciones. Cada una ofrece una vista limitada de la representación. Decir que un área se abre más no demuestra que sus temas sean más diversos; atribuirle más dimensiones efectivas no cuenta sus temas. Mantener explícito el objeto permite interpretar un cambio de forma.

2.3. Preguntas de investigación y alcance

Tres preguntas organizan el análisis:

- PI1.** ¿Qué relaciones estructurales comparten los modelos de embeddings y cómo varía el acuerdo entre los centros de las áreas, los artículos dentro de cada área y los vecinos locales?
- PI2.** ¿Cuánto cambian la geometría y los vecinos al modificar el texto de entrada o la regla de combinación de las salidas, en comparación con cambiar el modelo?
- PI3.** ¿Qué comparaciones geométricas entre áreas se mantienen, se invierten o quedan sin resolver al cambiar de modelo y de selección de artículos, y qué tamaño tienen las diferencias?

Estas preguntas se refieren al corpus y a los modelos efectivamente comparados. La tercera se añadió tras los primeros resultados, en la ampliación exploratoria documentada en los métodos y el suplemento. Conservo ese orden de desarrollo. Las etiquetas de OpenAlex organizan las comparaciones y permanecen con sus errores conocidos; no son una referencia temática independiente. El estudio puede establecer persistencia dentro de este diseño. No puede identificar un único mapa correcto y utilizarlo después para declarar un modelo ganador.

3. Datos y diseño de la comparación

3.1. Corpus y muestras de análisis

El corpus contiene 500.000 identificadores distintos de trabajos de OpenAlex, recogidos y limpiados hasta el 15 de septiembre de 2026. OpenAlex proporciona los metadatos y los textos (Priem et al., 2022). La consulta a su catálogo principal se limitó a artículos, revisiones y trabajos de congresos publicados entre 2000 y 2024, etiquetados como ingleses, con título no vacío, un resumen reconstruible de al menos 50 palabras y un área principal conocida. Se excluyeron las marcas de retractación y paratexto. Se eliminaron los fallos claros de idioma y contenido; los casos inciertos y las posibles versiones duplicadas se conservaron con marcas. La clasificación por tema principal de cada registro quedó fijada al extraerlo. Estas etiquetas automáticas utilizan texto, citas e información de la revista (OpenAlex, 2026); sirven para organizar el análisis, no como criterio independiente de corrección.

La muestra general de 400.000 registros válidos se obtuvo mediante consultas aleatorias a la API con semillas registradas. Otros 100.000 registros reforzaron los grupos más pequeños de área y período, asignando repetidamente nuevas plazas al grupo menos poblado. Los grupos grandes no se redujeron al tamaño del menor. Los 130 grupos resultantes cubren 26 áreas

y cinco períodos: 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Todos contienen al menos 2.165 registros. Las comparaciones globales utilizan la muestra general; las comparaciones entre grupos pueden usar ambas partes. Las medias que dan el mismo peso a cada grupo describen una comparación equilibrada, no las proporciones de la investigación mundial.

Usar los mismos artículos es una condición de partida; las distintas preguntas también necesitan muestras diferentes (Tabla 1). Las tres entradas de texto se comparan en 52.000 artículos equilibrados por área y período, incluido el piloto anterior de 26.000. Otra muestra de 52.000 artículos contrasta las entradas habituales con un fragmento literal común que cabe en todos los tokenizadores. Las comparaciones de grupos iguales y las búsquedas de vecinos emparejadas controlan otros cambios de la comparación. Cada comparación entre modelos mantiene la identidad de los artículos. El Suplemento S1 recoge las reglas de extracción y limpieza, los recuentos y las marcas que permanecen.

Tabla 1: Corpus y muestras de análisis.

Muestra	Artículos y representación	Comparación y alcance
Corpus original	500.000 identificadores: 400.000 base + 100.000 de refuerzo. Diez modelos; título y resumen.	26 áreas, cinco períodos. Los resúmenes globales usan la base; el corpus completo no es proporcional a la población.
Tres entradas de texto	52.000 identificadores; 400 por área y período, 2.000 por área. Título, resumen y ambos.	Mismos artículos y candidatos entre modelos. Incluye el piloto de 26.000 artículos.
Fragmento común	Otra muestra distinta de 52.000 identificadores; 400 por área y período.	Contenido habitual y común emparejado; tokenización propia de cada modelo. Distinta de la muestra de tres entradas.
Grupos de igual tamaño	256 artículos por centro; 26 áreas, 217 especialidades o 26 centros de especialidades.	Dentro de grupos: 26 áreas y las mismas 183 especialidades con 128, 256 y 512 artículos. Objetos distintos de los centros.
Búsquedas emparejadas	217 especialidades; 50 consultas fijas por cada una (10.850 en total). Diez selecciones de candidatos.	256 candidatos en cada ámbito, incluidas las 50 consultas. El conjunto del área está condicionado por esas consultas.
Geometría / parejas de áreas	2.000 por área; veinte mitades de 1.000 y cinco selecciones de 2.000.	325 parejas y dos propiedades; 26 condiciones guardadas. Las medidas alternativas tienen distinta cobertura.

Las filas se solapan y no deben sumarse. Períodos: 2000–04, 2005–09, 2010–14, 2015–19 y 2020–24. Cada comparación usa los mismos identificadores entre modelos. En la búsqueda, cada artículo de consulta se excluye a sí mismo. Los 1.300 artículos de prueba técnica no forman otra muestra científica. Filtros y cuotas completos: Tabla S1.

3.2. Modelos y representaciones del texto

Elegí un conjunto fijo de diez modelos para comparar representaciones utilizadas en material académico con enfoques de entrenamiento distintos (Tabla 2). Incluye modelos de documentos científicos, de frases generales y de palabras biomédicas o científicas. Su propósito es una comparación acotada; no puede representar una población aleatoria de modelos ni clasificar las versiones más recientes. Las versiones de modelos, tokenizadores y formatos de texto se fijaron antes del cálculo. Los modelos representaron los mismos títulos y resúmenes con su formato habitual y su límite propio. El límite de 256 tokens de MiniLM es el principal, y una variante separada de 512 comprueba su sensibilidad. Los límites propios recortaron el 49,58 % de las entradas de MiniLM y el 20,16 % de las de MPNet.

En BERT, SciBERT, BioBERT y PubMedBERT, el vector principal del documento es la media de los estados de los tokens de la última capa que no son relleno, incluidos los símbolos especiales. Estos modelos no se entrenaron específicamente para medir similitud entre documentos. Como alternativas se usaron el estado de la primera posición (CLS, antes del *pooler*) y el de la última posición sin relleno (SEP). La media se fijó antes de las comparaciones principales y se mantuvo tras los primeros controles; no se eligió para maximizar el acuerdo. Los otros seis modelos usan sus reglas documentadas de representación. Las entradas de solo título y solo resumen utilizan los mismos 52.000 identificadores que la comparación con ambos textos. Al mantener los límites propios de cada modelo, se comparan formas prácticas de utilizarlos, sin aislar la arquitectura de la longitud del texto.

Tabla 2: Modelos de embeddings y reglas principales de representación.

Modelo	Dim.	Tokens	Representación	Referencia
SPECTER	768	512	CLS	(Cohan et al., 2020)
SPECTER2	768	512	CLS + adaptador	(Singh et al., 2023)
SciNCL	768	512	CLS	(Ostendorff et al., 2022)
SciBERT	768	512	Media	(Beltagy et al., 2019)
BERT	768	512	Media	(Devlin et al., 2019)
MPNet	768	384	Media	(Reimers and Gurevych, 2019)
MiniLM	384	256	Media	(Reimers and Gurevych, 2019)
PubMedBERT / BiomedBERT	768	512	Media	(Gu et al., 2022)
BioBERT	768	512	Media	(Lee et al., 2020)
SimCSE	768	512	CLS, antes del pooler	(Gao et al., 2021)

MPNet y MiniLM utilizan all-mpnet-base-v2 y all-MiniLM-L6-v2, respectivamente. Los límites cuentan tokens, incluidos los símbolos especiales. Media: promedio de posiciones sin relleno de la última capa, con símbolos especiales. CLS: primera posición antes del pooler; SPECTER2 añade su adaptador de proximidad. En MPNet/MiniLM, la referencia describe el marco Sentence-BERT, no el entrenamiento exacto de esas versiones. Las reglas alternativas no son modelos adicionales. Versiones, formatos y recorte: Tabla S2.

3.3. Objetos y medidas

Todas las medidas utilizan las dimensiones originales de los embeddings, sin proyectarlos en dos dimensiones. Primero se ajusta cada vector de artículo para que tenga longitud uno. El acuerdo de forma se mide principalmente mediante la alineación lineal centrada de kernels corregida, o CKA, que compara las relaciones entre los mismos artículos (Kornblith et al., 2019; Murphy et al., 2024). Un valor mayor indica más acuerdo. La corrección por tamaño de muestra reduce una fuente conocida de aumento artificial del acuerdo; no convierte el cociente completo en un estimador exactamente insesgado. La alineación de Procrustes y las correlaciones entre los rangos de las distancias aportan comprobaciones con sensibilidades distintas. Sus definiciones y la fórmula de corrección aparecen en el Suplemento S2. Son medidas relacionadas, no votos independientes sobre la validez (Williams et al., 2021; Williams, 2024).

Un centro comprime los vectores de artículos de longitud uno de un grupo en su media. Ese es el objeto utilizado para comparar la organización general. El análisis interno mantiene separados los artículos. Utilizo grupos aleatorios para examinar cuánto acuerdo entre centros

puede acompañar al propio promedio sin las etiquetas observadas. Se conservan los tamaños de los grupos y los períodos de publicación, y cada modelo recibe la misma asignación aleatoria.

El acuerdo de vecinos es la fracción de los k artículos más próximos que comparten dos modelos. La elección principal es $k = 25$, con 10 y 50 como controles. Las búsquedas usan similitud del coseno y excluyen el propio artículo consultado. En cada resultado se indica qué candidatos pueden aparecer: todos los artículos de un grupo de área y período, una selección de tamaño igualado, un conjunto emparejado de área y especialidad (*Subfield*) o el corpus general. El cálculo exacto por bloques evita almacenar todas las distancias por parejas. Comprobaciones independientes mediante ordenación completa verifican las listas de vecinos guardadas. Ni la coincidencia ni su ajuste simple por azar eliminan todos los efectos de la composición o el tamaño del conjunto de candidatos.

Otras dos propiedades describen geométricamente cada área. La *apertura angular* es la mediana del ángulo entre vectores de artículos distintos. La *dimensión lineal efectiva* es el cociente de participación de la matriz de covarianza centrada C , $PR = (\text{tr } C)^2 / \text{tr}(C^2)$. Es mayor cuando la variación se reparte entre más direcciones. Como alternativas se utilizan cuantiles angulares, ángulos respecto al centro, el rango efectivo basado en entropía y el número de direcciones que contienen el 80 % de la varianza. Las dos últimas proceden del mismo espectro de covarianza que PR; no aportan una validación temática independiente. También se probaron medidas de conexión de grafos, pero sus contraejemplos con nubes sintéticas impidieron interpretarlas como fragmentación general (Suplemento S6).

3.4. Comparaciones emparejadas y estabilidad

La comparación estricta de vecinos entre área y especialidad fija 50 artículos de consulta en cada una de 217 especialidades. Ambas búsquedas contienen 256 candidatos, incluidas esas mismas 50 consultas, y las mismas cantidades por período. Diez selecciones cambian los 206 candidatos restantes dentro de la especialidad o de su área principal. Por tanto, la búsqueda más amplia está condicionada por las consultas; no es una selección libre de 256 artículos del área. El diseño cubre 10.850 consultas y mantiene constantes las oportunidades de búsqueda mientras cambia su ámbito.

Para la geometría de las áreas sigo todas las parejas no ordenadas de las 26 áreas: 325 comparaciones por propiedad. Un modelo sostiene una dirección persistente solo si esa dirección resiste los 2.000 artículos por área de la selección principal, veinte medias muestras de 1.000 y cinco selecciones adicionales de 2.000 del mismo corpus. El acuerdo de los diez exige la misma dirección persistente en todo el conjunto. La oposición exige al menos dos modelos fijos que sostengan repetidamente direcciones contrarias. Las demás parejas quedan sin resolver, lo que deja la igualdad sin demostrar. Para distinguir un cambio de dirección del tamaño de

una diferencia, la magnitud relativa es $2(B - A)/(A + B)$, donde A y B son los valores de las áreas. Los mínimos de 0, 1, 5 y 10 % comprueban la sensibilidad a diferencias pequeñas.

Estas repeticiones permanecen dentro de un corpus fijo. Comprueban la sensibilidad a la selección de artículos; sus subconjuntos solapados no aportan muestras poblacionales independientes ni intervalos de confianza. Conservo como alertas los desplazamientos excesivos de la mediana y los rangos amplios de selección, con reglas operativas y denominadores registrados por separado en el suplemento. Los recuentos de parejas necesitan la misma cautela. Los modelos reaparecen en varias parejas de modelos y las áreas en varias parejas de áreas, por lo que sus recuentos son descriptivos. Ninguna prueba de significación trata las parejas como observaciones independientes.

3.5. Secuencia de las comprobaciones

La secuencia del trabajo forma parte de su interpretación. Las comparaciones iniciales de forma y vecinos precedieron a la muestra ampliada de entradas, las búsquedas emparejadas de especialidades y el atlas de casos. La morfología fue una ampliación exploratoria posterior, y el resumen de todas las parejas siguió a sus primeros ejemplos. Las reglas se registraron localmente antes de los nuevos cálculos correspondientes. Ese registro no es un preregistro externo del estudio completo. Los centros de grupos aleatorios y la comprobación con una fracción fija de vecinos fueron controles añadidos después de resultados anteriores. El Suplemento S2 registra la secuencia, y los Suplementos S3–S7 conservan las comprobaciones de tiempo, composición, características de los modelos, errores de la fuente y procesamiento, incluidas las que acotan las conclusiones.

4. Resultados

4.1. Estructura general compartida y variación dentro de las áreas

Los modelos coinciden mucho en la disposición de los centros de los grupos. Con 256 artículos por centro, la CKA corregida media es de 0,939 para las 26 áreas y de 0,911 para 217 especialidades (Figura 1A). Al restringir la segunda comparación a 26 centros de especialidades, el valor es 0,902. Los grupos aleatorios con tamaños y fechas iguales también presentan acuerdo positivo, alrededor de 0,63–0,64, pero no alcanzan el nivel observado. El promedio contribuye, por tanto, al acuerdo, aunque no basta para explicar el asociado a los grupos definidos por estas etiquetas.

La organización interna tiene un nivel de acuerdo más modesto: la CKA media ronda 0,63 en las áreas y 0,64 en las mismas 183 especialidades disponibles en todos los tamaños (Figura 1B). Esas medias cambian poco entre 128 y 512 artículos. Una etiqueta disciplinar más detallada no produce automáticamente una comparación menos consistente. La distancia con

el panel de centros es grande, pero su interpretación no llega a establecer un efecto causal de la escala. Los centros promediados y los artículos individuales son objetos distintos.

Las medidas alternativas respaldan en términos generales el orden del acuerdo entre parejas de modelos. En los 130 grupos originales de área y período, la correlación media de rangos con la CKA corregida es 0,891 para Procrustes y 0,881 para los rangos de distancias. El acuerdo no es completo, y el control original de selección conserva 50 alertas entre 5.850 comparaciones de pareja de modelos y grupo (Tabla S4). Estas limitaciones afectan a comparaciones concretas; una media global no las elimina.




Figura 1: Acuerdo entre los centros de los grupos y dentro de los grupos. (A) CKA corregida media de las parejas fijas de modelos y las comparaciones de centros guardadas; cada centro contiene 256 artículos. Los grupos aleatorios conservan tamaños y fechas. La condición de 26 especialidades controla el número de centros. (B) Acuerdo interno con tres cantidades de artículos, para 26 áreas y las mismas 183 especialidades válidas. Los puntos y las etiquetas muestran medias; las líneas abarcan los percentiles 2,5–97,5 entre comparaciones de grupo y pareja de modelos (1.170 para áreas; 8.235 para especialidades). Son rangos descriptivos, no intervalos de confianza; las parejas de modelos no son independientes. Todos los ejes de CKA van de 0 a 1. Los paneles comparan objetos distintos, por lo que su diferencia no es un efecto causal estimado.

4.2. Acuerdo de vecinos en comparaciones emparejadas

En las búsquedas completas dentro de los grupos de área y período, dos modelos conservan de media el 30,3 % de los 25 vecinos más próximos: unos 7,6 artículos de 25. Esta media da el mismo peso a cada grupo y pareja de modelos. Restringir cada grupo a 2.048 candidatos comunes aumenta la coincidencia al 31,9 %. En la búsqueda separada sobre el corpus general de 400.000 artículos, 13.000 consultas equilibradas conservan el 17,5 %. Este último resultado cambia tanto el ámbito como el número de candidatos, por lo que no demuestra por sí solo que haya menos acuerdo al cruzar fronteras disciplinares.

El experimento emparejado de área y especialidad aborda directamente esa ambigüedad (Figura 2). Con las mismas consultas, fechas y 256 candidatos, el acuerdo es menor en la especialidad en 127 de 217 casos y mayor en 90. La diferencia media es pequeña: $-1,35$ puntos porcentuales. Con 50 vecinos, el reparto pasa a 109 casos con menos acuerdo y 108 con más. Una búsqueda más estrecha puede conservar más vecinos o menos, según el grupo y el número de vecinos elegido. No hay una pérdida universal de acuerdo al pasar de área a especialidad.

El acuerdo de forma y el de vecinos sí varían juntos: las 45 medias por pareja de modelos originales tienen una correlación descriptiva de rangos de 0,920. Mantengo ambos porque la interpretación cambia con el objeto. La CKA resume relaciones distribuidas por el espacio. Una lista de vecinos nombra los artículos que encontraría allí un lector. Su asociación no hace intercambiables esas consecuencias, ni informar de ambas crea evidencia independiente de fiabilidad.

El atlas permite examinar esas diferencias locales. Sus ejemplos de especialidades se seleccionan mediante una regla registrada de persistencia en 27 combinaciones de tamaño, regla de representación y número de vecinos. Los ejemplos de artículos muestran después relaciones que se mantienen entre modelos y otras cuya inclusión cambia mucho (Suplemento S4). Algunos casos extremos revelan problemas de la fuente: un libro de historia aparece en Física, un registro sobre infección aparece en Ciencia Política y un anuncio sigue en el corpus. La comparación con los registros originales confirma que son problemas de la fuente o de clasificación, no filas de embeddings mal alineadas. Los ejemplos son exploratorios y se han seleccionado deliberadamente; no estiman la frecuencia de esos errores ni la precisión de las relaciones.

4.3. Texto de entrada y decisiones de representación

El texto que se entrega al modelo merece tanta atención como su nombre. En los mismos 52.000 artículos, cambiar de modelo da un cambio medio de forma de 0,370; conservarlo y entregar solo el título da 0,366, midiendo el cambio como uno menos la CKA corregida. Las fracciones correspondientes de vecinos sustituidos son 68,8 % y 70,7 % (Figura 3). Una




Figura 2: Acuerdo de vecinos en búsquedas emparejadas de área y especialidad. Cada punto es una de las 217 especialidades, con el promedio de las parejas de modelos y diez selecciones de candidatos. Ambos ámbitos contienen las mismas 50 consultas fijas entre 256 candidatos y fechas igualadas; se excluye el propio artículo. El conjunto del área está condicionado por estas consultas. Los puntos por encima de la diagonal tienen más coincidencia en la búsqueda estrecha; los situados por debajo tienen menos. La dispersión describe diferencias entre grupos, no intervalos de confianza.

decisión sobre la entrada puede, por tanto, tener consecuencias de tamaño comparable en este diseño. La proximidad de las medias deja sin contrastar su equivalencia.

Quitar solo el título cambia menos. Las entradas de solo resumen tienen un cambio medio de forma de 0,027, pero sustituyen el 22,1 % de los 25 vecinos. Por tanto, un cambio pequeño en la geometría general puede alterar los artículos recuperados localmente. También hay diferencias importantes entre modelos: al usar solo el título, la sustitución de vecinos va del 51,7 % en MPNet al 84,2 % en SciBERT (Tabla S5). Una única media conjunta ocultaría esas diferencias.

Incluso el orden de esos efectos medios depende de cómo se obtiene el vector. Con la regla principal de la media, quitar el título tiene un efecto relativamente pequeño, y quitar el resumen supera ligeramente al cambio de modelo en la sustitución media de vecinos. Reemplazar




Figura 3: Cambios asociados al modelo y al texto de entrada. Los mismos 52.000 identificadores aportan 2.000 candidatos por área. La entrada de referencia es título y resumen: quitar el resumen deja el título, y quitar el título deja el resumen. (A) Uno menos la CKA corregida. (B) Fracción de los 25 vecinos sustituidos. Cada punto es la media de un área sobre el conjunto fijo de modelos. Las cajas muestran la mediana y el rango intercuartílico, con bigotes de 1,5 veces ese rango; se muestran todas las áreas. No son intervalos de confianza. Se mantienen los límites propios de texto.

la media por CLS o SEP en los cuatro BERT de palabras invierte ese último orden. Cuatro representaciones se mueven a la vez en estos escenarios, incluida la referencia entre modelos. El resultado es una sensibilidad de la comparación práctica, sin aislar un efecto causal de la combinación de las salidas. No justifica elegir una receta simplemente porque produzca más acuerdo.

La muestra ampliada reduce la sensibilidad a la selección de artículos. Con 100 selecciones comparables en cada tamaño, el control del contraste de forma pasa de 72 alertas entre 520 contrastes de modelo, área y entrada con 26.000 artículos a cinco con 52.000. La comprobación anterior de 20 selecciones da 31 y cuatro, respectivamente (Figura S1). Se conservan ambos registros. Superar este control no significa que el contraste sea distinto de cero ni certifica todos los resultados de vecinos o variantes de representación. Los controles de fragmento común y longitud de MiniLM también distinguen la exposición desigual al texto de un error de programación: el límite original de MiniLM era su ajuste documentado, no un fallo de implementación.

4.4. Persistencia e inversión de las comparaciones geométricas entre áreas

La ampliación geométrica se centra en una afirmación que un lector podría hacer: que un área tiene una propiedad medida mayor que otra. Primero compruebo el cambio de artículos dentro de un modelo. Entre los 260 casos de modelo y área, la apertura angular no presenta alertas ni con medias muestras ni con selecciones de igual tamaño. La dimensión lineal efectiva conserva cuatro alertas en medias muestras, aunque las cinco selecciones de igual tamaño no producen ninguna (Tabla S12). Ambas observaciones pertenecen al resultado. La comprobación satisfactoria de igual tamaño no puede sustituir a los cuatro casos señalados por el otro control.

Cambiar de modelo pone de manifiesto la distinción. Entre las 325 parejas de áreas, la apertura angular tiene una dirección persistente común a los diez modelos en 42 parejas, oposición persistente en 262 y un resultado sin resolver en 21. Para la dimensión lineal efectiva, los recuentos son 54, 221 y 50 (Figura 4). En una oposición, al menos dos modelos concretos mantienen direcciones contrarias a lo largo de las 26 condiciones de selección guardadas. La afirmación se refiere a esos modelos opuestos persistentes, sin exigir que todos discrepen. Una pareja sin resolver aún puede contener acuerdo parcial.

El tamaño de la diferencia cambia lo que podemos interpretar de esos totales. Muchas oposiciones angulares son pequeñas. Exigir que ambas direcciones opuestas superen una diferencia relativa simétrica del 5 % deja 96 parejas angulares; al 10 %, quedan 19. La dimensión lineal efectiva conserva 177 y 126 oposiciones con los mismos cortes. Mantengo estas magnitudes junto a los recuentos de dirección porque una diferencia persistente no tiene por qué ser grande. El mínimo es una elección explícita de sensibilidad, no una frontera universal de importancia científica. La Figura 4 conserva las 325 parejas en cada fila, incluido el grupo creciente de casos sin resolver.

Las medidas alternativas conservan buena parte del patrón. Al exigir que los mismos modelos opuestos mantengan sus direcciones en las alternativas angulares, permanecen 225 de las 262 oposiciones originales. Las alternativas espectrales conservan 196 de 221. Su cobertura es distinta: las alternativas angulares tienen las 26 condiciones de selección, mientras que el rango basado en entropía y el recuento del 80 % de varianza están disponibles para tres. Estas alternativas también comparten buena parte de su construcción matemática. Su acuerdo respalda una descripción geométrica, sin convertirla en una medida de diversidad temática.

El resultado no se limita a los cuatro BERT de palabras. Al restringir el conjunto a SPECTER, SPECTER2, SciNCL, MPNet, MiniLM y SimCSE, siguen apareciendo 231 oposiciones angulares y 160 de dimensión efectiva con mínimo cero. Un conjunto menor tiene menos oportunidades de contener modelos opuestos, por lo que el cambio en los recuentos no aísla un efecto del objetivo de entrenamiento. Las Tablas S14–S15 incluyen las omisiones de cada modelo y todas las clasificaciones de parejas.




Figura 4: Persistencia, oposición y magnitud de las comparaciones entre áreas. Cada fila contiene las 325 parejas para una propiedad y diez modelos. La dirección de un modelo debe mantenerse en la selección principal, veinte medias muestras y cinco selecciones adicionales de igual tamaño del mismo corpus. El acuerdo de los diez requiere una dirección común persistente; la oposición exige al menos dos modelos fijos con direcciones contrarias persistentes. Las demás parejas quedan sin resolver. La magnitud utiliza $2(B - A)/(A + B)$. Los cuatro mínimos son cortes operativos, no umbrales de significación o precisión. Las 26 condiciones se solapan; los controles puntuales se presentan por separado.

Las decisiones de procesamiento añaden otro límite. Después de restar el centro global y volver a normalizar, la misma pareja original de modelos opuestos y sus direcciones se conservan en 145 de 262 oposiciones angulares y en 218 de 221 oposiciones de dimensión efectiva, dentro del control puntual emparejado. La ordenación angular depende, por tanto, más de esa elección. Cambiar la regla de combinación también puede invertir comparaciones (Tabla S16). Son controles puntuales con referencias emparejadas, no otra serie de confirmaciones con 26 repeticiones. Las conclusiones se refieren a representaciones definidas explícitamente, no a propiedades que deban sobrevivir a cualquier transformación.

En la conexión, la interpretación sustantiva propuesta no superó las comprobaciones. Bajo algunas reglas, las nubes alargadas y los puntos extremos aislados podían parecer fragmentación, y las medidas cambiaban sustancialmente con el tamaño de muestra y el número de

vecinos. Solo el control de selecciones de igual tamaño conservó 51 alertas de conexión entre 260 casos. Mantengo esos resultados en el Suplemento S6 junto con las comprobaciones fallidas de su significado. No aportan aquí una base defendible para decir que un área contenga más grupos temáticos separados.

5. Discusión

5.1. Del acuerdo entre mapas a la persistencia de una afirmación

El resultado que trasladaría a una aplicación de mapas de la ciencia es que una comparación repetible puede seguir dependiendo de su representación. El análisis de centros establece una estructura general compartida por encima de la referencia aleatoria. Las comparaciones de áreas muestran después órdenes opuestos persistentes con distintos modelos, pese a cambiar repetidamente los artículos. Una puntuación global de acuerdo deja ese desacuerdo sin resolver. Por eso vincularía la afirmación de robustez a la relación, el conjunto de vecinos o la comparación de áreas que se está utilizando, y seguiría esa afirmación a través de las representaciones alternativas.

Esto continúa la pregunta metodológica ya planteada en los mapas de la ciencia (Gläser et al., 2017; Boyack and Klavans, 2020). Evaluar una representación frente a una clasificación externa, como hacen Constantino et al. (2025), establece su rendimiento respecto a ese criterio. Comparar alineación y búsqueda, como en Caspari et al. (2024), establece qué relaciones comparten las representaciones. La aportación que defiendo aquí conecta esos niveles con la persistencia y la magnitud de comparaciones concretas entre áreas sobre artículos emparejados. Se apoya en medidas de acuerdo existentes y en una preocupación establecida por la elección de representación.

Hay una razón para ser preciso sobre el significado de las cantidades geométricas. Un ángulo describe separación, y PR describe cómo ocupa la varianza las direcciones. Interdisciplinariedad y diversidad semántica añadirían afirmaciones sobre el contenido de los artículos. Esas afirmaciones necesitan su propia evidencia, como también advierte el trabajo relacionado sobre isotropía de embeddings (Rudman et al., 2022). Las comprobaciones de fragmentación muestran por qué mantengo explícito este límite. Una medida puede distinguir repetidamente dos nubes sin establecer la diferencia sustantiva que su nombre parece prometer.

5.2. Implicaciones para comparar mapas de la ciencia

Antes de interpretar un mapa de la ciencia, escribiría qué comparación se espera que sostenga. En búsqueda, esa comparación incluye los artículos candidatos y el número de vecinos. En geometría de áreas, incluye la regla de representación, el equilibrio de artículos y la diferencia mínima. Esas decisiones dan un objeto concreto a la comprobación de robustez. La documentación debería ser igual de específica: el nombre del modelo necesita su entrada de título o resumen, el límite de texto y la regla de combinación de las salidas. De otro modo, el lector sabe qué modelo se utilizó, pero no puede reconstruir la representación solo con esa información.

Medicina ofrece una razón útil para resistirse a una única explicación del desacuerdo. Su acuerdo de forma está por debajo del de Energía, pero su acuerdo de vecinos no es siempre el menor. Equilibrar la composición por especialidades y excluir BioBERT y PubMedBERT conservan la diferencia entre Medicina y Energía (Suplemento S5). Esos resultados acotan explicaciones sin seleccionar una causa única. Las familias de modelos también cambian con la forma de obtener el vector. Como estos modelos difieren en arquitecturas, fuentes de entrenamiento y objetivos relacionados, sus similitudes no permiten separar causalmente esas influencias.

La comparación temporal ilustra cómo una conclusión puede depender de las oportunidades de comparación. El acuerdo medio de forma aumenta ligeramente del primer período al último. El acuerdo de vecinos baja 0,87 puntos porcentuales con todos los candidatos y sube 0,91 puntos con 2.048 candidatos por grupo. El diseño de búsqueda cambia el signo. No interpreto esto como una convergencia histórica de la ciencia. Los modelos actuales representan publicaciones de fechas distintas con sus parámetros actuales; no recuperan el conocimiento disponible cuando aparecieron esas publicaciones.

5.3. Límites y siguiente validación

Un corpus grande sigue teniendo límites. Este contiene registros seleccionados de OpenAlex con resúmenes utilizables y texto predominantemente inglés. La muestra de refuerzo, las muestras equilibradas y los pesos iguales apoyan las comparaciones entre áreas sin estimar la distribución mundial de la investigación. El atlas deja visibles errores de clasificación y contenido que sobrevivieron a las reglas de limpieza. Eliminar problemas especificados no certifica cada registro. Las selecciones guardadas y las versiones fijas permiten inspeccionar la comparación; hacer más selecciones del mismo corpus deja intacta la cobertura que falta.

El conjunto de modelos necesita la misma precisión. Los modelos comparten algunas arquitecturas, fuentes de entrenamiento y objetivos, y varios no fueron entrenados específicamente para similitud. Las comprobaciones restringidas a seis modelos orientados a similitud y a otras reglas de representación ayudan a localizar sensibilidades dentro del conjunto, sin

convertirlo en una muestra representativa de todos los modelos. Una oposición persistente establece que la elección importa entre estos modelos. No puede decidir cuál de los órdenes opuestos es correcto en términos de contenido.

También conservo la historia exploratoria. La ampliación geométrica siguió a resultados anteriores y el resumen de todas las parejas siguió a sus primeros ejemplos. Hacer disponible esa secuencia y las tablas completas no convierte las comparaciones posteriores en un estudio confirmatorio. La siguiente pregunta que abordaría es si una comparación relevante entre áreas coincide con relaciones entre artículos evaluadas de forma independiente o responde a una pregunta propia de una disciplina. Ese paso comprobaría la interpretación que aquí queda abierta. Un conjunto mayor de modelos, por sí solo, no la aportaría.

6. Conclusión

Un mapa general compartido deja espacio para vecinos distintos y comparaciones geométricas opuestas entre áreas. El texto de entrada puede importar tanto como el modelo, y un resultado que resiste cambiar los artículos puede invertirse al cambiar el modelo. Por eso evaluaría la robustez allí donde se hace la afirmación científica. La apertura angular y la dimensión lineal efectiva permiten esa evaluación para propiedades geométricas definidas, manteniendo visibles las magnitudes y las sensibilidades al procesamiento. La distinción que queda es esencial: son propiedades de las representaciones. Establecer qué dicen sobre el conocimiento científico requiere más validación.

Declaraciones

Contribuciones del autor. Alejandro Treny Ortega concibió el proyecto y dirigió la investigación y la preparación del manuscrito como investigador independiente. La ayuda computacional y editorial se declara a continuación.

Conflictos de interés. El autor declara que no tiene conflictos de interés.

Financiación. Esta investigación no recibió financiación externa.

Disponibilidad de datos y código. El repositorio del proyecto es <https://github.com/aleetreny/Shape-of-Science-Robustness>. Este borrador se acompaña de las tablas utilizadas en las figuras y de las fuentes editables del manuscrito. El corpus fijo, los vectores y los registros locales completos de ejecución no se han depositado en un archivo público persistente. Publicar el código por sí solo no permite reproducir por completo este análisis. El Suplemento S8 detalla el inventario de acceso y los requisitos pendientes; aquí no se afirma que exista un depósito de datos ni un identificador persistente.

Uso de herramientas de inteligencia artificial. OpenAI Codex ayudó con las búsquedas bibliográficas, el desarrollo de software y los análisis, la visualización y la redacción y edición del manuscrito. El autor es responsable del contenido.

Referencias

- Iz Beltagy, Kyle Lo, and Arman Cohan. SciBERT: A pretrained language model for scientific text. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3615–3620, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1371. URL <https://aclanthology.org/D19-1371/>.
- Kevin W. Boyack and Richard Klavans. A comparison of large-scale science models based on textual, direct citation and hybrid relatedness. *Quantitative Science Studies*, 1(4):1570–1585, 2020. ISSN 2641-3337. doi: 10.1162/qss_a_00085.
- Laura Caspari, Kanishka Ghosh Dastidar, Saber Zerhoudi, Jelena Mitrovic, and Michael Granitzer. Beyond benchmarks: Evaluating embedding model similarity for retrieval augmented generation systems. arXiv:2407.08275, 2024. URL <https://arxiv.org/abs/2407.08275>. Preprint.
- Arman Cohan, Sergey Feldman, Iz Beltagy, Doug Downey, and Daniel Weld. SPECTER: Document-level representation learning using citation-informed transformers. In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2270–2282, Online, jul 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.207. URL <https://aclanthology.org/2020.acl-main.207/>.
- Isabel Constantino, Sadamori Kojaku, Santo Fortunato, and Yong-Yeol Ahn. Representing the disciplinary structure of physics: A comparative evaluation of graph and text embedding methods. *Quantitative Science Studies*, 6:263–280, 2025. ISSN 2641-3337. doi: 10.1162/qss_a_00349.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Jill Burstein, Christy Doran, and Thamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, jun 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423/>.
- Tianyu Gao, Xingcheng Yao, and Danqi Chen. SimCSE: Simple contrastive learning of sentence embeddings. In Marie-Francine Moens, Xuanjing Huang, Lucia Specia, and Scott Wen-tau Yih, editors, *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 6894–6910, Online and Punta Cana, Dominican Republic, nov 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.emnlp-main.552. URL <https://aclanthology.org/2021.emnlp-main.552/>.

- Jochen Gläser, Wolfgang Glänzel, and Andrea Scharnhorst. Same data—different results? towards a comparative approach to the identification of thematic structures in science. *Scientometrics*, 111(2):981–998, 2017. ISSN 0138-9130. doi: 10.1007/s11192-017-2296-z.
- Rita González-Márquez, Luca Schmidt, Benjamin M. Schmidt, Philipp Berens, and Dmitry Kobak. The landscape of biomedical research. *Patterns*, 5(6):100968, 2024. ISSN 2666-3899. doi: 10.1016/j.patter.2024.100968.
- Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23, 2022. ISSN 2691-1957. doi: 10.1145/3458754.
- Matthias Held and Theresa Velden. How to interpret algorithmically constructed topical structures of scientific fields? a case study of citation-based mappings of the research specialty of invasion biology. *Quantitative Science Studies*, 3(3):651–671, 2022. ISSN 2641-3337. doi: 10.1162/qss_a_00194.
- Nathaniel Imel and Zachary Hafen. Density, asymmetry and citation dynamics in scientific literature. arXiv:2506.23366, 2025. URL <https://arxiv.org/abs/2506.23366>. Preprint.
- Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In Kamalika Chaudhuri and Ruslan Salakhutdinov, editors, *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529. PMLR, 09–15 Jun 2019. URL <https://proceedings.mlr.press/v97/kornblith19a.html>.
- Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. Biobert: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240, 2020. ISSN 1367-4803. doi: 10.1093/bioinformatics/btz682.
- Alex Murphy, Joel Zylberberg, and Alona Fyshe. Correcting biased centered kernel alignment measures in biological and artificial neural networks. arXiv:2405.01012, 2024. URL <https://arxiv.org/abs/2405.01012>. Preprint.
- OpenAlex. Topics. OpenAlex Help Center, 2026. URL <https://help.openalex.org/data/topics/>. Accessed 18 September 2026.
- Malte Ostendorff, Nils Rethmeier, Isabelle Augenstein, Bela Gipp, and Georg Rehm. Neighborhood contrastive learning for scientific document representations with citation embeddings. In Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang, editors, *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11670–11688, Abu Dhabi, United Arab Emirates, dec 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.emnlp-main.802. URL <https://aclanthology.org/2022.emnlp-main.802/>.
- Jason Priem, Heather Piwowar, and Richard Orr. OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts, 2022. URL <https://arxiv.org/abs/2205.01833v2>. Preprint, version 2.

- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In Kentaro Inui, Jing Jiang, Vincent Ng, and Xiaojun Wan, editors, *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China, nov 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1410. URL <https://aclanthology.org/D19-1410/>.
- William Rudman, Nate Gillman, Taylor Rayne, and Carsten Eickhoff. IsoScore: Measuring the uniformity of embedding space utilization. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3325–3339, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.262. URL <https://aclanthology.org/2022.findings-acl.262/>.
- Amanpreet Singh, Mike D’Arcy, Arman Cohan, Doug Downey, and Sergey Feldman. SciRe-eval: A multi-format benchmark for scientific document representations. In Houda Bouamor, Juan Pino, and Kalika Bali, editors, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 5548–5566, Singapore, dec 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.338. URL <https://aclanthology.org/2023.emnlp-main.338/>.
- Shruti Singh and Mayank Singh. The inefficiency of language models in scholarly retrieval: An experimental walk-through. In Smaranda Muresan, Preslav Nakov, and Aline Villavicencio, editors, *Findings of the Association for Computational Linguistics: ACL 2022*, pages 3153–3173, Dublin, Ireland, may 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.findings-acl.249. URL <https://aclanthology.org/2022.findings-acl.249/>.
- Alex H Williams. Equivalence between representational similarity analysis, centered kernel alignment, and canonical correlations analysis. In Marco Fumero, Clementine Domine, Zorah Löhner, Donato Crisostomi, Luca Moschella, and Kimberly Stachenfeld, editors, *Proceedings of UniReps: the Second Edition of the Workshop on Unifying Representations in Neural Models*, volume 285 of *Proceedings of Machine Learning Research*, pages 10–23. PMLR, 14 Dec 2024. URL <https://proceedings.mlr.press/v285/williams24a.html>.
- Alex H Williams, Erin Kunz, Simon Kornblith, and Scott Linderman. Generalized shape metrics on neural representations. In M. Ranzato, A. Beygelzimer, Y. Dauphin, P.S. Liang, and J. Wortman Vaughan, editors, *Advances in Neural Information Processing Systems*, volume 34, pages 4738–4750. Curran Associates, Inc., 2021. URL https://proceedings.neurips.cc/paper_files/paper/2021/file/252a3dbaeb32e7690242ad3b556e626b-Paper.pdf.